


LLM 后训练之 Data Filtering

深度研究与工程手册

从清洗、质量评分、难度与多样性，到 Preference Pair、RL Rollout、影响函数与在线数据选择

Data Filtering = Hard Gating + Value Estimation + Diversity-Aware Budget Selection



研究日期：2026-08-13

系列：LLM Post-Training Engineering

目录与研究地图

模块	核心问题
0-2 第一性原理	Data Filtering 到底在优化什么？和 Cleaning / Selection / Curation 有何区别？
3-8 样本价值	Validity、Correctness、Quality、Difficulty、Diversity、Novelty 如何组合？
9-13 风险与完整性	Dedup、Coverage、Contamination、Provenance、Safety 如何治理？
14-18 阶段化过滤	SFT / DPO / RLVR / Distillation / Agent 需要怎样不同的过滤器？
19-23 先进选择方法	IFD / SelectIT / DEITA / LESS / RDS+ / D3 / GAIA / TAGS / MDS
24-27 生产工程	Scale-aware cost、Calibration、Data Lineage、Filter Service Contract
28-31 评测与落地	Ablation、失败模式、成熟度模型、Cookbook 与检查清单
32 参考资料	2023-2026 关键论文与公开技术报告

阅读方式：如果你是研究算法：重点看第 6-8、19-23 章；如果你在搭后训练平台：重点看第 2、14-18、24-27 章；如果你负责数据团队：重点看第 3-13、30-31 章。

0. 执行摘要：Data Filtering 是训练信号的“纯化与预算分配层”

后训练数据不是越多越好。真正的问题是：在有限 token、GPU、标注与 rollout 预算下，哪些样本值得让当前 policy 再学习一次？因此 Data Filtering 不应被理解成单纯的脏数据清洗，而应被理解为从候选经验池中构造“最大有效学习信号”的阶段化决策系统。

Single-sample “quality” is not enough



Training value is context-dependent: a good sample can be redundant, too easy, off-target, contaminated, or too expensive.

图 0-1 单样本质量只是训练价值的一部分。

层	问题	典型动作
Hard Gate	这个样本是否允许进入？	schema、空值、语言、policy、test contamination、invalid tool trace
Correctness / Reliability	答案或轨迹可靠吗？	unit test、math verifier、RM/Judge、human audit
Value Scoring	它对当前模型有多大训练价值？	quality、difficulty、uncertainty、influence、margin
Set-level Selection	它加入集合后还增加信息吗？	dedup、coverage、diversity、coreset、representation selection
Budget Allocation	值得花多少 token/GPU？	sample cap、token budget、task balancing、stage routing
Feedback Control	模型变强后还值钱吗？	failure mining、dynamic sampling、online selection

核心公式：不是 Quality(sample) 最大化，而更接近：在预算 B 下，选择能最大化目标能力增益、覆盖与可靠性，同时最小化冗余、污染与计算成本的数据子集。

1. Cleaning、Filtering、Selection、Pruning、Curation：概念边界

术语	输入	输出	本质
Cleaning	原始样本	格式正确样本	修正/删除明显错误与噪声
Filtering	候选样本	满足条件的样本	规则或模型判断是否保留
Scoring	候选样本	连续分数/标签	估计质量、难度、价值、风险
Selection	已评分/已表示的池	预算内子集	全局组合优化
Pruning	已有训练集	更小训练集	删除冗余或低价值数据
Curation	多来源数据	可训练数据资产	来源、过滤、混合、版本、审计的全流程

Know-Why: 把所有步骤都叫“过滤”会掩盖两个重要差异：第一，硬门禁和软排序的错误成本不同；第二，单样本判断和集合级选择的目标不同。

Raw Pool -> Cleaning -> Hard Gates -> Scoring -> Dedup/Coverage -> Budget Selection -> Stage Dataset -> Train

2. 第一性模型：Data Filtering 应优化“有效学习信号 / 成本”

可以把样本 i 的训练价值拆成硬约束与软价值。硬约束先决定“能否使用”，软价值再决定“值不值得优先使用”。

```
Gate_i = Valid_i × PolicyOK_i × NonContaminated_i × ProvenanceOK_i
Value_i = f(Quality, Correctness, Difficulty, Novelty, TargetRelevance, Verifiability, Influence)
Utility_i = Gate_i × Value_i / (TokenCost_i + JudgeCost_i + TrainCost_i)
```

为什么先 Gate 再 Score：如果把 correctness、污染或关键安全约束直接和“写得漂亮”线性加权，就会允许高风格分抵消硬错误。生产系统通常需要 lexicographic / gating 逻辑。

Data Filtering = Hard Gating + Value Estimation + Diversity-Aware Budget Selection




图 2-1 生产级过滤通常是漏斗，而不是一个总分阈值。

3. 维度一：Structural Validity - 最便宜、最定性理

检查	例子	建议
Schema	messages / role / tool_call JSON 是否合法	deterministic parser; 失败直接拒绝
Empty / Truncated	空 prompt、截断 response、异常 stop reason	hard gate
Turn Consistency	assistant/user 角色交错、tool result 缺失	state-machine validator
Language	语言与任务 metadata 不一致	language ID + whitelist/route
Length	极短无信息、超长异常、max context 溢出	按 stage 做长度窗，而非统一阈值
Tool Validity	不存在的 tool、参数 schema 错	tool schema verifier
Code Parse	语法无法解析	parser/compiler; 但不要把“能编译”当“正确”

工程推论：越能确定性验证的条件，越不应该交给昂贵 LLM Judge。把 LLM Judge 用在真正需要语义判断的地方，可以降低成本并提高可复现性。

4. 维度二：Correctness / Reliability - “好写法”不能替代“正确”

任务	优先 verifier	次级信号
Math	exact / symbolic / answer equivalence	reasoning judge / PRM
Code	unit test / hidden test / compiler	code judge / static analysis
Structured IF	schema / regex / exact constraints	LLM rubric
Tool Use	tool schema + environment state	trajectory judge
Factual QA	reference / retrieval evidence	LLM factuality judge
Open Writing	无强 verifier	rubric judge + human preference

公开研究证据：Llama 3 在后训练数据处理中明确将质量与难度分开评分；其质量分结合 Reward Model 和 Llama-based judge，并观察到两类信号存在高分歧，组合后内部测试集 recall 最好。[10]

Know-How：正确性 filter 不一定要“全自动”。高价值切片可以使用 deterministic verifier；不可验证切片用 ensemble judge；高风险/高不确定样本进入 human audit。

5. 维度三：Quality - 从“一个总分”升级为分维度评分

维度	典型问题	可观测信号
Accuracy	回答内容是否事实/逻辑正确?	verifier / reference / RM
Instruction Following	是否满足明确约束?	IFEval-style checks / rubric
Relevance	是否真正回答用户问题?	LLM judge / semantic checks
Completeness	关键步骤是否缺失?	rubric / coverage
Tone / Presentation	是否存在模板腔、过度道歉、emoji 模式?	rules + judge
Conciseness	是否信息密度低、冗长?	length-normalized rubric
Grounding	引用/工具结果是否被正确使用?	evidence consistency

公开研究证据：AlpaGasus 用强 LLM 从 Alpaca 52K 中筛到约 9K 高质量样本，报告更好的模型表现与显著训练时间下降；LIMA 则以 1,000 条人工精挑数据展示“少而精”的极端案例。[1][2]

警告：Quality scorer 很容易学到长度、格式、来源、模型风格等 shortcut。必须做 counterfactual / swap / style-control eval，检查 scorer 是否真的在评估内容。

6. 维度四：Difficulty - 不是越难越好，而是寻找 Learnable Frontier

难度的工程目标不是选“最难数据”，而是优先当前模型仍有学习空间、又不是纯噪声或不可解的数据。

区域	特征	训练价值
Too Easy	模型几乎总是正确 / loss 很低	梯度弱；可少量保留防遗忘
Learnable Frontier	模型有时成功、有时失败	通常信息密度最高
Very Hard but Valid	低成功率但可验证	适合 curriculum / teacher distill
Unanswerable / Noisy	参考答案错、条件不足	应过滤，不应误判为 hard

公开研究证据：IFD 使用条件与非条件答案生成难度估计来挑“cherry samples”；SelectIT 使用模型自身不确定性进行数据选择。DEITA 则把 complexity、quality、diversity 作为三个独立维度。[3][5][6]

工程推论：难度分数必须和 correctness / dependability 联动，否则“最难”集合往往会混入错误答案、模糊任务和不可解 prompt。

7. 维度五：Diversity / Coverage - 本高分不代表数据集高价

方法	关注对象	优点	风险
Exact / Near Dedup	文本重复	便宜、确定	抓不到语义重复
Embedding Dedup	语义相似	能去 paraphrase 类冗余	阈值敏感，可能误删同主题不同技能
Tag Coverage	任务/意图标签	可解释、易做配额	tagger 质量限制
K-center / Coreset	表示空间覆盖	集合级优化	高维距离不一定对应技能差异
RDS+	representation + target queries	大规模实验表现强	依赖 query set / representation

公开研究证据： InsTag 用开放标签量化 instruction diversity/complexity；Llama 3 的语义去重在 cluster 内按 quality × difficulty 排序，再做相似度阈值贪心保留。[4][10]

公开研究证据： 2024-2025 的大规模研究提醒：在百万级多来源池中，很多复杂 selection method 不再明显优于随机；representation-based RDS+ 是少数在大规模、多任务设置中稳定更强的方法之一。[13][14]

8. 去重不是“越狠越好”：需要层级化 Dedup

层级	建议 Key	为什么
Exact	normalized text hash	去完全重复与流水线重放
Prompt-level	user prompt	避免同一问题被大量不同 completion 放大
Response-level	answer semantics	防止 teacher 模板复制
Conversation-level	full dialog embedding	保留多轮结构多样性
Skill-level	tags / clusters	避免少数任务家族淹没长尾
Cross-source	source + semantic	检测多个公开数据集互相复制

Know-How： 去重的单位必须和训练目标匹配。DPO 可能需要保留同 prompt 的多 response；SFT 可能只想保留一个高质量 response；RL prompt pool 则应按 prompt 去重，但 rollout 本身必须保留组内多样性。

9. Contamination：过滤系统必须保护 Eval，而不仅是保护训练质量

公开研究证据： Tulu 3 对公开训练 prompt 做系统 decontamination，比较 full-string、n-gram 和 embedding matching 后选择 8-gram prompt matching；其规则把同一训练实例覆盖测试实例超过 50% token 的情况视为显著重叠，并对多个数据集实际删除 0.7%-11.3% 不等的样本。[9]

污染类型	例子	对策
Exact Test Leak	benchmark prompt 原样出现	exact / n-gram
Template Leak	只换数字/实体	partial n-gram / normalized structure
Answer Leak	训练 response 含测试答案	prompt+answer scan
Paraphrase Leak	语义改写测试题	embedding/LLM review；高误报风险
Synthetic Backflow	generator 训练过 benchmark	provenance + generator policy
Eval-guided Selection Leak	直接用测试集做 selection query	dev/query set 与 final test 隔离

关键边界： Decontamination 的目标是防止“测试信息进入训练闭环”。它不是一般的相似度去重；宁可建立独立 final test，也不要让 final test 参与数据打分与选择。

10. Provenance / Lineage：没有来源追踪，就无法解释过滤结果

字段	示例	用途
source_dataset	WildChat / synthetic / human	来源分析、license、bias
generator_model	teacher-v7	synthetic drift / style tracking
judge_version	rm-2026-07 / rubric-v3	重算与审计
filter_reason	duplicate / low_quality / contaminated	错误分析
scores	quality=0.91,difficulty=0.64	阈值复盘
verifier_evidence	pytest log / answer match	可验证性
parent_ids	prompt / response / pair parents	追踪数据派生
stage_usage	SFT/DPO/RLVR	防止错误跨阶段复用

sample_id -> source -> generator -> raw -> cleaned -> scored -> selected -> training_run -> checkpoint
-> eval

11. Safety / Policy Filtering：避免把“安全”做成单一删数据动作

后训练里的安全数据治理通常需要区分：应拒绝的请求、应安全完成的请求、无害但容易误拒绝的边界样本，以及高风险但需要分类/分析而非执行的样本。简单关键词删除会破坏边界学习。

类别	处理方式
明显非法/危险指令	按行为规范构造正确 refusal / safe completion；不是简单丢掉所有样本
Benign near-boundary	保留，防止过度拒绝
Policy ambiguity	进入高质量 human/rubric review
Sensitive domain factual QA	保留事实性与非操作性安全回答
Red-team failure	标注 failure taxonomy，形成 targeted corrective data

工程原则：安全过滤既是“数据准入”也是“行为分布塑形”。如果只删掉困难边界问题，模型不会自动学会正确区分。

12. SFT Data Filtering：目标是高质量 Behavior Prior




图 12-1 不同训练阶段的过滤优先级不同。

SFT Filter	建议
Hard validity	必须做：schema、角色、truncation、tool trace
Correctness	优先 verifier；开放任务用 judge ensemble
Quality	准确、instruction following、tone 分维度
Difficulty	保留 learnable frontier + 一部分 easy anchor
Diversity	tag/embedding/representation 级覆盖
Dedup	prompt / dialogue / semantic 多层
Mixture	过滤后还要重新 balance，防止某域被大量删空

公开研究证据： Llama 3 报告其多数后训练数据为模型生成，因此进行 rule-based cleaning、RM+Llama quality scoring、difficulty scoring 和 semantic dedup；最终数据 mix 还会对高质量来源多 epoch、对其他来源 downsample。[10]

13. Preference / DPO Data Filtering：Pair Quality 比单条 Response Quality 更重要

Pair 状态	问题	处理
chosen 好 / rejected 差	理想 pair	保留
chosen 略好 / rejected 也很好	margin 太小；可能造成不必要 unlearning	降权或转成 soft preference
chosen 差 / rejected 更差	会教模型偏爱低质量输出	过滤
label 反转	judge error	re-judge / human audit
style-only difference	可能只学 verbosity / formatting	做 style-controlled pair
off-policy stale pair	和当前 policy 太远	用于早期；后期补 on-policy pair

公开研究证据： UltraFeedback 展示了规模化 AI feedback 的路线；2025 的 preference data selection 工作进一步指出 DPO 不应无差别使用所有 pair，并报告仅用 UltraFeedback 约 10% 的高 margin 子集可提升若干模型的 AlpacaEval 2.0 表现。[11][17]

Know-How： Preference Filtering 的核心对象不是“response 分数”，而是 pair 信息量： $\text{label reliability} \times \text{quality floor} \times \text{preference margin} \times \text{policy relevance}$ 。

14. RLVR / GRPO Rollout Filtering：过滤“无梯度经验”

进入在线 RL 后，Data Filtering 从静态 dataset selection 变成 rollout-time experience gating。此时最重要的不是美学质量，而是：reward 是否可靠、group 是否产生学习信号、轨迹是否有效、长度/环境成本是否可接受。

公开研究证据：DAPO 的 Dynamic Sampling 明确过采样并过滤 accuracy=0 和 accuracy=1 的 prompt group，使 batch 中保留“既非全错也非全对”的 group，从而避免 zero-advantage/zero-gradient 经验占据训练批次；论文报告该策略提升样本效率并缩短达到同等性能的时间。[15]

RL Filter	为什么
Invalid reward / verifier error	错误 reward 会直接推动 policy 走错方向
All-correct group	组内 advantage=0；学习信号弱
All-wrong group	同样缺乏相对区分；可能需要更易 prompt / teacher
Overlong / gibberish	高 token 成本 + 噪声 reward
Duplicate trajectories	浪费 rollout budget
Environment failure	区分 agent 失败与环境本身异常

15. Distillation / Long-CoT Filtering：Teacher 输出也必须被审查

风险	过滤策略
Teacher final answer 错	math answer verifier / code tests
CoT 逻辑错误但碰巧答案对	process checks / multi-sample consistency / judge
模板化推理	semantic dedup / style diversity
异常超长 reasoning	length-efficiency score + correctness
benchmark leakage	prompt decontamination
language mixing / unreadable	format / language / readability gates

公开研究证据：DeepSeek-R1 报告在其多阶段 pipeline 中利用 rejection sampling 和过滤生成 SFT 数据以改善 reasoning、writing 与其他能力；公开的 AM-DeepSeek-R1-Distilled 数据集则采用 semantic dedup、测试污染清洗，并分别用参考答案、测试用例或 reward model 验证不同任务的蒸馏响应。[16][20]

16. Agent Trajectory Filtering：从“答案质量”升级到“状态转移质量”

轨迹维度	检查
Task Success	环境最终状态是否达到目标
Tool Validity	工具选择、参数、权限、返回解析
Efficiency	无意义循环、重复 read/search、成本
Recovery	工具失败后是否能诊断并恢复
Causal Use	final answer 是否真的使用 observation
Milestones	关键中间目标是否完成
Trajectory Diversity	避免只学一种脆弱工具路径

$$\text{trajectory_value} = \text{task_success} \times \text{validity} \times \text{evidence_use} \times \text{recovery} - \text{cost} - \text{redundant_steps}$$

Know-Why: Agent 数据的最小单位不再是 prompt-response，而是 trajectory。只看 final answer 会把“偶然成功”和“可复用策略”混在一起。

17. Model-aware Filtering：同一条数据对不同模型价值不同

Data value 不是数据本身的固定属性。对于强模型，一条简单 instruction 可能几乎没有梯度；对于弱模型，同一条样本可能非常关键。Targeted post-training 需要 model-aware / task-aware selection。

公开研究证据： LESS 用 optimizer-aware 的低秩梯度相似性估计训练样本对目标能力的影响，报告在若干任务上选择约 5% 数据即可超过全量数据训练；同时其选择结果可在不同模型规模和家族间一定程度迁移。[7]

信号	回答的问题	成本
Loss / PPL	模型觉得它难吗？	低
IFD / uncertainty	instruction 对 answer 的条件增益有多大？	中
Embedding similarity	它与目标任务语义/技能接近吗？	低-中
Gradient / influence	训练它是否会推动目标 eval？	高
On-policy failure	当前模型实际在哪些样本失败？	rollout 成本

18. Scale-aware Filtering：过滤器必须和数据规模一起被评测




图 18-1 概念图：复杂选择器的收益必须扣除 selection compute。

公开研究证据：2024 的 “Random Selection is Almost All You Need” 在百万级多来源数据上发现多数 self-scoring 选择器难以显著优于随机，并强调 diversity 的重要性；2025 的 Large-Scale Data Selection 则在最大 5.8M pool、最多 2.5M selection 的实验中发现很多方法仍落后于 random，但 RDS+ 在大规模和 FLOPs-controlled 设置中表现更稳定。[13][14]

必须报告	为什么
Pool Size	小池方法可能无法外推到百万级
Selected Size	选 6K 与选 1M 是完全不同问题
Selection FLOPs	外部 Judge / gradient 方法可能比省下的训练更贵
Training FLOPs	不能只看 sample 数，长样本 token 成本巨大
Wall-clock / throughput	生产系统受 I/O、judge latency、embedding pipeline 影响
Random / Balanced Random	永远保留便宜强 baseline

19. 方法谱系 I：Quality / Difficulty / Uncertainty Scoring

方法	核心信号	代表结论
LIMA	human curation	极少高质量演示即可建立强 instruction behavior
AlpaGasus	strong LLM quality score	52K → 9K，数据中心 IFT
IFD	instruction-following difficulty	用模型自身条件生成难度挑样本
SelectIT	uncertainty-aware self-reflection	不依赖额外强模型进行质量选择
Superfiltering	small-model filtering	弱模型可为更强模型筛数据，降低 filtering cost
DEITA	complexity + quality + diversity	6K SFT + 10K DPO 达到强 alignment 表现

重要变化：研究方向从“给每条数据一个质量分”逐步转向“质量 + 难度 + 多样性 + 模型状态 + 计算成本”的联合决策。

20. 方法谱系 II：Representation / Influence / Coreset


方法	信号	适合
InsTag	fine-grained intent tags	覆盖与复杂度分析
K-center / DiverseEvol	embedding distance	集合级覆盖
LESS	low-rank gradient similarity	targeted capability
RDS+	weighted representation pooling	大规模多任务选择
D3 (2025)	diversity + difficulty + dependability	低预算 sample-efficient tuning
TAGS (2026)	knowledge tree + information gain	可控知识覆盖与领域对齐

公开研究证据： 2025 D3 把 Diversity、Difficulty、Dependability 联合成 weighted coreset；2026 TAGS 进一步把扁平 embedding/tag 升级为知识树，在树层面控制信息增益与领域分布。[18][22]

21. 方法谱系 III：Online / Dynamic Data Selection

静态过滤假设“数据价值在训练开始前就能确定”。但随着模型学习，同一条样本的价值会变化。在线选择方法把 data valuation 变成 feedback controller。

Dynamic Data Filtering Controller



Model state changes → useful data changes. Filtering should be re-evaluated as capabilities, reward margins and failures move.

图 21-1 Model state 变化后，需要重新估计数据价值。

公开研究证据：2026 GAIA 将 instruction data valuation 视为非平稳在线估计，用 Gaussian Process 建模语义空间中的 utility，并通过动态策略融合自适应改变选样重点；这代表“filter once”向“select while training”演进。[21]

Static	Dynamic
训练前一次打分	随 checkpoint / failure 更新
value(sample) 固定	value(sample, model_t) 变化
容易实现 / 可复现	更贴近真实学习过程
可能迅速过时	需要在线 scoring 与 buffer 管理

22. 多轮对话 Data Filtering：不能只按单 turn 打分

问题	单 turn filter 为什么不够	对话级指标
Topic Drift	每个 turn 都合理，但整段偏离任务	trajectory/topic grounding
Repetitive Chitchat	局部自然但无信息进展	information progress
Form Mismatch	user 问题和 assistant 形式不匹配	query-answer form consistency
Broken Context	后续回答依赖不存在事实	entity / state consistency
Long Dialogue Cost	样本数少但 token 巨大	dialogue-level utility/token

公开研究证据：2026 MDS 专门研究 multi-turn instruction tuning 数据选择，主张以整段 conversation 而非孤立 turn 评分，并结合全局覆盖与局部结构可靠性。[23]

23. Filtering Cost Model：不要用“样本数”假装预算

$$\text{TotalCost} = \text{ScoringCost} + \text{EmbeddingCost} + \text{VerifierCost} + \text{HumanAudit} + \text{TrainingTokenCost} + \text{RolloutCost}$$

数据类型	隐藏成本
Long context SFT	1 条样本可能等于数十/数百条短样本 token
Preference pair	至少两条 completion + judge / label
GRPO group	N 个 rollout + verifier + policy update
Agent trajectory	tool / environment wall-clock + external API
Gradient influence	对大量样本计算/存储梯度特征
LLM Judge filtering	外部模型推理成本与吞吐瓶颈

推荐 KPI：不要只汇报“保留率 20%”。更有意义的是：Eval Gain / GPU-hour、Effective Signal / Million Tokens、Verifier-confirmed Success / Rollout Cost、Selection Gain - Selection Cost。

24. Threshold Calibration：错误过滤的两类代价并不对称

错误	含义	什么时候更危险
False Positive	坏数据被放进训练	高 reward 权重、SFT 高 epoch、小数据集
False Negative	好数据被误删	长尾能力、罕见语言、安全边界、低资源领域

因此阈值不应全局统一。对 correctness 可以追求高 precision；对 rare skill / safety boundary 可能需要更高 recall，再由后续 human/ensemble 二次审核。

Calibration Checklist: 分 task/domain/language 做 PR curve；报告 reject-rate；随机抽查 keep 与 reject 两侧；重点看 threshold 附近样本；监控每个数据源的删除比例，防止某一来源被 scorer 系统性歧视。

25. Filter Ensemble：为什么“RM 或 LLM Judge”可能优于“RM 且 LLM Judge”

公开研究证据： Llama 3 报告 RM 与 Llama-based quality score 有较高分歧，并最终保留被 RM 或 Llama filter 标记为高质量的样本；其内部分析发现组合信号能获得更好的 recall。[10]

组合逻辑	效果	适合
AND	高 precision、低 recall	硬 correctness gate / 小而精
OR	高 recall、保留多样信号	质量候选池 + 后续 dedup/selection
Weighted Sum	可平衡多维指标	软排序；需 calibration
Lexicographic	硬约束优先	correctness > quality > style
Disagreement Routing	只把分歧样本送人工	高价值 human budget

26. 生产级 Data Filter Service Contract

```
filter_request:
  sample_id: string
  stage: [sft, dpo, rlvr, distill, agent]
  task_tags: [...]
  source: ...
  prompt: ...
  response_or_trajectory: ...

filter_result:
  hard_gate: pass|fail
  reasons: [...]
  scores:
    correctness: 0..1
    quality: 0..1
    difficulty: 0..1
    novelty: 0..1
    target_relevance: 0..1
  evidence: {...}
  cluster_id: ...
  contamination_hits: [...]
  cost_estimate: ...
  recommendation: keep|reject|audit|downweight
  filter_version: ...
```

服务组件	职责
Parser / Rule Gate	确定性格式、长度、policy、tool checks
Verifier Router	math/code/schema/env verifier
Judge Ensemble	开放式 quality / relevance
Embedding Service	dedup / cluster / coverage
Value Estimator	difficulty / uncertainty / influence / target relevance
Contamination Service	eval registry + n-gram / structure matching
Selector	预算约束下 subset / quotas / diversity
Audit Store	保存 evidence、reject reason、版本

27. Dataset Contract：把过滤规则写成可版本化配置

```
dataset_filter_spec:
  version: v3
  stage: sft
  hard_gates:
    schema_valid: true
    contamination: reject
    verifier_pass: required_for=[math, code]
  soft_scores:
    quality_min: 0.75
    difficulty_range: [0.25, 0.90]
  dedup:
    exact: true
    semantic_threshold: 0.92
    rank_key: quality*difficulty
  coverage:
    min_per_skill: 200
    max_source_share: 0.20
  audit:
    random_keep_rate: 0.005
    random_reject_rate: 0.01
    disagreement_to_human: true
```

Know-How: Filter config 必须和模型版本、Judge 版本、Eval 版本一起记录，否则下一轮无法回答“究竟是哪一个过滤变化导致模型变好/变差”。

28. 必做的 Data Filtering Ablation

实验	目的
Full vs Random vs Filtered	确认 filtering 真有增益，不只是数据减少
Same sample count	排除训练步数/epoch 差异
Same token count	排除长度偏差
Quality only vs Diversity only	测量单样本分 vs 集合覆盖贡献
Difficulty bands	找 learnable frontier
Judge A vs Judge B vs Ensemble	检查 scorer dependency
With/without decontamination	确认 benchmark 不依赖泄漏
Small-pool vs million-pool	测试 selection 方法的 scale robustness
Offline vs on-policy / dynamic	测量 stale data 问题
Keep/reject human audit	估计 FPR/FNR

最关键的实验纪律：任何“数据选择方法超过全量数据”的结论，都应同时和 balanced random、等 token、等训练 FLOPs 做比较。否则容易把 length、source mix、训练步数误认为 selection intelligence。


29. 18 常失模式

#	失败模式	症状 / 原因
1	只做质量分	集合高度重复，长尾能力下降
2	越难越好	混入不可解、错误答案
3	只做 exact dedup	paraphrase/template flood
4	semantic dedup 过猛	同主题不同技能被误删
5	LLM Judge 单点	style/length/source shortcut
6	Filter 评测泄漏	测试集参与 selection
7	阈值全局统一	低资源领域被大量删掉
8	不记录 reject reason	无法调试和回滚
9	只看 sample count	长样本吞噬 token budget
10	忽略 selection FLOPs	过滤比训练本身还贵
11	Preference pair 无质量底线	chosen 只是“没那么差”
12	DPO margin 太小	学习噪声/不必要 unlearning
13	RL group 全对/全错	zero-gradient batch
14	Teacher distill 不验证	把强模型错误固化给 student
15	Agent 只看 final success	偶然成功轨迹被当好策略
16	数据价值静态化	模型变强后仍重复 easy data
17	过滤后不重新 balance	某些能力被系统性抽空
18	没有 human audit	过滤器漂移长期不可见

30. Data Filtering 成熟度模型：L0 → L4

级别	系统形态	能力
L0 Raw Pile	只做格式清洗	能训练，但噪声与污染不可控
L1 Rule Filter	规则 + exact dedup	基本稳定、低成本
L2 Scored Dataset	Judge / RM / difficulty / embedding	可做质量与多样性优化
L3 Stage-aware Selector	SFT/DPO/RL/Agent 分阶段 + verifier + lineage	训练信号与阶段匹配
L4 Adaptive Controller	online selection + failure mining + cost-aware + audit	随 model state 动态分配训练经验

Dynamic Data Filtering Controller



Model state changes → useful data changes. Filtering should be re-evaluated as capabilities, reward margins and failures move.

31. 可直接使用的 Data Filtering Cookbook

1. 先定义 hard gates: schema、关键 correctness、contamination、provenance; 不要一开始就做总分。
2. 为每个 stage 单独定义“什么是有价值数据”: SFT 重示范质量, DPO 重 pair 信息量, RLVR 重有效 reward variance, Agent 重成功轨迹与恢复能力。
3. 把 quality、difficulty、diversity 分开测; 不要用一个 LLM 总分替代所有维度。
4. 先建立 cheap baseline: 规则 + balanced random + simple embedding; 复杂方法必须证明其增益超过额外 selection cost。
5. 对可验证任务优先 verifier; 对开放任务使用 rubric judge / ensemble; 分歧进入 audit。
6. 使用层级去重: exact -> prompt -> response -> semantic -> skill coverage。
7. 污染检测必须以独立 eval registry 驱动, final test 不参与 selection query。
8. 过滤后重新检查 distribution: domain、language、difficulty、length、source、safety slice。
9. 记录每条样本的 scores、reasons、evidence、versions, 支持重算与回滚。
10. 每轮训练后用 failure taxonomy 更新数据优先级, 最终把静态 filter 变成动态 controller。

最终心智模型: Data Filtering 的终点不是“把坏数据删掉”, 而是建立一个知道当前模型缺什么、知道哪些经验可信、知道每单位计算最值得学什么的训练经验调度器。

32. 核心 Know-Why / Know-How 总结

结论	Know-Why	Know-How
质量不是单变量	正确、难度、覆盖、成本互相独立	hard gate + multi-score + set-level selection
数据价值依赖模型	easy/hard 会随 checkpoint 变化	model-aware / online selection
可验证优先	Judge 更易偏置和被利用	rule/code/math/env verifier first
多样性是集合属性	单样本高分会导致重复	tag/embedding/coreset + quotas
偏好数据看 pair	单条 response 分数不足	quality floor + margin + label reliability
RL 过滤的是经验梯度	全对/全错 group 没有相对信号	dynamic sampling / reward variance
规模改变最优方法	复杂方法可能在 million-scale 失效	random baseline + FLOPs-controlled eval
过滤必须可审计	scorer drift 会静默改变训练分布	lineage + reject reason + human audit

33. 参考资料与推荐阅读顺序

[1] Zhou et al., LIMA: Less Is More for Alignment, arXiv:2305.11206 (2023).

[2] Chen et al., AlpaGasus: Training A Better Alpaca with Fewer Data, arXiv:2307.08701 (2023).

[3] Li et al., From Quantity to Quality: Self-Guided Data Selection / IFD, arXiv:2308.12032 (2023).

[4] Lu et al., #InsTag: Instruction Tagging for Analyzing SFT, arXiv:2308.07074 (2023).

[5] Liu et al., What Makes Good Data for Alignment? / DEITA, arXiv:2312.15685 (2023).

[6] Liu et al., SelectIT: Uncertainty-Aware Self-Reflection, arXiv:2402.16705 (2024).

[7] Xia et al., LESS: Selecting Influential Data for Targeted Instruction Tuning, arXiv:2402.04333 (2024).

[8] Li et al., Superfiltering: Weak-to-Strong Data Filtering, arXiv:2402.00530 (2024).

[9] Lambert et al., Tülu 3: Pushing Frontiers in Open Language Model Post-Training, arXiv:2411.15124 (2024).

[10] Llama Team, The Llama 3 Herd of Models, arXiv:2407.21783 (2024).

[11] Cui et al., UltraFeedback: Boosting Language Models with Scaled AI Feedback, arXiv:2310.01377 (2023).

[12] Xia et al., Rethinking Data Selection at Scale: Random Selection is Almost All You Need, arXiv:2410.09335 (2024).

[13] Ivison et al., Large-Scale Data Selection for Instruction Tuning, arXiv:2503.01807 (2025).

[14] Zhang et al., D3: Diversity, Difficulty, and Dependability-Aware Data Selection, arXiv:2503.11441 (2025).

[15] Yu et al., DAPO: An Open-Source LLM Reinforcement Learning System at Scale, arXiv:2503.14476 (2025).

[16] DeepSeek-AI, DeepSeek-R1: Incentivizing Reasoning Capability via RL, arXiv:2501.12948 (2025).

[17] Deng et al., Less is More: Improving LLM Alignment via Preference Data Selection, arXiv:2502.14560 (2025).

[18] Yang et al., Diversity-driven Data Selection through Sparse Autoencoder, arXiv:2502.14050 (2025).

[19] Yang et al., Select2Reason: Data Selection for Long-CoT Reasoning, arXiv:2505.17266 (2025).

[20] Zhao et al., AM-DeepSeek-R1-Distilled 1.4M Dataset, arXiv:2503.19633 (2025).

[21] Wang et al., GAIA: Online Data Selection for Instruction Tuning via Gaussian Processes, arXiv:2606.30077 (2026).

[22] Niu et al., TAGS: From Tags to Trees for Controllable Data Selection, arXiv:2601.13995 (2026).

[23] Li et al., Data Selection for Multi-turn Dialogue Instruction Tuning, arXiv:2604.07892 (2026).

推荐阅读顺序： LIMA/AlpaGasus → DEITA/IFD/InsTag → LESS/SelectIT → Llama 3/Tülu 3 → scale-aware selection → DAPO → 2025-2026 dynamic / structured selection。先理解“什么是好数据”，再理解“数据价值如何依赖模型与训练阶段”。