

LLM 后训练之 Preference Optimization

从 Preference Pair 到稳定 Policy：偏好数据、目标函数、在线更新与生产级工程

Post-Training Research Handbook · 2026-08

Know-Why × Know-How × Engineering Contract

执行摘要：Preference Optimization 到底在优化什么？

SFT 回答“理想行为长什么样”，Preference Optimization 回答“在多个可行行为之间，模型应该更倾向哪一个”。它不是简单地把 chosen 概率拉高、rejected 概率压低，而是在有限、带噪、可能偏置的比较信号下，重塑模型的相对行为几何。

核心定义

Preference Optimization = Preference Signal × Pair Construction × Implicit/Explicit Reward × Policy Regularization × Data Distribution × Evaluation。真正的工程问题是：偏好信号是否可信、pair 是否有信息量、目标函数是否与部署分布匹配、以及训练是否只学会了“赢 Judge”。

层	核心问题	典型产物
Preference Source	谁定义 better / worse?	Human / AI Judge / Rule / Verifier
Pair Factory	哪些响应应该被配成一对?	(x, y+, y-, margin, rationale)
Objective	如何把比较信号写进参数?	DPO / IPO / KTO / ORPO / SimPO / SPPO
Regularization	如何避免漂移与过优化?	Reference/KL、margin、BC/NLL、calibration
Distribution	offline pair 是否覆盖当前 policy?	offline / near-policy / online
Eval	是否真的更符合用户目标?	pair accuracy、win rate、capability regression、hack gap

历史上，InstructGPT 和 Anthropic HH-RLHF 将人类排序用于训练 Reward Model，再通过 PPO 优化 policy；DPO 证明在一类 KL-regularized RLHF 假设下，可以直接从偏好对训练 policy，显著简化工程链路。[1][2][4]

1. 从 SFT 到 Preference Optimization：为什么需要第二阶段？

1.1 SFT 的监督信号是“绝对示范”，Preference 的监督信号是“相对差异”

训练方式	监督信号	最自然的问题	主要盲点
SFT	Prompt -> Ideal Response	“我应该怎样回答？”	只有一个 target；不能表达多个可接受答案的相对质量
Preference	Prompt + chosen/rejected	“A 与 B 谁更好？”	依赖 pair 质量与偏好模型假设
RL / RLVR	Rollout -> Reward	“怎样探索出更高回报策略？”	在线 rollout 与 reward engineering 成本高

Preference 的优势来自 “delta signal”：即使 chosen 和 rejected 单独看都不完美，只要二者存在稳定、可解释的质量差，pair 就可能提供有价值的梯度。2025 年的 Delta Learning 工作进一步展示，较弱模型之间构造的偏好差异也可能驱动更强 student 获益。[18]

1.2 一个更准确的概率视角

```
SFT:      maximize log pi_theta(y_good | x)
Preference: increase [score_theta(x,y+) - score_theta(x,y-)]
RL:      maximize E_{y~pi_theta}[R(x,y)] subject to regularization
```

因此 Preference Optimization 的对象不是单条 response，而是 response space 内的相对排序结构。工程上必须关注 margin、coverage 和 ranking consistency，而不能只盯着 chosen loss。

2. Preference Signal：人类偏好、AI 偏好与可验证偏好

信号源	优势	风险	适用
Human ranking	接近真实用户体验；可覆盖开放问题	昂贵、一致性有限、标注者偏差	产品风格、帮助性、开放式质量
AI Judge / RLAIF	规模大、成本低、可结构化 rubric	judge bias、self-enhancement、verbosity bias	大规模 pair 生成、规则型行为
Rule-based	确定、廉价、可审计	覆盖窄，容易 Goodhart	格式、约束、安全规则
Verifier-derived	客观且抗主观漂移	仅适用于可验证任务	代码、数学、结构化任务
Implicit user behavior	贴近真实部署	反馈有混杂因素	产品闭环，需严格因果/隐私治理

Constitutional AI 展示了用原则驱动 AI preference、再训练 preference model 与 RL policy 的 RLAIF 路线，说明 preference source 可以从纯人工扩展为“规范 + 模型监督”。[3] UltraFeedback 则将 AI feedback 扩展到大规模、多维度反馈数据。[10]

3. Preference Data Contract：pair 不是三列 CSV

最小数据结构只有 prompt/chosen/rejected，但生产级 pair 必须保留来源、生成 policy、judge、置信度、质量 margin、长度、任务类型与 provenance，否则后续无法判断训练为什么有效或为什么退化。

```
{
  "prompt_id": "...",
  "prompt": "...",
  "chosen": "...",
  "rejected": "...",
  "chosen_model": "policy_v17",
  "rejected_model": "policy_v17",
  "judge": "judge_v5",
  "preference": "chosen",
  "confidence": 0.84,
  "margin": 0.31,
  "criteria": {"correctness": 1, "helpfulness": 1, "style": 0},
  "source": "online_rollout",
  "policy_age": 0,
  "lengths": {"chosen": 522, "rejected": 498},
  "lineage": {...}
}
```

3.1 Pair 的五个信息量维度

维度	低价值 pair	高价值 pair
Preference certainty	Judge 近似随机	多 judge/规则一致
Quality delta	A 与 B 几乎相同	存在可学习但不过大的差异
Policy relevance	远离当前 model distribution	当前或 near-policy responses
Capability relevance	已饱和 easy task	当前 capability gap
Artifact control	差异主要来自长度/格式	差异来自目标能力本身

Know-How

Preference Pair 的价值不是 chosen 有多好，而是“chosen 与 rejected 的差异是否指向你想训练的轴，并且这个差异对当前 policy 仍可学习”。

4. Preference Pair Factory：chosen/rejected 应该怎样构造？

策略	构造方式	优点	风险
Human-vs-model	专家答案 vs model	强正样本	delta 过大，容易退化成 SFT-ish
Strong-vs-weak model	强 teacher vs 弱 teacher	规模化	teacher style 泄漏
Same-policy Best-vs-Worst	同一 policy N 个样本排序	on/near-policy	需要 judge；可能长度偏置
Adjacent pair	排序相邻候选配对	delta 更精细	标签噪声敏感
Hard-negative	chosen 与高质量错误 response	信息量大	构造与验证成本高
Failure-driven	线上失败 vs 修正答案	产品相关	分布容易偏向近期热点

RRHF 早期就强调 sampled response quality 会明显影响训练，实质上已经指出 Preference Optimization 与 Response Generation 是耦合系统。[9]

5. 经典 RLHF：Preference -> Reward Model -> PPO

InstructGPT 的经典流水线是：SFT -> 收集 rankings -> Reward Model -> PPO。Anthropic HH-RLHF 进一步实践了迭代式在线偏好收集：随着 policy 更新，不断收集新的 preference data 与更新 preference model。[1][2]

```
Prompt x
-> sample y1..yk
-> human ranking
-> train R_phi(x,y)
-> PPO maximizes R_phi - beta * KL(pi || pi_ref)
```

5.1 为什么它复杂？

- Reward Model 与 policy 分开训练，存在 reward model generalization gap。
- PPO 通常需要 policy / reference / reward / value 等多个模型状态。
- 在线 sampling、reward inference 与 policy training 的系统复杂度高。
- Policy 越偏离 RM 数据分布，越可能 reward hacking。

关键转折

DPO 的意义不是“RLHF 错了”，而是证明在特定偏好模型与 KL-regularized objective 下，可以把 reward-learning + policy-optimization 的一部分数学结构折叠成一个 supervised-style pairwise loss。[4]

6. DPO：最重要的直接偏好优化基线

6.1 核心变量

```
r_theta(x,y) = beta * [log pi_theta(y|x) - log pi_ref(y|x)]
Delta = r_theta(x,y+) - r_theta(x,y-)
L_DPO = - log sigmoid(Delta)
```

直觉上，DPO 比较 policy 相对 reference 对 chosen/rejected 的偏移。如果当前模型相对 reference 更偏向 chosen，则 loss 下降。beta 控制隐式 reward 的尺度与 policy 偏离 reference 的强度。[4]

6.2 DPO 的真正工程优势

优势	为什么重要
无需单独 RM	减少一条训练与部署链
无需训练时在线 rollout	可在固定 preference dataset 上离线训练
实现接近 supervised training	稳定、容易扩到大模型
pair-level objective	直接使用 ranking 信息

6.3 DPO 的假设与边界

- 依赖偏好概率模型假设；经典推导常落在 Bradley-Terry 结构。
- 离线 DPO 的效果高度依赖数据 coverage：当前 policy 走到训练 pair 未覆盖区域时，没有新的反馈。
- pair label 被视作高置信偏好时，噪声会被放大。
- 相对优化不保证 chosen 的绝对 likelihood 一定上升，可能出现 likelihood displacement。

7. DPO 的训练动力学：为什么“margin 变大”仍可能有问题？

Preference loss 只要求 chosen 相对 rejected 更优。因此存在多种实现 margin 的方式：chosen 上升、rejected 下降，或两者都下降但 rejected 下降更多。Reward Model Distillation 工作分析了 DPO 在单标签偏好下可能产生过度自信甚至退化的现象。[13]

监控指标	含义	异常信号
rewards/chosen	chosen 隐式 reward	持续下降但 margin 变大
rewards/rejected	rejected 隐式 reward	下降过快
reward margin	pair separation	高但 generation 质量不升
pair accuracy	训练集排序正确率	很快 100% 可能意味着过拟合
chosen logp	绝对 chosen likelihood	明显下降
response length	生成长度	持续膨胀可能是 length hacking

工程原则

DPO 不能只看 loss / reward margin。至少同时看 chosen log-prob、rejected log-prob、length distribution、held-out pair accuracy、独立 judge win rate 与 capability regression。

8. IPO：从“拟合确定偏好”转向更稳健的有限间隔

IPO 来自更一般的 PsiPO 理论框架。该工作指出 DPO 仍依赖把 pairwise preference 映射到 pointwise reward 的近似，并给出 Identity Preference Optimization 作为特殊情形，强调在有限偏好数据下避免某些过拟合行为。[5]

Conceptually: DPO pushes preference logit toward +infinity on separable data;
IPO instead targets a finite log-likelihood-ratio gap controlled by beta.

DPO	IPO
logistic preference fit	finite target gap
容易把可分 pair 推向极端 margin	对 preference overfitting 更克制
经典强基线	适合怀疑标签噪声/过分离时做对照

9. KTO：没有 pair 也可以做 Preference Optimization

KTO 的重要工程价值是把数据需求从 pairwise preference 降到 “desirable / undesirable” 二元标签。论文基于 prospect-theoretic utility 构造 HALO 目标，并报告在 1B-30B 规模上可以匹配或超过若干 pair-based 方法。[6]

DPO 数据	KTO 数据
prompt + chosen + rejected	prompt + completion + desirable?
必须形成 pair	可以来自点赞/点踩、审核、单条反馈
pair 内相对质量	pointwise desirability + utility shaping

Know-When

如果真实产品只能稳定收集 thumbs-up / thumbs-down，而很难让用户对两个长回答做成对比较，KTO 类型的 unpaired preference objective 具有明显的数据采集优势。

当前 TRL 的 KTOTrainer 也直接支持 unpaired preference format，并提供正负样本不平衡权重与 beta 等配置。[20]

10. ORPO：把 SFT 与 Preference 合一段

ORPO 将 chosen 的 NLL 学习与 favored/disfavored 的 odds-ratio preference penalty 合在同一目标中，不需要单独 reference model，也试图消除 “先 SFT 再 preference tuning” 的两阶段复杂度。[7]

$$L_{ORPO} = L_{NLL}(chosen) + \lambda * L_{odds_ratio}(chosen, rejected)$$

适合	不适合
想用一套 preference dataset 完成 instruction + preference adaptation	已有成熟 SFT checkpoint 且需要严格控制 policy drift
算力/内存不希望维护 reference model	需要 reference-relative reward 解释与兼容既有 DPO 流程
chosen response 本身质量很高	chosen 只是 “相对更好” 但绝对质量一般

11. SimPO：Reference-Free + Length Normalization + Target Margin

SimPO 用平均每 token log-probability 作为隐式 reward，去掉 reference model，并加入 target reward margin，使训练目标更贴近序列生成时的长度归一化比较。论文在多个 chat benchmark 上报告相对 DPO 的改进，并强调没有显著依赖更长回答。[8]

```
r_theta(x,y) = beta / |y| * log pi_theta(y|x)
L = -log sigmoid(r(y+) - r(y-) - gamma)
```

设计	解决的问题
Reference-free	降低 reference forward / cache 成本
Average log-prob	减少序列长度对 reward 尺度的直接影响
Target margin gamma	要求 chosen 至少领先 rejected 一个目标间隔

独立工作 SamPO 也从 DPO 的 sequence-level KL 角度分析了 length reliance，说明“长度偏好”不一定完全来自数据标注，objective 本身也可能放大长度相关偏差。[15]

12. SLiC-HF / RRHF：DPO 之前的直接 ranking 学习路线

SLiC-HF 使用 sequence likelihood calibration 学习 human preference，并展示可以使用为其他模型收集的离线偏好数据；RRHF 则通过 ranking loss 直接让模型 likelihood 排序贴合 feedback ranking。[9][11]

方法	核心思想	今天的价值
SLiC-HF	calibrate sequence likelihood with preference margin	理解 hinge/margin preference loss 的来源
RRHF	按 response ranking 调整 conditional likelihood	理解 best-of-N learner 与采样质量耦合
DPO	reference-relative implicit reward + logistic objective	当前最常用强基线

13. Offline vs Online Preference Optimization

Preference Optimization 的一个更根本轴不是“DPO 还是 IPO”，而是训练 pair 来自哪里。Offline 方法在固定数据集上优化，Online 方法持续从当前/混合 policy 采样并重新获得偏好信号。Anthropic HH-RLHF 很早就使用迭代式在线反馈；后续 online IPO / Nash-MD / SPPO 等把这一差异显式理论化。[2][12][14]

维度	Offline	Online / Iterative
数据	固定 pair	当前 policy 持续生成
覆盖	受历史 policy 限制	可追随 policy 漂移
成本	低	需要 generation + judge
稳定性	高	更复杂，存在 feedback loop
探索	弱	强
主要风险	distribution mismatch	judge exploitation / self-reinforcement

核心判断

Offline preference optimization 更像“用一张历史地图校准路线”；Online preference optimization 更像“边走边重新测绘”。当 policy 已明显离开 pair 数据分布时，继续堆 offline epochs 往往不如重新生成 near-policy comparisons。

14. SPPO / Self-Play：Preference 从静态标签变成博弈

SPPO 将一般偏好关系建模为常和两人博弈，并通过 self-play 迭代逼近 Nash equilibrium policy，试图绕开“偏好必须来自某个标量 reward”的强假设。[14]

```
policy_t -> sample candidates -> preference oracle -> win/lose pairs
          -> update policy -> repeat
```

2026 年 S-SPPO 进一步指出：如果 preference oracle 对语义几乎相同的回答给出过度自信的胜负，self-play 可能发生 policy degeneration，因此引入语义校准与表示空间多样性约束。[19]

15. Preference Model 假设：Bradley-Terry 并不是世界本身

大量方法的差异可以理解为：你如何假设人类产生偏好的机制。Bradley-Terry 把 $P(y+ > y-)$ 写成两个标量 utility 差的 logistic 函数，但真实偏好可能存在上下文依赖、非传递、群体差异与不可比较性。IPO/PsiPO、general preference oracle、SPPO 等工作都在挑战“所有偏好都来自一个全局标量 reward”的简化。[5][12][14]

15.1 实际工程中的四类偏好

类型	例子	建议
强可传递	代码通过测试 > 不通过	Verifier 优先，少用纯 Judge
弱可传递	更清晰、更简洁	pairwise + rubric + 多 judge
多目标冲突	详细 vs 简洁；帮助性 vs 风险	保留 criterion-level labels，不只存总分
个体异质	写作风格偏好	persona/user-conditioned preference，不要强行一个全局 reward

16. Label Noise：偏好数据并不是 ground truth

偏好标注常包含歧义、随机 flip 与 criterion 冲突。Robust DPO 工作对随机 preference flip 给出理论分析，说明 vanilla DPO 对 noisy feedback 的依赖需要显式治理。[16]

噪声来源	表现	治理
Judge disagreement	同一 pair 胜负反转	multi-judge / human arbitration
Tiny margin	两答案几乎等价	drop / soft label / lower weight
Criterion conflict	A 更正确，B 更简洁	vector labels + task-specific weights
Annotation drift	不同时间 rubric 变化	versioned judge spec
Position/length bias	更长或先出现更容易赢	swap test / length control

17. Pair Margin：不是所有 chosen/rejected 都应等权

Pair 数据最值得保存的额外变量之一是 confidence / margin。大 margin pair 标签更稳定，但可能过于容易；小 margin pair 更精细，却更容易噪声化。生产配方通常需要“可学习 frontier”，而不是极端 easy 或极端 ambiguous。

```
pair_value ~= reliability * target_relevance * learnability * policy_coverage
              / annotation_cost
```

17.1 三段式采样

区间	解释	策略
Easy / huge margin	模型容易学、标签稳	低比例保留，稳定 anchor
Frontier / medium margin	最可能提供有效排序梯度	主训练区域
Ambiguous / tiny margin	可能是真正细粒度偏好，也可能是噪声	soft label / rerank / human review

18. Length Bias 与 Style Hacking

开放式对话中，Judge 常把“更长、更完整”误当成“更好”，Preference Optimization 会把这种偏差内化并放大。SamPO 从 objective 角度显示 DPO 也可能存在 length reliance；因此需要同时治理数据与 loss 两端。[15]

- Pair construction：匹配 chosen/rejected 长度区间，避免长度成为主判别特征。
- Judge：加入 length-controlled rubric，并进行 response-order swap。
- Training：监控 token length、verbosity、chosen/rejected length gap。
- Eval：使用 length-controlled win rate 与任务完成率，不只用 raw win rate。

19. Likelihood Displacement / Probability Collapse

“chosen 胜过 rejected” 并不等于 “chosen 变得更可能生成”。当目标只约束相对差异时，模型可能通过强烈压低 rejected 来获得更大 margin。Reward Model Distillation 与后续 calibrated/gradient-control 研究都围绕这个问题展开。[13][17]

19.1 防护思路

防护	作用
Chosen NLL / BC regularizer	给 chosen 绝对正向锚点
Finite target gap (IPO)	避免无限拉大 pair margin
Reward calibration	限制 implicit reward 绝对尺度漂移
Label smoothing / robust loss	避免把单次 preference 当确定真理
Early stopping	pair accuracy 饱和后减少过优化
Independent generation eval	检测 loss 改善但生成退化

20. Reference Model：到底是约束、坐标系还是成本？

DPO 的 reference model 同时扮演三个角色：提供相对 reward 的坐标系、限制 policy 偏离、以及引入额外 forward/log-prob 存储成本。reference-free 方法（ORPO/SimPO）减少了成本，但也改变了优化几何。

设计	优点	代价
Frozen reference	稳定、可解释	显存/计算或预计算成本
Precomputed ref logp	训练高效	数据与 tokenizer/template 必须严格一致
Synced / moving reference	减轻 stale reference	系统更复杂
Reference-free	简单、便宜	需要其他方式控制 drift / reward scale

21. Beta、Margin、Learning Rate：Preference Optimization 的三大旋钮

超参	直觉	过大	过小
beta	reference-relative reward / regularization 尺度	更新保守或 reward scale 受限 (依方法定义)	policy 可能过度偏离
margin/gamma	chosen 应领先多少	过度分离、损伤多样性	学习信号弱
learning rate	每步策略移动幅度	collapse/forgetting	训练无效

注意：不同实现对 beta 的定义可能不同，不能跨算法机械复用数值。生产配置应保存 “objective + equation convention + library version”，而不是只保存 beta=0.1。

22. Preference Objective 选择矩阵

场景	优先基线	为什么	需要额外关注
成熟 SFT + paired data	DPO	简单、稳定、生态成熟	beta、chosen logp、length
pair 标签噪声高	IPO / robust DPO	减少无限 margin / 噪声敏感	soft label、relabel
只有 thumbs up/down	KTO	支持 unpaired desirability	class balance、KL estimate
想合并 SFT 与 preference	ORPO	chosen NLL + preference 一阶段	chosen 绝对质量
reference 成本高且长度偏差明显	SimPO	reference-free + normalized reward	gamma、长度控制
offline coverage 已陈旧	Online DPO/IPO	刷新 near-policy pair	judge stability、成本
偏好非传递/博弈性强	SPPO/Nash-style	不强制全局标量 reward	oracle calibration

23. Preference Optimization 与 SFT 的接口

SFT checkpoint 决定 Preference Optimization 的起点、response distribution 和 pair coverage。一个过窄的 SFT 会限制后续 preference search；一个格式不稳的 SFT 会让 preference 阶段把梯度浪费在基本合法性上。

23.1 DPO-ready SFT Checklist

- Chat template / special tokens 与 preference dataset 完全一致。
- chosen/rejected 都从同一 prompt serialization 计算。
- SFT 已学会基本格式、工具 schema、拒答/路由等硬行为。
- 保留一定 response entropy，不要在 SFT 阶段把行为训成单一模板。
- Preference 数据尽量来自当前或 near-current SFT policy 的候选分布。

24. Preference Optimization 与 RL / GRPO 的接口

Preference Optimization 更适合“已有候选之间的相对价值”；RL/GRPO 更适合“需要通过 rollout 探索新的策略”。因此成熟 pipeline 常见的是：SFT 建行为先验，Preference 优化用户偏好与开放质量，RLVR 再对可验证能力做在线搜索。Tulu 3 就采用 SFT -> DPO -> RLVR 的多阶段开放配方。[21]

```
SFT:          learn valid behavior
DPO/Preference: shape relative behavior / style / helpfulness
RLVR/GRPO:    explore strategies under verifiable reward
```

边界原则

如果你能稳定写出 verifier，并且真正目标是发现更强推理策略，不要试图用无限多 preference pairs 代替 RL search。反之，如果目标是开放式“更自然、更有帮助、更符合产品风格”，pairwise preference 往往比稀疏 scalar reward 更直接。

25. Preference Evaluation：训练 loss 不等于对齐成功

指标层	指标	回答的问题
Pair-level	held-out pair accuracy / margin	是否学会历史偏好？
Generation-level	independent judge win rate	新生成是否更好？
Length-controlled	LC win rate / token length	是否靠更长作弊？
Capability	MATH/code/IFEval/agent success	是否损伤核心能力？
Calibration	confidence vs agreement	偏好模型/隐式 reward 是否可信？
Distribution	OOD prompt slices	是否只在训练分布有效？
Product	task completion / user satisfaction	是否提高真实目标？

25.1 必做 Ablation

- Same data: DPO vs SFT-on-chosen。证明收益真的来自 preference signal。
- Same objective: random pair vs margin-filtered pair。验证 pair factory。
- Reference vs reference-free。分析 memory/cost 与质量。
- Offline vs refreshed near-policy data。验证 coverage mismatch。
- Raw win rate vs length-controlled win rate。检测 verbosity hacking。

26. Online Preference Flywheel

```
Current Policy
-> Prompt sampler
-> N candidates
-> Judge/Verifier/Ensemble
-> informative pair selection
-> preference optimization
-> independent eval
-> failure / disagreement mining
-> next iteration
```

Flywheel 的核心不是“重复 DPO”，而是每一轮都更新 data distribution。Anthropic HH-RLHF 的 weekly online feedback 是早期代表；后续 online IPO 与 SPPO 将其扩展为理论化的 on-policy / self-play preference learning。[2][12][14]

27. Preference Optimization 的生产级数据服务

服务	职责
Candidate Store	保存 generation、policy version、sampling config
Judge Service	rubric、pairwise/pointwise、confidence、version
Pair Builder	margin、hard negative、length matching、dedup
Preference Registry	pair lineage、license、privacy、filter history
Logprob Service	policy/ref logp 预计算与模板校验
Trainer	objective、beta/gamma、mask、distributed training
Eval Service	independent judge + capability suites
Drift Monitor	pair age、policy distance、judge drift

27.1 Preference Dataset Version 必须保存什么？

```
pref-v23 = {
  prompt_snapshot, candidate_policy_versions,
  judge_spec_version, pair_builder_version,
  length_filter, confidence_threshold,
  decontamination_version, tokenizer_hash,
  chat_template_hash, created_at
}
```

28. Production Training Contract（可直接复用）

```
stage: preference_optimization
base_checkpoint: sft-v17
objective:
  name: dpo
  beta: 0.1
  reference: sft-v17
  label_smoothing: 0.0

data:
  dataset: pref-v23
  pair_policy_age_max: 2
  min_confidence: 0.70
  length_gap_ratio_max: 1.5
  dedup: semantic-v4
serialization:
  chat_template_hash: abc...
training:
  lr: 5e-7
  epochs: 1
  max_length: 4096
monitor:
  - dpo_loss
  - reward_margin
  - chosen_logp
  - rejected_logp
  - response_length
  - heldout_pair_accuracy
stop_if:
  capability_regression_pct: 2.0
  length_increase_pct: 15.0
  chosen_logp_drop: threshold
eval:
  independent_judge: judge-v8
  slices: [chat, coding, reasoning, tool_use, safety]
```


29. 18 类常见失败模式与诊断

Failure	症状	修复
1. Pair 太容易	pair accuracy 快速 100%，generation 无提升	提高 frontier / hard-negative 比例
2. Pair 太模糊	loss 抖动、judge disagreement 高	soft label / drop / human review
3. Stale preference data	离线提升、线上无提升	near-policy refresh
4. Length hacking	win rate 升但长度暴涨	length control + SimPO/SamPO-style analysis
5. Chosen likelihood 下降	margin 升但 preferred generation 变少	BC/NLL anchor、IPO/calibration
6. Judge overfit	训练 judge 赢，human/independent judge 不赢	独立 evaluator 与 judge ensemble
7. Style collapse	回答模板化	diversity eval + lower margin/epochs
8. Capability regression	chat 更讨喜但 math/code 变差	multi-objective eval + mixture repair
9. Reference mismatch	logp 异常	锁定 tokenizer/template/checkpoint hash
10. Bad negative	rejected 有事实优势	pair revalidation
11. Position bias	交换顺序后标签翻转	swap consistency filter
12. Criterion mixing	同一 pair 正确性/风格冲突	criterion-level labels
13. Label noise	不同标注者不一致	robust loss / smoothing / consensus
14. Overtraining	train pair 越来越好，gen eval 下降	early stop on generation eval
15. Offline coverage gap	新 policy 输出类型从未出现在 pair 中	online/iterative preference
16. Reward proxy drift	margin 与真实产品指标脱钩	objective-to-eval traceability
17. Synthetic monoculture	所有 chosen 都像同一 teacher	multi-source candidate generation
18. Cost blindness	复杂 pair factory 训练收益抵不过生成/标注成本	gain per GPU\$/label\$ 评估

30. Preference Optimization 成熟度模型

级别	系统形态	典型特征
L0 - Pair CSV	人工拼 chosen/rejected	无 lineage；只看 train loss
L1 - DPO Recipe	稳定 DPO pipeline	有 reference、pair eval、基本版本管理
L2 - Preference Factory	多源 candidate + judge + pair selection	margin/length/noise 治理
L3 - Adaptive Preference	near-policy refresh + disagreement mining	offline/online 混合、动态 pair distribution
L4 - Preference Control Plane	目标、数据、judge、policy、eval 全闭环	按 capability gap / product impact 自动分配 偏好采样预算

成熟系统的目标

不是“把 DPO 跑稳”，而是建立一个能够持续回答：当前模型在哪些行为边界上仍有不确定性？下一批最有价值的 comparisons 是什么？哪些偏好只是 Judge 的偏差？

31. 方法选择的 Know-Why / Know-How 总表

方法	Know-Why	Know-How	主要风险
DPO	把 RM+RL 的一部分结构折叠成 pairwise supervised objective	锁定 reference/template；监控 chosen/rejected logp	offline coverage、likelihood displacement
IPO	避免对确定 pair 无限分离	有限 target gap；作为 noisy-data 对照	可能欠拟合强偏好
KTO	真实系统更容易得到 thumbs up/down	unpaired data balance；稳定 KL estimate	pointwise desirability 偏置
ORPO	合并 SFT 与 preference	chosen 必须绝对高质量	相对更好不等于值得 SFT
SimPO	降低 reference 成本并处理长度尺度	length normalization + gamma	margin 与 LR 需联调
Online DPO/IPO	解决 stale offline coverage	周期性从 current policy 采样	judge feedback loop
SPPO	偏好可能非传递，采用 game view	self-play + oracle calibration	semantic collapse / instability

32. 研究结论：Preference Optimization 的十条第一性原则

- 1. Preference 的训练单位是“差异”，不是单条高质量答案。
- 2. Pair quality = 标签可靠性 × delta 信息量 × 当前 policy coverage。
- 3. 离线算法的核心瓶颈常常不是 loss，而是 stale data distribution。
- 4. DPO margin 变大不等于 chosen 绝对概率变大。
- 5. Preference objective 必须与长度、格式、风格 proxy 解耦，否则会产生 shortcut。
- 6. 真实偏好不一定来自单一全局标量 reward；要允许 criterion conflict 与个体差异。
- 7. Reference model 是一种正则坐标系，不只是额外显存负担。
- 8. SFT 与 Preference 的最佳边界是：SFT 教合法行为，Preference 教合法行为之间的相对选择。
- 9. 当任务有可靠 verifier 且需要策略发现时，Preference 不应取代 RL/RLVR。
- 10. 生产级 Preference Optimization 的终点是“动态比较预算控制器”，而不是某个固定 loss。

最终公式

Effective Preference Signal $\sim$ Reliability $\times$ Relative Quality Delta $\times$ Policy Relevance $\times$ Target Relevance / (Generation Cost + Annotation Cost + Optimization Risk)

33. 推荐阅读路线

阶段	论文	为什么读
基础	InstructGPT [1]	理解 ranking -> RM -> PPO 的经典链路
基础	Anthropic HH-RLHF [2]	理解 online preference feedback 与 helpful/harmless trade-off
转折	DPO [4]	直接偏好优化的核心数学
理论	PsiPO / IPO [5]	理解 DPO 假设与 preference overfitting
数据形态	KTO [6]	从 pair 扩展到 desirable/undesirable
单阶段	ORPO [7]	SFT 与 preference 合并
reference-free	SimPO [8]	平均 logp reward、target margin
数据	UltraFeedback [10]	规模化 AI preference 数据
在线	Online IPO / Nash-MD [12]	理解 online vs offline 的根本差异
博弈	SPPO [14]	非标量 reward 的 preference game
鲁棒	Robust DPO / RM Distillation [13][16]	理解 label noise 与 likelihood pathology
生产	Tulu 3 [21]	开放的 SFT -> DPO -> RLVR 全链路

参考文献与主要研究来源

- [1] Ouyang et al., 2022. Training language models to follow instructions with human feedback. <https://arxiv.org/abs/2203.02155>
- [2] Bai et al., 2022. Training a Helpful and Harmless Assistant with RLHF. <https://arxiv.org/abs/2204.05862>
- [3] Bai et al., 2022. Constitutional AI: Harmlessness from AI Feedback. <https://arxiv.org/abs/2212.08073>
- [4] Rafailov et al., 2023. Direct Preference Optimization. <https://arxiv.org/abs/2305.18290>
- [5] Azar et al., 2023. A General Theoretical Paradigm to Understand Learning from Human Preferences (PsiPO/IPO). <https://arxiv.org/abs/2310.12036>
- [6] Ethayarajh et al., 2024. KTO: Model Alignment as Prospect Theoretic Optimization. <https://arxiv.org/abs/2402.01306>
- [7] Hong et al., 2024. ORPO: Monolithic Preference Optimization without Reference Model. <https://arxiv.org/abs/2403.07691>
- [8] Meng et al., 2024. SimPO: Simple Preference Optimization with a Reference-Free Reward. <https://arxiv.org/abs/2405.14734>
- [9] Yuan et al., 2023. RRHF: Rank Responses to Align Language Models with Human Feedback without tears. <https://arxiv.org/abs/2304.05302>
- [10] Cui et al., 2023. UltraFeedback: Boosting Language Models with Scaled AI Feedback. <https://arxiv.org/abs/2310.01377>
- [11] Zhao et al., 2023. SLiC-HF: Sequence Likelihood Calibration with Human Feedback. <https://arxiv.org/abs/2305.10425>
- [12] Calandriello et al., 2024. Human Alignment of Large Language Models through Online Preference Optimisation. <https://arxiv.org/abs/2403.08635>
- [13] Fisch et al., 2024. Robust Preference Optimization through Reward Model Distillation. <https://arxiv.org/abs/2405.19316>
- [14] Wu et al., 2024. Self-Play Preference Optimization for Language Model Alignment. <https://arxiv.org/abs/2405.00675>
- [15] Lu et al., 2024. Eliminating Biased Length Reliance of DPO via Down-Sampled KL Divergence (SamPO). <https://arxiv.org/abs/2406.10957>
- [16] Chowdhury et al., 2024. Provably Robust DPO: Aligning Language Models with Noisy Feedback. <https://arxiv.org/abs/2403.00409>
- [17] Xiao et al., 2024. Cal-DPO: Calibrated Direct Preference Optimization. <https://arxiv.org/abs/2412.14516>
- [18] Geng et al., 2025. The Delta Learning Hypothesis: Preference Tuning on Weak Data can Yield Strong Gains. <https://arxiv.org/abs/2507.06187>
- [19] Chen et al., 2026. S-SPPO: Semantic-Calibrated Self-Play Preference Optimization. <https://arxiv.org/abs/2606.01561>
- [20] Hugging Face TRL Documentation: DPO/KTO/ORPO and preference trainers. <https://huggingface.co/docs/trl/>
- [21] Lambert et al., 2024. Tulu 3: Pushing Frontiers in Open Language Model Post-Training. <https://arxiv.org/abs/2411.15124>

使用说明

本手册把论文中的研究结论与工程推论分开处理：带编号引用的具体论文主张来自对应公开论文/官方文档；“Know-How” “工程原则” “生产 Contract” 等为基于这些证据综合出的工程抽象，需在具体模型、数据 and 产品分布上通过消融实验重新验证。