

LayerNorm / RMSNorm

Transformer Normalization 深度分析 2026

数学 · 梯度 · Residual Stream · Pre/Post/Peri-LN · QK-Norm · 系统工程

2016201920202021-22202420252026

Transformer Normalization 发展脉络（精选）



本报告面向：从零实现 Transformer、LLM 预训练稳定性、架构设计、训练 Infra / Kernel 优化与算法面试。

研究基线：Layer Normalization、RMSNorm、Pre/Post-LN 理论、NormFormer、DeepNorm、Gemma 2、OLMo 2、Peri-LN、nGPT、DyT，以及 2025-2026 normalization-removal 新研究。

版本：2026-08-14。近期预印本会明确标注“新兴研究”，不与已经大规模验证的工程惯例混为一谈。

0. Executive Summary : Normalization 到底在 Transformer 里做什么？

最常见的解释是“把激活归一化，让训练更稳定”。这个说法方向正确，但对大模型工程而言过于粗糙。Normalization 实际同时影响四个对象：激活的径向尺度、残差流随深度的增长、参数梯度的条件数/尺度，以及 attention logits / output logits 的动态范围。

关键结论：Normalization 更像“尺度控制器 + 优化几何重参数化器”，而不只是一个防 NaN 的保险丝。

层面	Normalization 实际控制什么	工程后果
表示几何	把输入向量的绝对尺度压到可控范围；LayerNorm 还去除均值方向	减少不同 token / layer 的尺度漂移
残差流	决定 branch update 相对于 residual stream 的有效大小	影响“有效深度”、后层是否还能写入新信息
梯度	改变 Jacobian 与梯度在深度方向的传播	决定 warmup、初始化、学习率敏感性
Attention	QK-Norm 可直接控制 $q \cdot k$ 的尺度	抑制 attention logit 爆炸与 softmax 过饱和
系统	Norm 是 reduction-heavy、memory-bound 运算	影响融合 kernel、mixed precision、TP/SP 通信布局
推理	最终 Norm 影响 LM head 输入尺度	影响 logit scale、量化误差与模型校准

本报告最重要的三个区分：

- LayerNorm vs RMSNorm：前者“减均值 + 除标准差”，后者只做 RMS 重缩放；二者不变性不同。
- Norm 类型 vs Norm 位置：RMSNorm 并不等价于 Pre-LN；“用什么 Norm”和“放在哪里”是两套独立设计变量。
- 训练稳定 vs 最终表达能力：一种 topology 更容易训练，并不自动意味着相同训练预算下的最终最优。

LayerNorm 与 RMSNorm：操作差异与不变性




图 1 · LayerNorm 与 RMSNorm 的最小数学差异

1. Normalization 族：先把念分干

方法	核心统计量 / 操作	Transformer 中常见位置	主要目标
LayerNorm	$\mu(x)$, $\text{Var}(x)$, 随后 affine γ, β	block 输入/输出、final norm	re-centering + re-scaling

方法	核心统计量 / 操作	Transformer 中常见位置	主要目标
RMSNorm	$\text{RMS}(x)$ ，通常只有 γ	现代 LLM block / final norm	re-scaling，计算更简单
ScaleNorm	L2 norm + 单个 scale	早期 PreNorm 研究	简化 LayerNorm
QK-Norm	对 Q/K 每个 head 归一化	attention dot product 之前	控制 attention logit 尺度
DeepNorm	Post-LN + residual scale + 配套初始化	超深 Transformer	限制 model update
NormFormer	Pre-LN 上增加额外 Norm / head scale	Attention/FFN 内部	平衡层间梯度
Peri-LN	子层前后都规范化，再做 residual add	Gemma2-like / 新研究	兼顾 gradient 与 variance
nGPT	权重、表示约束在 hypersphere	全模型	把尺度自由度系统性移除
DyT / Derf	点式有界非线性替代统计归一化	norm-free 实验	减少 sample-dependent reductions




图 2 · Norm 的“位置”与“类型”是独立设计变量

2. LayerNorm：公式、统计量与不变性

2.1 标准定义

对一个 token 的 hidden vector $x \in \mathbb{R}^d$, LayerNorm 在 hidden dimension 上计算：

$$\begin{aligned}\mu &= (1/d) \sum_i x_i \\ \sigma^2 &= (1/d) \sum_i (x_i - \mu)^2 \\ y_i &= y_i \cdot (x_i - \mu) / \sqrt{\sigma^2 + \epsilon} + \beta_i\end{aligned}$$

与 BatchNorm 不同，LayerNorm 的统计量来自单个样本/单个 token 的 feature 维，不依赖 batch 内其他样本，因此训练和推理时使用同一种统计逻辑。原始 LayerNorm 论文正是为了解决 batch-size 依赖以及序列模型中 BatchNorm 难以直接使用的问题。

2.2 两种关键不变性

变换	LayerNorm 输出（忽略 affine）	解释
$x \rightarrow a \cdot x, a > 0$	基本不变	全局正尺度被标准差抵消
$x \rightarrow x + c \cdot 1$	不变	均值中心化消除统一平移
$x \rightarrow D \cdot x$, D 为逐维不同缩放	不变	LayerNorm 不是逐维 whitening
维度旋转 Qx	一般不保持	统计轴是 hidden features，不是完整协方差白化

关键结论：LayerNorm 不是 whitening。它只使用一个均值和一个标量方差，不会消除 feature-feature covariance。

2.3 为什么 affine γ/β 不能随便删？

标准化会把所有 token 的均值/尺度压到固定形式， γ/β 允许网络重新学习每个 channel 的有效尺度和偏移。对于现代 LLM，很多 RMSNorm 只保留 γ 而没有 β ；是否保留 bias 会影响 checkpoint 兼容、量化 folding 和参数映射。

3. RMSNorm：为什么“只做 RMS”在 LLM 中如此常见

3.1 定义

$$\begin{aligned}\text{rms}(x) &= \sqrt{(1/d) \sum_i x_i^2 + \epsilon} \\ y_i &= y_i \cdot x_i / \text{rms}(x)\end{aligned}$$

RMSNorm 论文的核心假设是：LayerNorm 的 re-centering 不一定是稳定训练所必需，而 re-scaling 才是关键。它移除了均值计算与 β ，在理论上保留对正尺度的 invariance。

3.2 RMS 与标准差的关系


有恒等式： $E[x^2] = \text{Var}(x) + E[x]^2$ 。因此 $\text{RMS}^2 = \sigma^2 + \mu^2$ 。若 residual stream 的均值天然接近 0，则 RMSNorm 与 LayerNorm 的尺度因子会非常接近；若 mean drift 明显，则二者差异会被放大。

关键结论：“RMSNorm $\approx$ LayerNorm”成立的隐含条件之一，是 activation mean 足够接近 0；这不是数学恒等式。

3.3 为什么现代 LLM 偏爱 RMSNorm

- 少一次均值 reduction 和中心化步骤，kernel 更简单；在大模型中真正收益取决于 fusion 与硬件。
- 不引入 β ，参数和状态略少，便于和 bias-free Transformer 风格统一。
- 对于 Pre-Norm decoder LLM，经验上长期表现稳定，因此被 Llama-family、Gemma、OLMo 2 等多种架构采用或扩展。
- RMSNorm 仍然需要 reduction；它不是“零成本 Norm”。

LayerNorm 与 RMSNorm：操作差异与不变性



4. Jacobian 与反向传播：Norm 为什么会改变优化几何？

设 $\hat{x} = (x - \mu) / \sqrt{\sigma^2 + \epsilon}$ 。LayerNorm 的 Jacobian 不是简单的对角缩放：每个输出维都依赖所有输入维，因为 μ 与 σ^2 都由全向量共同决定。这意味着一个 feature 的扰动会通过统计量耦合到其他 feature。

直觉形式： $J_{LN} \approx (\gamma / \sigma) \cdot [I - (1/d)11^T - (1/d)\hat{x}\hat{x}^T]$

RMSNorm 则去掉了均值中心化相关项，仍包含由 RMS 产生的 rank-1 耦合。

这个结构说明了两个重要事实：

- Normalization 把“纯径向”变化压掉，因此网络更关注方向信息；但 affine γ 又可以恢复各 channel 的不同尺度。
- 梯度不是简单穿过一个常数缩放；统计量的导数改变了梯度方向，因此 Norm placement 会实质改变深度优化动力学。

4.1 ϵ 不只是防除零

ϵ 的相对大小决定低方差输入的有效增益。当 $\sigma^2 \ll \epsilon$ 时，输出近似按 $1/\sqrt{\epsilon}$ 放大；不同框架/模型常使用 $1e-5$ 、 $1e-6$ 等不同值。加载 checkpoint 时若 ϵ 改变，通常不会立刻崩溃，但可能破坏精确 parity，尤其在低方差 token、量化和极深模型中。

Gotcha	为什么危险	建议
训练和推理 ϵ 不一致	低方差向量的缩放不同	把 ϵ 视为架构参数写入 checkpoint/config
FP16 中先平方再求和	可能 overflow / underflow	统计量内部使用更高精度累积
把 variance 用 unbiased=True	与主流 LayerNorm 定义不同	明确使用 population variance
normalized_shape 配错	可能沿多个维度做归一化	LLM 一般只沿 hidden dim

5. Pre-LN vs Post-LN：真正差异在梯度高速公路

5.1 Post-LN

$$y = \text{Norm}(x + F(x))$$

原始 Transformer 使用这一类结构。Xiong 等人的 mean-field 分析指出，Post-LN 在初始化时靠近输出层的梯度可能更大，因此学习率 warmup 对稳定训练尤其重要。

5.2 Pre-LN

$$y = x + F(\text{Norm}(x))$$

Pre-LN 的 residual identity path 不经过 Norm，梯度可以沿 skip connection 直接传播，因此初始化阶段更容易稳定。这是它成为现代 decoder LLM 常见选择的重要原因。

5.3 但 Pre-LN 并非没有代价

把所有 layer update 累加到同一 residual stream 后，stream 的绝对尺度可能随深度增长。如果 $F(\text{Norm}(x))$ 的幅度近似稳定，而 $\|x\|$ 越来越大，则后层 update / stream ratio 可能降低：

$$\rho_l = \|\Delta h_{l+1}\| / \|h_{l+1}\|$$

当 ρ_l 持续下降时，网络物理层数增加，但后层对最终表示的边际改写可能越来越小。这类现象常被描述为“有效深度”问题，而不是简单的梯度消失。




图 3 · 概念示意，不是任一论文的实测曲线

6. Peri-LN / 双侧 Norm : 为什么近年重新出现？

Peri-LN 把 normalization 放在子层“外围”：既规范化子层输入，也规范化子层输出，然后再写回 residual stream。2025 年 Peri-LN 工作系统分析了这种布局，报告其在实验中更平衡地控制 variance growth 与 gradient flow。

```
u = Norm_in(x)
Δ = Norm_out(F(u))
y = x + Δ
```

6.1 Gemma 2 : Pre-norm + Post-norm with RMSNorm

Gemma 2 技术报告明确列出 pre-norm=yes、post-norm=yes，并说明 RMSNorm 同时用于每个 Transformer sub-layer 的输入和输出。这个设计说明现代架构不再局限于“Pre 或 Post 二选一”。

6.2 OLMo 2 : Reordered Norm

OLMo 2 报告从 non-parametric LayerNorm 转向 RMSNorm，并把 norm 从 attention/MLP 的输入侧改到输出侧，再与 residual 相加。其动机来自大规模训练稳定性实验。

架构	Norm 类型	主要位置	公开报告中的动机/特征
Original Transformer	LayerNorm	Post-LN	经典设计；依赖 warmup 等稳定策略
典型 Llama-style	RMSNorm	Pre-LN	identity gradient path 清晰
Gemma 2	RMSNorm	Pre + Post	同时控制子层输入与输出尺度
OLMo 2	RMSNorm	子层输出再写 residual	报告为 reordered norm，稳定性驱动
Peri-LN	LN/RMSNorm 可变	子层外围	研究目标是平衡 variance 与 gradient

关键结论：不要用“Gemma 2 是 Post-LN”这种一句话标签概括。它明确同时使用 pre- 和 post-normalization。

7. Residual Stream 尺度：Norm 与“有效深度”

在 Pre-Norm block 中： $h_L = h_0 + \sum_l \Delta h_l$ 。Normalization 保证每个 sublayer 看到的输入尺度相对稳定，但并不直接阻止 residual stream 自身的 RMS 增长。

7.1 应该监控什么

指标	定义/近似	异常信号
stream_rms(l)	$RMS(h_l)$	随深度/step 单调暴涨
branch_rms(l)	$RMS(\Delta h_l)$	突然 spike 或层间极不均匀
update_ratio	$RMS(\Delta h_l)/RMS(h_l)$	后层趋近 0：可能有效深度下降
norm_gamma_rms	$RMS(\gamma_l)$	持续膨胀或 collapse
mean_abs	$ mean(h_l) $	LayerNorm/RMSNorm 差异的直接诊断量
grad_norm_by_depth	每层梯度范数	早层/晚层严重不平衡

仅看 global grad norm 不够：Normalization 问题高度“按层”发生。训练 dashboard 至少应该按 depth 采样 8-16 个 probe layers。

8. NormFormer、DeepNorm、LayerScale : Normalization 与 Residual Scaling 的交叉地带

8.1 NormFormer

NormFormer 针对 Pre-LN 模型的梯度大小在深度方向不均衡问题，在 attention 后、FFN 中间等位置增加额外 normalization 与 head-wise scaling。论文报告小幅参数开销即可改善 pretraining convergence。

8.2 DeepNorm

DeepNorm 不是“换一个 LayerNorm 公式”，而是 Post-LN residual scaling + 配套初始化。其核心目标是限制 model update，使极深 Transformer 可稳定训练。

8.3 LayerScale / ReZero

这些方法直接给 residual branch 增加可学习或深度相关的写入系数。它们与 Norm 的共同点，是都在控制“branch update 相对主流状态有多大”；差异是 Normalization 依赖当前 sample statistics，而 residual scaling 可以是 sample-independent。

关键结论：大模型稳定性设计往往是“Norm placement + residual scale + init + LR schedule”的组合问题，单独比较某一个模块容易得出错误因果结论。

9. QK-Norm : Normalization 不只属于 residual block

Attention logits 为 $s_{ij} = q_i \cdot k_j / \sqrt{d_{\text{head}}}$ 。如果 q/k 范数持续变大，即使有 $1/\sqrt{d}$ scaling，logit 仍可能过大，softmax 接近 one-hot，熵下降并导致训练不稳定。

9.1 原始 QKNorm

2020 年 QKNorm 将每个 query/key 向量做 L2 normalization，并用可学习 scale 替代固定的 $1/\sqrt{d}$ 。这直接把 dot product 变成 cosine-like similarity。

9.2 大规模模型中的 QK normalization

ViT-22B 报告把 query/key normalization 作为稳定 22B 视觉 Transformer 的关键架构改动之一。OLMo 2 也采用 QK-Norm；NVIDIA Transformer Engine 现已把 L2Normalization、RMSNorm、LayerNorm 等 QK norm 类型作为显式配置。

QK 方案	logit 尺度来源	优点	Gotcha
标准 scale	$\ q\ \cdot \ k\ / \sqrt{d}$	简单、无需额外 reduction	范数漂移会放大 logits
L2 QKNorm	$\cos(q,k) \times \text{learnable scale}$	直接移除 q/k 范数自由度	改变原始 attention parameterization
RMS QK-Norm	$\text{RMS}(q), \text{RMS}(k)$	适合现代 RMSNorm kernel 风格	与 RoPE/MLA/cache layout 耦合
clipping	直接裁剪 qkv/logits	工程简单	不是几何不变性，阈值敏感

9.3 RoPE 与 QK-Norm 的顺序

RoPE 是正交旋转，理想精确算术下保持向量 L2 norm；但 RMSNorm 与逐维 γ 、低精度误差、partial rotary 等会让“放 RoPE 前还是后”不再完全等价。checkpoint 迁移时必须以原实现顺序为准。

10. Final Norm : 为什么最后一个 Norm 特别重要

许多 decoder LLM 在最后一个 Transformer block 后、LM head 前放 final RMSNorm/LayerNorm。它把 residual stream 的径向尺度从最终 logits 中剥离，使输出主要依赖表示方向与 LM head 权重。

```
logits = W_vocab · Norm(h_final)
```

如果移除 final norm，cross-entropy 可以通过增大 hidden/logit scale 来提升置信度；这会产生额外的径向优化自由度。2026 年 TaperNorm 工作把“scale anchoring”视为输出 normalization 的关键角色之一，并研究逐步把 sample-dependent norm 退火为固定 affine map。该结论仍属于新兴研究。

10.1 量化 Gotcha

final residual stream 的分布可能比 norm 后更宽。量化 LM head 时，如果 calibration 采样点放在 norm 前而 kernel 实际量化 norm 后输入，会导致量化尺度错配。

11. 定性 : FP32、BF16、FP16、FP8

11.1 Reduction 是风险点

LayerNorm/RMSNorm 包含平方、求和、均值、rsqrt。低精度下最危险的是统计量 reduction，而不是最后的逐元素乘法。NVIDIA Transformer Engine 文档指出，低精度输入/输出可行，但 norm/exp 等操作常需要内部更高精度。

11.2 典型实现策略

input: BF16/FP16
mean / variance / rms accumulation: FP32 (or hardware-supported higher precision path)
rsqrt: FP32
output cast back to activation dtype

问题	症状	根因	处理
variance 负数	sqrt NaN	$E[x^2]-E[x]^2$ 的取消误差	Welford 或稳定 reduction; 高精度累积
FP16 overflow	Norm 前已有 Inf	residual/MLP 激活太大	定位上游, 不要只增大 ϵ
ϵ 过小	小方差 token 极端增益	低精度下 denominator 太小	用模型原始 ϵ ; 做 ablation
γ FP16 更新不稳	少量 channels 爆长	optimizer state / update precision	master weights / FP32 optimizer state
fused kernel 不一致	训练/推理微小漂移	reduction order 不同	允许 tolerance; 做逐层 parity

12. Kernel / 系工程：Norm 为什么经常 memory-bound

矩阵乘法有高 arithmetic intensity；LayerNorm/RMSNorm 需要读入一个 token 的全部 hidden features，做 reduction，再第二次/融合地写出结果，因此通常更接近 memory-bound。单看 FLOPs 会严重低估它的延迟影响。

12.1 最有价值的 fusion

- RMSNorm/LayerNorm + QKV Linear：减少中间 activation 写回 HBM。
- RMSNorm/LayerNorm + MLP up/gate projection：同理。
- Dropout + residual add + norm：训练时减少多次读写；但 RNG 与反向重算需要严格一致。
- Final norm + LM head：在 last-token decode 场景可能有融合空间，但 vocabulary projection 通常更重。

12.2 RMSNorm “更快”为什么不是固定百分比

原始 RMSNorm 论文在当时多种网络上报告显著运行时间下降，但在现代 GPU LLM 中，收益受 hidden size、batch/token 数、kernel fusion、memory hierarchy 和 compiler 决定。若 LayerNorm 和 RMSNorm 都被高度融合，理论上少一个 mean reduction 并不等价于端到端同等比例加速。

12.3 Tensor / Sequence Parallel

如果 hidden dimension 被 tensor-parallel shard，那么 LayerNorm/RMSNorm 的统计量是否需要跨 rank all-reduce，取决于 shard 方式。Megatron-style sequence parallel 通常让每个 rank 持有完整 hidden features 的部分 token，从而避免在 Norm 上做 hidden-wise collective。

关键结论：“Norm 没有参数量，所以系统成本小”是错误直觉。它的瓶颈通常来自内存带宽、reduction 与 kernel launch，而不是参数。

13. Checkpoint 移：LayerNorm ↔ RMSNorm 绝不是改 class 名

13.1 LN → RMSNorm 的功能差异

LayerNorm 会减去 μ ，而 RMSNorm 不会。即使把 γ 完全复制，也无法对任意输入保持函数等价。只有在 activation mean 近似 0 的条件下，两者才可能近似。2026 年也出现了研究如何在特定条件下做 LN→RMSNorm 参数映射或可证明替换，但这仍不是通用“一键转换”。

13.2 迁移 checklist

1. 记录原 checkpoint：Norm 类型、 ϵ 、 γ/β 、有无 zero-centered gamma、放置位置。
2. 从真实校准数据统计每层 pre-norm activation mean/RMS，而不是假设零均值。
3. 先做 forward parity：逐层 residual stream、attention output、MLP output。
4. 若结构变化，使用短程 distillation / continued pretraining 恢复，而不是直接宣称等价。
5. 重新做量化 calibration、KV-cache decode parity 和长上下文测试。

14. Normalization-free / 新型路线：哪些已经成熟，哪些仍是研究？

方向	核心思想	成熟度判断（2026）
nGPT	把 embeddings、weights、hidden states 约束在 hypersphere	有吸引力的系统重参数化研究；不是主流通用 LLM recipe
DyT	用 $\tanh(\alpha x)$ 点式函数替代 sample-stat	2025 研究表明多类 Transformer 可行；仍需

方向	核心思想	成熟度判断（2026）
	norm	大规模 LLM 复现
Derf	进一步设计 normalization-free 点式替代	2025-26 新研究
TaperNorm	训练早期保留 norm，后期退火到固定 affine	2026 新兴；强调 scale anchoring
LN removal fine-tuning	训练后移除 LN 并恢复模型	解释性/推理实验；不等同于从零 norm-free 预训练

这些方向共同提出一个更深的问题：Normalization 的真正功能，到底是“动态统计标准化”，还是更一般的“限制表示的径向自由度 / 输出尺度”？目前工程事实仍是：RMSNorm/LayerNorm 是最成熟的大模型训练方案。

15. 55 个高频 Gotchas

#	Gotcha	为什么危险
1	把 LayerNorm 当 BatchNorm	LN 不跨 batch 统计；batch size 不改变其统计定义。
2	把 RMSNorm 说成“没有归一化”	它仍按 token 计算 RMS reduction。
3	LN 和 RMSNorm 只差速度	二者 invariance 不同；activation mean 非零时函数差异真实存在。
4	ϵ 只是防 0	它决定低方差向量的增益上限。
5	训练/推理 ϵ 不同	会破坏 exact parity。
6	variance 用 unbiased estimator	主流 LN 使用 population variance。
7	沿错维度归一化	LLM 通常沿最后 hidden dim。
8	把 pre/post 位置写反	checkpoint 载入可成功但函数完全不同。
9	只比较 Norm 类型，不固定 topology	实验因果混杂。
10	只比较 topology，不固定 init/LR	Post-LN 往往更依赖稳定化配置。
11	Pre-LN=永不需要 warmup	更稳定 ≠ 任何规模/优化器都无需 warmup。
12	Post-LN=一定更差	DeepNorm/现代双侧设计说明 Post-style 可被稳定化。
13	Gemma2 简化成 Post-LN	它公开报告同时 pre- 和 post-RMSNorm。
14	RMSNorm 一定有 bias	很多现代实现只有 γ 。
15	LN 一定有 β	可配置 bias=False；不同框架默认不同。
16	忽略 γ 初始化	γ 的 parameterization 会改变初始 branch scale。
17	zero-centered gamma 与普通 gamma 混用	公式是 $(1+\gamma)$ 而不是 γ 。
18	只看 loss，不看 stream RMS	尺度病态可能早于 loss spike。
19	只看 global grad norm	层间梯度失衡会被平均掉。
20	Norm 后均值/方差统计错对象	RMSNorm 后均值不保证为 0。
21	把 $RMS=std$	$RMS^2=Var+mean^2$ 。
22	把 LN 当 whitening	它不处理完整 covariance。
23	把 γ 当无关紧要	γ 是每 channel 的可学习尺度路由。
24	weight decay 作用于 γ 不做记录	会改变有效尺度动态。
25	对 Norm bias/weight 使用和矩阵同 LR 不做 ablation	超大规模训练可能敏感。
26	FP16 直接做平方累积	overflow/underflow 风险。

#	Gotcha	为什么危险
27	NaN 出现在 Norm 就认定 Norm 是根因	通常上游 residual 已出现 Inf。
28	用增大 ϵ 掩盖激活爆炸	会改变模型函数且治标不治本。
29	fused 与 unfused 要求 bitwise 相等	reduction 顺序不同会有浮点差异。
30	fused dropout-add-norm 重算 RNG 不一致	activation checkpoint 反向会错。
31	sequence parallel 分片沿 hidden	可能迫使 Norm 统计跨 rank 通信。
32	TP checkpoint γ shard 规则错误	Norm 参数通常与 hidden layout 强相关。
33	量化把 norm 统计也硬压到 INT8	reduction 需要更高精度。
34	量化 calibration 在 norm 前/后搞反	输入分布完全不同。
35	QK-Norm 和 block Norm 混为一谈	一个控制 attention vectors，一个控制 residual/branch。
36	QK-Norm 后仍机械使用原 $1/\sqrt{d}$	取决于具体公式；有的用 learnable scale。
37	RoPE 与 QK-Norm 顺序随意换	实现、 γ 、低精度下不一定等价。
38	partial rotary + QK-Norm 不做单测	rotary/non-rotary 维的统计会不同。
39	MLA 中直接加 key RMSNorm	可能破坏 latent cache 优势。
40	final norm 可随便删	会改变 logit scale 与径向自由度。
41	LM head tying 后忽略 final norm	embedding/LM head 共享并不消除 final norm 作用。
42	LN $\rightarrow$ RMSNorm 只复制 γ	缺少 mean-centering，无法通用等价。
43	结构迁移后不做短程恢复	小函数差异会逐层累积。
44	只在随机输入做 parity	真实 activation mean/variance 才能暴露差异。
45	使用太短序列评估稳定性	长上下文可能放大 residual/logit scale 问题。
46	只测平均 perplexity	需要 loss spikes、tail tokens、long-context。
47	Norm kernel benchmark 不含真实 shape	batch/token/hidden 决定 memory behavior。
48	“RMSNorm 少一次 reduction=2 $\times$ 快”	端到端受 fusion 与带宽限制。
49	归一化参数忽略 optimizer state 成本	每层虽小，但状态/通信仍存在。
50	把 norm-free 论文直接视为生产替代	大规模语言预训练证据仍不足。
51	把 1B-3B 实验外推到 100B+	稳定性现象经常随 scale 改变。
52	不记录 PyTorch/TE kernel 版本	融合实现与默认参数会演化。
53	normalized_shape 在多模态模型复用错误	图像/音频 feature layout 可能不同。
54	MoE 每个 expert 输出尺度不监控	router 与 expert branch 可产生异质 residual update。
55	只问 “LayerNorm 还是 RMSNorm”	更重要的问题通常是类型 $\times$ 位置 $\times$ residual $\times$ init $\times$ precision 的联合设计。

16. Know-how：从零训练 LLM 的 Normalization 工程手册

- 先选择 topology，再选择 Norm 类型：例如 Pre-RMSNorm 是一个组合，不是一个单一模块。
- 把 ϵ 、affine/bias、zero-centered-gamma、Norm placement 作为 config 的一等字段。
- 初期 baseline 优先使用成熟的 Pre-RMSNorm；不要同时改 topology、init、optimizer。

9. 每 4-8 层插入监控 probe, 记录 stream_rms、branch_rms、mean_abs、 γ _rms、grad_norm。
10. 重点监控 update_ratio=branch_rms/stream_rms; 它比单看激活绝对值更能反映后层写入能力。
11. 用 BF16/FP16 激活时, 确认 Norm reduction 内部精度; 用 kernel 文档/单测验证, 不靠猜。
12. 训练早期记录 attention logit max/entropy; 必要时再引入 QK-Norm, 而不是先堆多个稳定技巧。
13. 做 topology ablation 时固定数据顺序、token budget、LR schedule、init、gradient clipping。
14. 若试 Post-LN/Peri-LN, 重新搜索 peak LR / warmup; 不能复用 Pre-LN 超参直接比较。
15. Norm 参数的 weight decay / learning rate 策略必须明确记录。
16. 在大规模训练前做 100M-1B proxy, 但至少用相同 depth/width scaling 规律与真实 precision。
17. 对 loss spike, 先查上游 residual / MLP / attention, 再查 Norm; Norm 常是第一个“显出 NaN”的地方而非源头。
18. 部署前做 unfused reference vs fused kernel 的逐层 tolerance parity。
19. 做 TP/SP/CP 时专门检查 Norm reduction 是否跨错误维度或引入多余 collective。
20. 转换 checkpoint 时用真实 calibration corpus 比较每层 mean/RMS, 而不是只对随机 Gaussian 输入。
21. 量化前分别统计 norm 前/后的 percentile、amax、outlier channels。
22. 长上下文扩展后重新检查 residual RMS 和 attention logits; 位置外推改变的不只 attention pattern。
23. MoE 模型要按 expert / router path 统计 branch 输出尺度, 避免少数 expert 主导 residual。
24. 所有 normalization-free 方案先做完整训练曲线 + 同 compute ablation, 再考虑生产替换。
25. 最终架构选择应以“稳定训练 + 单位 token utility + 实际吞吐 + 推理精度”联合评价。

17. Know-why : 20 条因果原理

问题	Know-why
为什么 LN 与 batch size 无关?	统计量来自单 token 的 hidden features, 不跨 batch。
为什么 RMSNorm 能工作?	很多稳定收益来自控制向量径向尺度; re-centering 在许多 LLM 表示中不是必须。
为什么 Pre-LN 更易训?	identity residual path 不经过 normalization, 初始化时梯度高速公路更直接。
为什么 Pre-LN 仍可能有深度问题?	residual stream 累加增长, 而每层 branch 输入被归一化, 后层相对 update 可能变小。
为什么 Post-LN 更依赖 warmup?	梯度尺度在深度方向更不均衡; 初始化附近大 LR 更容易失稳。
为什么双侧 Norm 有吸引力?	同时约束子层输入分布与写回 residual 的 branch 尺度。
为什么 ϵ 会影响模型?	它定义 denominator 下界, 因此定义低方差区域的最大局部增益。
为什么 Norm 内部常用 FP32 reduction?	平方/求和/rsqrt 对动态范围和取消误差敏感。
为什么 RMSNorm 不保证 zero mean?	它没有减 μ ; 只控制 $E[x^2]$ 。
为什么 LN 不等于 whitening?	只除一个标量标准差, 没有消除全协方差。
为什么 γ 很重要?	归一化抹去尺度后, γ 恢复每个 channel 可学习的有效增益。
为什么 QK-Norm 能防 attention saturation?	它消除 q/k 范数增长对 dot-product 的直接放大。
为什么 final norm 能锚定 logit scale?	LM head 看到固定径向尺度的 hidden, 无法单靠放大 residual norm 提升置信度。
为什么 Norm kernel 经常 memory-bound?	每个 token 要做 reduction + 读写, FLOPs 很低而内存访问不可少。
为什么 fusion 有用?	减少中间 activation 落 HBM 与 kernel launch。
为什么 LN→RMSNorm 不能直接等价?	LayerNorm 减均值, RMSNorm 不减; 这是输入依赖的差异, 静态 γ 无法一般补偿。
为什么只看 loss spike 太晚?	激活尺度、梯度不均衡通常会先出现趋势异常。
为什么 norm-free 路线可能成立?	稳定性的核心可能是限制径向/输出尺度, 而不一定非要 sample-statistics normalization。
为什么 norm-free 仍难成为默认?	成熟 recipe 的 scaling evidence、precision/kernels、checkpoint ecosystem 都更弱。
为什么 Norm 需要与 residual/init 联合设计?	所有这些机制都共同决定每层 update 的绝对和相对尺度。

18. Debug Playbook : 从 NaN / Loss Spike 反推根因

症状	第一检查点	第二检查点	常见误判
LayerNorm 输出 NaN	Norm 输入是否已有 Inf/NaN	variance/rms accumulation dtype	直接把 ϵ 调大
某层 stream RMS 暴涨	attention/MLP branch RMS	γ 、residual scale、LR	认为是 tokenizer/data 单点
attention entropy→0	Q/K RMS、logit max	QK-Norm / scale / RoPE	只调 softmax temperature
后层 grad 极小	update_ratio by depth	Pre-LN stream growth	只增加全局 LR
训练正常、decode 漂移	fused norm parity	KV/cache / dtype path	归咎采样随机性
量化后困惑度暴涨	final/pre-proj norm 分布	outlier channel / calibration	盲目增加 quant bits
LN→RMSNorm 转换失真	activation mean by layer	distill/continued training	复制 γ 后认为完成

症状	第一检查点	第二检查点	常见误判
多机才 NaN	SP/TP reduction axis	collective dtype / overlap	认为 kernel 单卡正确就足够

19. 公平 Ablation Matrix

实验轴	候选	必须固定	建议记录
Norm 类型	LayerNorm / RMSNorm	topology、 ϵ 、init、LR	loss/token、throughput、mean_abs
Placement	Pre / Post / Peri / reordered	Norm 类型、residual scale	grad-by-depth、stream RMS
ϵ	1e-5 / 1e-6 / sweep	所有其他超参	tail loss、low-var tokens
QK Norm	none / L2 / RMS	head dim、RoPE、softmax	logit max、entropy、QK RMS
Norm precision	FP32 acc / lower precision	kernel/layout	NaN、speed、parity
Fusion	reference / fused	dtype、math definition	HBM traffic、latency
Norm-free	RMSNorm / DyT / other	compute/data/optimizer	stability + final utility

最重要的实验原则：不能在同一个 ablation 里同时改变 Norm topology、residual scaling、初始化和学习率，再把结果归因给“RMSNorm 比 LayerNorm 好”。

20. PyTorch Reference : 实现与单测

20.1 手写 LayerNorm / RMSNorm

```
import torch
import torch.nn as nn

class ManualLayerNorm(nn.Module):
    def __init__(self, d, eps=1e-5):
        super().__init__()
        self.weight = nn.Parameter(torch.ones(d))
        self.bias = nn.Parameter(torch.zeros(d))
        self.eps = eps
    def forward(self, x):
        xf = x.float()
        mean = xf.mean(dim=-1, keepdim=True)
        var = (xf - mean).pow(2).mean(dim=-1, keepdim=True)
        y = (xf - mean) * torch.rsqrt(var + self.eps)
        return (y * self.weight.float() + self.bias.float()).to(x.dtype)

class ManualRMSNorm(nn.Module):
    def __init__(self, d, eps=1e-6):
        super().__init__()
        self.weight = nn.Parameter(torch.ones(d))
        self.eps = eps
    def forward(self, x):
        xf = x.float()
        ms = xf.pow(2).mean(dim=-1, keepdim=True)
        y = xf * torch.rsqrt(ms + self.eps)
        return (y * self.weight.float()).to(x.dtype)
```

20.2 三种 topology skeleton

```
# Pre-Norm
x = x + attn(rms1(x))
x = x + mlp(rms2(x))

# Post-Norm
x = rms1(x + attn(x))
x = rms2(x + mlp(x))

# Peri / dual-sided norm (conceptual)
x = x + post1(attn(pre1(x)))
x = x + post2(mlp(pre2(x)))
```

20.3 必做 parity tests

```
# 1) torch reference vs manual
# 2) fp32 vs bf16 tolerance
# 3) fused vs unfused
# 4) full forward vs checkpointed backward
# 5) single GPU vs TP/SP
# 6) prefill vs decode path (if QK/final norm involved)
```

20.4 监控 hook

```
@torch.no_grad()
def stats(x):
    xf = x.float()
    return {
        "mean_abs": xf.mean(-1).abs().mean().item(),
        "rms": xf.pow(2).mean(-1).sqrt().mean().item(),
```

```

    "amax": xf.abs().amax().item(),
}

```

21. 面试 / 深度推 25 □

26. 推导 LayerNorm 对 $x \rightarrow a \cdot x + b \cdot 1$ 的不变性； $a < 0$ 时发生什么？
27. 证明 $\text{RMS}^2 = \text{Var} + \text{mean}^2$ ，并据此说明 LN 与 RMSNorm 何时近似。
28. 为什么 LayerNorm 不是 whitening？
29. 写出 LayerNorm Jacobian 的结构，并解释 rank-1 / centering 项的来源。
30. 为什么 Pre-LN 在初始化时更容易训练？
31. 为什么 Pre-LN 深层模型可能出现 update/stream ratio 下降？
32. Post-LN 为什么通常更依赖 warmup？
33. Gemma 2 同时 pre/post RMSNorm 与典型 Pre-RMSNorm 有什么区别？
34. OLMo 2 的 reordered norm 改变了 residual 写入的哪一个量？
35. RMSNorm 少了哪些运算？为什么端到端速度收益不能直接按 FLOPs 推？
36. ϵ 取值如何影响低方差 token？
37. 为什么 Norm reduction 在 BF16/FP16 下常需要 FP32 accumulation？
38. QK-Norm 与 $1/\sqrt{d_{\text{head}}}$ scaling 的关系是什么？
39. L2 QKNorm 与 RMS QK-Norm 的几何差异是什么？
40. RoPE 前后做 QK-Norm 是否严格等价？讨论 exact arithmetic 与 learned γ 。
41. 为什么 final norm 会影响 logit scale？
42. LN $\rightarrow$ RMSNorm 为什么不能只复制 γ ？
43. 如果 activation mean 一直 ≈ 0 ，是否就能安全替换？还缺哪些条件？
44. 如何设计一个公平的 Pre-LN vs Peri-LN ablation？
45. 如何从日志区分 “branch explosion” 和 “residual accumulation growth”？
46. 为什么 global grad norm 不能诊断层间梯度失衡？
47. 在 sequence parallel 中怎样布局 token/hidden 才能让 Norm 无跨 rank reduction？
48. 为什么 fused dropout-add-norm 和 activation checkpoint 容易出现 RNG/parity bug？
49. norm-free Transformer 成立说明了什么？又不能说明什么？
50. 如果要设计 100B 模型，你会把 Norm topology、QK-Norm、precision、monitoring 如何组成最小稳定 recipe？

22. ：如何把 Normalization 作为系统问题理解

把现代 Transformer 的 Normalization 压缩成一句话：它通过约束表示和分支更新的尺度自由度，重新塑造深度网络的优化几何。LayerNorm、RMSNorm、QK-Norm、final norm 看似是同一种运算的不同位置，实际上分别控制 residual stream、attention matching 和输出 logits 的不同尺度通道。

你真正要问的问题	比“用 LN 还是 RMSNorm？”更好的问法
表示	我们需要 re-centering，还是只需要 re-scaling？
深度	residual stream 与 branch update 的比值如何随层数变化？
梯度	当前 topology 是否让不同深度的参数获得同量级有效更新？
Attention	Q/K norm 是否失控并导致 softmax saturation？
数值	reduction/rsqrt 在什么精度执行？
系统	Norm 是否与 Linear / residual add 融合，真实瓶颈在哪里？
迁移	结构变化是否经过真实 activation 校准与恢复训练？
研究	新方案证据是在小模型、视觉模型，还是长周期 LLM 预训练？

关键结论：最可靠的工程思路不是寻找“最好的 Norm”，而是控制 residual / branch / QK / logit 四条尺度链路，并用逐层监控验证它们。

23. 考文主要究源

[1] Ba, Kiros, Hinton. Layer Normalization. arXiv:1607.06450 (2016).

[2] Vaswani et al. Attention Is All You Need. NeurIPS (2017).

[3] Nguyen & Salazar. Transformers without Tears: Improving the Normalization of Self-Attention. arXiv:1910.05895 (2019).

[4] Zhang & Sennrich. Root Mean Square Layer Normalization. NeurIPS (2019), arXiv:1910.07467.

[5] Xiong et al. On Layer Normalization in the Transformer Architecture. ICML (2020), arXiv:2002.04745.

[6] Henry et al. Query-Key Normalization for Transformers. arXiv:2010.04245 (2020).

[7] Shleifer, Weston, Ott. NormFormer: Improved Transformer Pretraining with Extra Normalization. arXiv:2110.09456 (2021).

[8] Wang et al. DeepNet: Scaling Transformers to 1,000 Layers. arXiv:2203.00555 (2022).

[9] Dehghani et al. Scaling Vision Transformers to 22 Billion Parameters. ICML (2023), arXiv:2302.05442.

[10] Gemma Team. Gemma 2: Improving Open Language Models at a Practical Size. arXiv:2408.00118 (2024).

[11] Loshchilov et al. nGPT: Normalized Transformer with Representation Learning on the Hypersphere. arXiv:2410.01131 (2024).

[12] OLMo Team. 2 OLMo 2 Furious. arXiv:2501.00656 (2025 revision).

[13] Kim et al. Peri-LN: Revisiting Layer Normalization in the Transformer Architecture. arXiv:2502.02732 / ICML 2025.

[14] Zhu et al. Transformers without Normalization. arXiv:2503.10622 (2025).

[15] Kanavalau et al. Gated Normalization Removal and Scale Anchoring in Pre-Norm Transformers. arXiv:2602.10408 (2026).

[16] Han et al. QK-Normed MLA: QK normalization without full key caching. arXiv:2606.16310 (2026).

[17] PyTorch documentation: `torch.nn.LayerNorm` / `torch.nn.RMSNorm` (consulted 2026-08).

[18] NVIDIA Transformer Engine documentation: LayerNorm/RMSNorm, QK norm, low-precision training (consulted 2026-08).

说明：2025-2026 的 `normalization-free`、`Peri-LN`、`TaperNorm`、`QK-Normed MLA` 等结论仍在快速演化。本报告将其用于理解研究趋势，不把它们直接描述为已经替代 `Pre-RMSNorm` 的行业共识。