

LLM 预训练之 Learning Rate Schedule

Warmup · Cosine · Linear-to-Zero · WSD · WSO · WSqD · μ Transfer

深度研究手册 / 2026-08




图 1 常见学习率调度曲线。曲线仅用于比较机制形状，不代表统一推荐超参数。

核心判断

Learning Rate Schedule 不是“训练后期把 LR 调小”这么简单。它定义每个 optimizer step 可走多远，因此同时控制早期稳定性、中期探索速度、终局降噪、训练 horizon 可扩展性，以及 checkpoint 是否适合作为后续 Continued Pretraining / SFT 的起点。

层次	核心变量	决定什么
Optimizer	AdamW / β / ϵ / WD	给定梯度下，每个坐标如何预条件
LR Schedule	$\eta(t)$, warmup, decay	全局 step size 如何随训练时间变化
Batch / Tokens	B(t), tokens/step	梯度噪声与每次更新覆盖的数据量
Model Scaling	width/depth/parameterization	同一数值 LR 对实际 update 的含义
Training Horizon	目标 tokens / steps	cosine/linear 等 schedule 的终点位置

1. Learning Rate 在 AdamW 里真正控制什么？

对于 AdamW，可将任务梯度部分的更新粗略写成 $\Delta\theta_t \approx -\eta_t \cdot m_hat_t / (\sqrt{v_hat_t} + \epsilon)$ 。因此 η_t 是乘在预条件更新方向上的全局尺度。它不直接等于“参数移动百分比”，但会和参数范数、second moment、weight decay、gradient clipping 一起决定实际 update-to-weight ratio。

Learning Rate 不是孤立旋钮：它与 Optimizer、Batch、模型尺度共同决定 Update Dynamics




图 2 LR 是 *update-control plane* 的一个核心变量，而不是独立于 *Optimizer/Batch/Scale* 的旋钮。

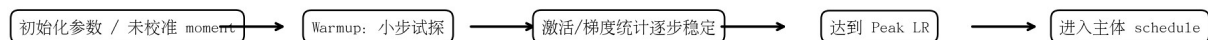
指标	建议监控	为什么比只看 LR 数值更有意义
η_t	当前 LR / peak ratio	知道 schedule 处于哪一阶段
Update RMS	每层实际 $\Delta\theta$ RMS	直接反映 optimizer 后的位移
Update/Weight	$\ \Delta\theta\ / \ \theta\ $	把 step size 与参数尺度关联
Grad Norm	全局 + 分层	区分“LR 太大”与“梯度本身异常”
Loss spike	step 位置 + LR phase	判断 warmup/peak/rewarm 是否与不稳定相关

Know-how

调 LR 时不要只画 train loss。至少同时记录：LR、grad norm、update RMS / update-to-weight ratio、各层 activation RMS、optimizer moment RMS，以及 validation loss。否则很难判断“LR 不合适”究竟是 step size、moment、batch noise 还是数值稳定问题。

2. Warmup：为什么现代 Transformer 几乎都需要早期缓启动？

Warmup 的工程角色：让“可承受的步长”逐步打开



Warmup 不是单一理论机制的产物；它是对训练早期高曲率、moment 初始化、残差/激活尺度和大 batch 高峰 LR 风险的工程缓冲。

图 3 Warmup 的工程角色。不同论文对其机制解释并不完全相同，因此不应归结为单一原因。

原始 Transformer 使用与 model dimension 和 step 相的 warmup + inverse-square-root schedule；此后线性 warmup 成为大规模 Transformer 的常见工程做法。Warmup 的共同目的，是避免一开始直接用 peak LR 让尚未稳定的表示、梯度与 optimizer moment 发生过大大位移。[R1]

Warmup 维度	常见选择	主要风险
起始 LR	0 或很小的 lr_init	过高会把第一批 noisy update 放大
长度	固定 steps / samples / tokens / fraction	过短可能不稳；过长浪费高 LR 学习阶段
形状	Linear 最常见；也有 polynomial	形状影响通常小于 peak LR 与长度，但需验证
计量单位	优先 samples/tokens 当 batch 会变化	按 steps 时，改变 global batch 会改变 warmup token 数

一个重要边界

Warmup 不能修复错误的 peak LR、错误的初始化、爆炸的 activation 或不稳定的低精度 kernel。它只是让系统逐步进入目标 step size。若 warmup 结束立刻 loss spike，通常应优先重新检查 peak LR 和 update statistics。

3. 主体 Schedule：Cosine、Linear、Inverse-Sqrt、Constant

Schedule	典型形式	是否要求预知终点	主要优势	主要代价
Cosine	$\eta_{\min} + 0.5(\eta_{\max} - \eta_{\min})(1 + \cos \pi u)$	是	平滑、成熟、被大量 LLM recipe 使用	训练 horizon 改变时需要重新解释整条曲线
Linear-to-zero	$\eta_{\max}(1-u)$	是	简单；2025 D2Z 给出强经验结果	终点绑定强；对 peak LR tuning 敏感
Inverse-sqrt	$\eta \propto 1/\sqrt{t}$ (warmup 后)	否/较弱	自然支持持续训练；原始 Transformer 系	后期衰减慢；与现代 AdamW recipe 需重新调参
Constant / WSO	warmup 后 $\eta = \eta_{\text{peak}}$	否	持续可训练；2026 WSO 显示更佳 SFT 适应性	pretraining final loss 可能不如 decay-based
WSD	Warmup → Stable → Cooldown	主体不需；cooldown 需	可从 stable branch 任意时间点分叉结局模型	peak LR 仍可能与 horizon 有隐式耦合

Schedule	典型形式	是否要求预知终点	主要优势	主要代价
WSqD 2026	Warmup $\rightarrow$ shifted $1/\sqrt{t} \rightarrow$ linear decay	base 部分不需	提出 horizon-independent base LR	非常新，证据仍以预印本实验为主

3.1 Cosine 的隐藏前提：训练终点必须和 schedule horizon 对齐




图 4 Cosine 把预期训练终点编码进函数。延长/短不只是“多/少跑一些 steps”。

Chinchilla 的 scaling 实验指出：当目标是训练 D 个 tokens 时，把 cosine cycle length 设大致匹配 D ，final loss 更好；固定一的 130B-token schedule 会高估早期训练点的 loss，进而扭曲 compute-optimal 分析。[R4] 这说明 schedule horizon 本身就是 scaling experiment 的控制变量。

Know-why

如果你在 30% 训练进度提前停止 cosine run，你拿到的不是“计划中 30% compute 的最优 checkpoint”，而是一个仍处于较高 LR 的中间状态；相反，如果计划外延长到 150%，模型可能早已在 min LR 附近训练很久。

4. WSD：把持续学习与最终收敛解耦

WSD 的核心价值：把“持续训练主干”和“终点收敛分支”解耦




图 5 WSD / WSD-S 的核心思想：主干保持较高 LR，想发布/评测时再进行短 cooldown。

MiniCPM 2024 系统提出 Warmup-Stable-Decay (WSD)，目标之一是支持“不预先固定 token horizon”的连续训练，并提高中间 checkpoint 的可复用性。[R5] 之后 Wen 等从“river valley”视角解释其训练动力学：stable phase 的高 LR 允许沿低损失谷方向快速前进，而 decay phase 通过降低震荡暴露出更低的最终 loss；WSD-S 进一步尝试复用多个 compute budget 下的 decay 分支。[R6]

WSD 阶段	LR	优化直觉	工程意义
Warmup	0/小值 $\rightarrow$ peak	建立稳定训练统计	防止一开始大步失稳
Stable	$\approx$ peak	保持较高移动速度	可持取新据；主干不定固定 horizon
Decay / Cooldown	peak $\rightarrow$ min/0	降低 gradient-noise-induced oscillation	得到更低 final loss / 发布 checkpoint

WSD 不是“万能可无限延长”

2026 WSqD 指出：即使 stable phase 不依赖 horizon，peak LR 本身仍可能是按原始 horizon 调出来的；当训练被大幅延长时，原 peak LR 可能不再 optimal。[R12] 因此真正的 horizon-free 仍是开放问题。

5. 2025-2026：Decay 形正在被重新研究

5.1 Linear Decay-to-Zero (D2Z)

2025 的 Straight to Zero 在其 compute-optimal 实验设置中报告：在 peak LR 调优后，简单 linear decay-to-zero 一贯优于其比较的常见 $10\times$ cosine decay，并且数据量越大收益越明显；论文还报告 610M 模型、80 tokens-per-parameter 的 D2Z 训练低于 200 TPP、 $10\times$ decay 的 loss，对应其设定下约 60% compute savings。[R8] 这是一项有吸引力的经验结果，但仍应在自己的 tokenizer、optimizer、data mixture 和 batch regime 上复现。

5.2 Warmup-Stable-Only (WSO)：最低 pretraining loss 不一定最利于后续 SFT

ICLR 2026 工作比较 1B 与 8B 模型，发现 warmup 后保持 constant LR 的 WSO，在 SFT 后的性能持续优于 decay-based schedulers，尽管 decay-based 方法可能获得更好的 pretraining 指标；其 loss-landscape 分析还观察到 decay 模型落入更 sharp 的 minima，而 WSO 保留更平坦、可适应的解。[R11]

重要目标冲突

如果目标是“发布最强 Base checkpoint 的最低 pretraining loss”，强 decay/cooldown 很合理；如果目标是“获得最适合持续预训练或后续 SFT 的母 checkpoint”，2026 WSO 结果说明，不 decay 可能更有价值。两者优化目标并不完全相同。

5.3 WSqD：尝试把 peak LR 也从固定 horizon 中解耦

WSqD (2026-07) 把 WSD 的 constant stable phase 替换为 shifted inverse-square-root base，再保留最终 linear cooldown。论文结合凸优化的理论分析，在 SlimPajama LLM pretraining 中报告：一个 peak LR 可以跨多个训练 horizons 复用，性能匹配或超过仔的 WSD 与其他 baselines。[R12] 这是最新前沿预印本，生产采用前应关注后续独立复现。

6. Peak LR：比 schedule 形状更应该先调的变量

同一个 schedule shape 在错误 peak LR 下没有可比意义。实践中应先确定稳定且高效的 η_{peak} ，再比较 decay shape。MiniCPM 的 Model Wind Tunnel 实验结合 μP ，观察其 0.04B-0.5B 模型的 optimal base LR 没有明显漂移；Qwen2.5 则明确用跨 44M-14B dense、44M-1B activated MoE、0.8B-600B tokens 的实验拟合 optimal LR 与 batch size 的 scaling law。[R5][R10]

方法	目标	什么时候有用	注意点
小模型 LR sweep	直接寻找 η_{peak}	新架构/新数据配方	尺寸扩大后 optimal LR 可能漂移
μP / $\mu Transfer$	让超参跨 width 更稳定	大模型直接调参过贵	要求按 μP parameterization 设计；并非任意现有 checkpoint 可套用
经验 scaling law	拟合 $\eta_{opt}(N,D)$	有多个 proxy runs	依赖架构/optimizer/data family
Stability sweep	找最大无 spike LR	上前安全界	最大稳定 LR $\neq$ 最佳 final loss LR

$\mu Transfer$ 的价值

Tensor Programs V 量在 μP parameterization 下，多种 optimal hyperparameters 可从小模型 zero-shot 移到大模型；**竟在 Transformer 实验中用 40M proxy 调参，迁移到 6.7B GPT-3 规模并优于公开基线，同时大幅降低 tuning cost。** [R7]

7. Batch Size $\times$ LR：Schedule 不是只关于 Step Number

Batch size 影响 gradient noise；因此改变 global batch size 后，不应假定原 LR schedule 在统计意义上完全等价。Smith 等早期工作展示，在多个 optimizer 上，某些情况下可以用“增大 batch size”替代“衰减 LR”，说明二者都在改变噪声/更新动态。[R3] 但这不是 LLM 中可直接照搬的线性规则。

变化	若 Schedule 仍按 steps	潜在后果	更稳妥做法
Global batch $\times 2$	每个 step token $\times 2$	同样 warmup steps 实际 warmup tokens $\times 2$	优先按 samples/tokens 定义 warmup/decay
Gradient accumulation 改变	optimizer-step 频率改变	LR 时间轴与 data exposure 不一致	记录 optimizer steps 与 seen tokens 双轴
Sequence length 改变	tokens/sample 改变	sample-based 与 token-based schedule 语义分离	长上下文阶段明确重标 schedule
Data curriculum 改变	gradient statistics 变化	原 peak LR 可能不再稳定	阶段切换前做 LR/grad/update 监控

Megatron 当前 scheduler 配置同时支持 iteration-based 和 sample-based warmup/decay，并明确要求二者不要混用；这正体现了 schedule timebase 是训练语义的一部分，而不是日志展示单位。[R13]

8. Resume / Continued Pretraining：要不要 Rewarm？

如果只是同一训练 run 因故障从 checkpoint 恢复，通常应恢复 optimizer state + scheduler state，保持原训练轨迹；如果进入新的 continued-pretraining 数据阶段，则问题不同：新数据分布可能需要更大的 LR 来提高学习效率。Gupta 等在 Pythia-410M 上研究“rewarming”，发现重新升高 LR 会先让上下游 loss 变差，但长期能改善新数据性能，甚至超过从 scratch 训练的比较方案。[R9]

场景	Scheduler 处理	原因
故障恢复 / 完全相同 run	恢复原 scheduler state	目标是保持数学等价轨迹
计划内 cosine 延长	不能简单“多跑”	原 horizon 已定到 decay 位置
WSD stable branch 延长	可继续 stable，再择时 cooldown	这是 WSD 的核心优势

场景	Scheduler 处理	原因
新 domain continual PT	考虑 rewarm / 新 peak LR	数据分布与 gradient statistics 已改变
长上下文 CPT	常需要新 LR + 新 length curriculum	序列长度变化改变优化与显存/批量结构

9. Schedule Ablation：怎样做才不会得到假的结论？

必须控制	为什么
同一 tokens / compute budget	否则 schedule 只是训练量不同
同一 peak LR 或分别充分调 peak LR	shape 与 peak LR 强耦合；两种比较回答不同问题
同一 min LR / endpoint 定义	cosine-to-10% 与 cosine-to-zero 并非同一 schedule
同一 warmup tokens	warmup steps 在不同 batch 下不可比
同一 optimizer / β / ϵ / WD	这些参数改变有效 update
同一 eval checkpoints	decay schedule 的优势往往集中在末期
同时看 base loss + downstream/SFT	2026 WSO 量差可能排序相反
至少一个更长 horizon	检验 schedule 对 horizon extension 的稳健性

推荐实验顺序

① 先找稳定 peak LR 区间 → ② 固定 warmup tokens 比较 cosine / linear / constant → ③ 再加入 WSD（不同 cooldown fraction）→ ④ 如果训练 horizon 不确定，评估 WSD/WSqD → ⑤ 对最终候选做 continued PT / SFT 适应性评测，而不只看最后一个 pretraining validation loss。

10. Production Blueprint：Learning-Rate Control Plane

组件	必须记录/持久化	常见故障
Scheduler Config	peak/min LR, warmup, decay style, horizon, timebase	checkpoint 只存 model 不存 scheduler
Runtime State	current step/samples/tokens, current LR	batch 改变后 schedule 时间轴漂移
Optimizer State	m/v/master params	恢复时 no-load-optim 导致轨迹不连续
Observability	LR, grad norm, update RMS, loss, spike flags	只监控 loss 看不到 update 异常
Checkpoint Policy	stable checkpoint + cooldown checkpoint	只保留终局模型，无法继续训练
Experiment Registry	schedule + peak LR + warmup tokens + batch	无法复现实验或公平比较

11. 方法选择：一个可操作的决策表

你的目标	优先考虑	原因
固定预算、追求低 final pretrain loss	Linear-to-zero / Cosine-to-low LR	成熟；局降明
训练预算可能继续追加	WSD	stable branch 易延长并分叉 cooldown
希望 single mother checkpoint 后续多次 CPT/SFT	WSD stable / WSO 候选	避免早入低 LR / sharp terminal basin
需要 horizon-independent baseline	Inverse-sqrt / WSqD（研究性）	时间轴对最终 horizon 依赖更弱
跨模型规模调 LR 成本太高	μ P/ μ Transfer + proxy sweep	提高 hyperparameter transferability
batch/seq length 会显著变化	token/sample-based scheduler	让 LR 时间轴跟数据 exposure 对齐

最终 Know-why

Learning Rate Schedule 本质上是“训练过程中可接受参数位移随时间的预算函数”。Warmup 解决早期稳定进入高效区；主体阶段决定探索/学习速度；Decay/Cooldown 局降低 loss；而 WSD/WSO/WSqD 等新方向则开始把“最终收敛”和“可持续学习”拆成不同目标。

参考资料与证据等级

编号	资料	证据性质
[R1]	Vaswani et al., Attention Is All You Need, 2017. 原始 Transformer warmup + inverse-square-root LR.	经典/同行评审
[R2]	Loshchilov & Hutter, SGDR: Stochastic Gradient Descent with Warm Restarts, 2016/ICLR 2017. Cosine annealing.	经典/同行评审
[R3]	Smith et al., Don' t Decay the Learning Rate, Increase the Batch Size, 2017/ICLR 2018.	经典/同行评审
[R4]	Hoffmann et al., Training Compute-Optimal Large Language Models (Chinchilla), 2022. Appendix B / cosine horizon 与目标 token 匹配。	高质量实证
[R5]	Hu et al., MiniCPM: Unveiling the Potential of Small Language Models with Scalable Training Strategies, 2024. WSD / μ P experiments.	论文/大规模实验
[R6]	Wen et al., Understanding Warmup-Stable-Decay Learning Rates: A River Valley Loss Landscape Perspective, 2024.	论文/理论+实证
[R7]	Yang et al., Tensor Programs V: Tuning Large Neural Networks via Zero-Shot Hyperparameter Transfer, 2022.	经典/ μ P
[R8]	Bergsma et al., Straight to Zero: Why Linearly Decaying the Learning Rate to Zero Works Best for LLMs, 2025.	预印本/大规模实证

编号	资料	证据性质
[R9]	Gupta et al., Continual Pre-Training of Large Language Models: How to (re)warm your model?, 2023.	论文/continued PT
[R10]	Qwen Team, Qwen2.5 Technical Report, 2024. Hyperparameter scaling law for optimal LR/batch.	技术报告
[R11]	Yano et al., Pre-training LLM without Learning Rate Decay Enhances Supervised Fine-Tuning, ICLR 2026.	同行评审/新结果
[R12]	Ma & Chen, WSqD: A Horizon-Free Learning Rate Schedule for Large Model Training, 2026-07.	最新预印本
[R13]	NVIDIA Megatron Bridge/Core documentation, Optimizer and Scheduler Configuration, 2026. constant/linear/cosine/inverse-sqrt/WSD + sample/iter timebase.	官方实现文档
[R14]	DeepSeek-AI, DeepSeek-V3 Technical Report, 2024. AdamW/optimizer recipe 与稳定训练背景。	技术报告

证据解读说明：本文把 2025-2026 的新 schedule 结果与较成熟的 Transformer/Chinchilla/ μ P 结论分开标记。新论文中的具体 speedup / compute-saving 数值应视为其特定模型、数据、optimizer 与超参环境下的实验结果，而不是普适保证。