

LLM 预训练之 Position Encoding

Positional Representation / RoPE / Long-Context Scaling • 深度研究手册

从 Absolute / Relative Position 到 RoPE，再到 PI、YaRN、LongRoPE、LongRoPE2：位置如何进入 Attention，以及为什么“可输入更长”不等于“有效上下文更长”

核心视角：Position Encoding 是 Attention 的坐标系与频率系统

Research cut-off: 2026-08-13 | 01-B-Agent


执行摘要：Position Encoding 不只是“告诉模型第几个 token”

纯 self-attention 在没有额外结构时并不会天然拥有完整的序列坐标系。Position Encoding 的任务，是让 Attention 对“顺序、距离、平移、远近和超出训练长度的新位置”产生可学习且稳定的差异。对现代 decoder LLM，它还直接决定长上下文扩展是否需要修改 Q/K 几何、attention bias、RoPE frequency，甚至是否需要重新训练一段长上下文数据。

核心判断	Know-why	工程含义
位置方法的关键不是名字，而是“注入位置”	加到 embedding、attention score、Q/K rotation 的优化行为不同	A/B 时必须固定其余 attention recipe
相对位置通常更适合生成式 LLM	语言依赖常与 token 间距离/顺序有关，而非绝对索引本身	RoPE / relative bias 成为主流路线
RoPE 的本质是多频率相位系统	每对 Q/K 维度拥有不同旋转速度	theta/base、head dim、训练长度共同决定可用频率范围
长上下文不是 max_position_embeddings 配置项	位置 OOD、频率训练不足、数据长度不足都会造成失效	必须用真实长任务和 position-wise metrics 验证
“统一缩放”正在演进到“频率感知缩放”	不同频率维度在长距离上承担不同角色	YaRN/LongRoPE/LongRoPE2 对频率采用非均匀处理
短上下文保真与长上下文扩展是双目标	扩展可能损伤原训练区间分布	mixed-context training / short-context recovery 很重要

最重要的 Know-why “能生成某个位置的 sin/cos 或 RoPE angle” 只说明数学函数可计算；不说明模型在该位置的 hidden-state distribution、attention geometry 和 retrieval/reasoning 能力仍处于训练分布内。

Position Encoding 的统一视角：位置到底被注入到哪里？



同样叫“位置编码”，实际注入位置完全不同：加到 token embedding、加到 attention score、旋转 Q/K，或对 RoPE 频率进行重标定。

图 1 Position Encoding 的方法差异首先体现在位置被注入到模型的哪里。

1. 为什么 Transformer 必须处理 Position

原始 Transformer 去掉 recurrence 与 convolution 后，作者明确指出必须向模型注入 token 的相对或绝对位置，并采用不同频率的正弦/余弦编码；论文同时实验了 learned positional embeddings，结果近似，但选择 sinusoidal 的理由之一是希望能外推到训练时未见过的更长序列。 [1]

需求	真正要表达什么	坏设计的典型症状
Order sensitivity	A→B 与 B→A 不应等价	词序变化后表示近似不变
Relative distance	“相邻/相隔 1000 token” 应可区分	长依赖 attention 无法稳定定位
Translation robustness	整段文本整体右移不应改变语义	padding / offset 导致异常

需求	真正要表达什么	坏设计的典型症状
Length interpolation	训练范围内不同长度都能工作	靠近最大训练长度性能先下降
Length extrapolation	测试长度 > 训练最大长度仍稳定	PPL 爆炸、检索随位置剧烈退化
Cache compatibility	自回归 KV cache 中位置更新要廉价	增量推理需要重复改写历史 state

Haviv 等的 NoPE 实验提醒我们：在 causal LM 中，即使不显式加入 position embedding，模型也可能从 causal mask 的“可见前驱数量”等结构中恢复一部分绝对位置信息。因此，显式位置编码并不是位置感知的唯一来源；但这并不意味着生产级 LLM 可以忽略位置设计。[7]




图 2 Sinusoidal 通过多频率绝对坐标加到输入；RoPE 则把 position 转化为 Q/K 的相位旋转。

2. Absolute Position：简单、直接，但外推边界明显

方法	公式/机制	优点	局限
Learned Absolute	$h_{pos} = token_embed + P[pos]$	简单；可自主学习每个位置	超出训练位置没有参数；平移不变性弱
Sinusoidal	$\sin/\cos(pos / 10000^{(2i/d)})$	无额外 position 参数；任意位置可计算	数学可计算不等于模型真正外推
Position at input only	只在 block 0 注入	实现与 cache 最简单	深层 position signal 完全依赖网络传播

绝对位置方法最大的概念问题是：模型容易把“位置 1024”当作一个特定坐标，而不是“与当前 query 相距 37”。对自回归语言建模，很多依赖关系天然更像相对距离问题，因此 2018 年后研究开始把相对位置直接放进 Attention。

3. Relative Position：从 Shaw RPE 到 Transformer-XL / T5

Shaw 等将相对距离表示直接引入 self-attention，在 WMT14 英德/英法翻译上相对 absolute position 分别报告 +1.3 与 +0.3 BLEU，并发现再叠加 absolute position 没有进一步收益。[2]

Transformer-XL 在 segment recurrence 的同时重新设计 relative positional encoding，以避免把缓存片段的绝对位置当成当前片段坐标；其核心思想是让 attention 更关注 query-key 的相对位移。[3]

T5 采用 learned relative position bias，把距离 bucket 映射成每个 attention head 的 scalar bias。这条路线非常重要：位置不再修改 token representation，而是直接改变 attention logits。[4]

路线	位置注入点	参数形态	对长上下文的直觉
Shaw RPE	QK / value relation	relative distance embedding	显式建模 i-j，但 naive 成本较高

路线	位置注入点	参数形态	对长上下文的直觉
Transformer-XL	attention decomposition	relative term + content term	适合 segment recurrence / memory
T5 relative bias	attention logits	bucket -> head bias	大距离可 bucket 化，但超长外推仍需验证
ALiBi	attention logits	固定 head slope $\times$ distance	不需要位置 embedding table，天然带 recency bias

4. ALiBi：用 Attention Bias 做“Train Short, Test Long”

ALiBi 不向 token embedding 加位置向量，而是在 query-key attention score 上加入与距离成比例的惩罚。其论文在 1.3B 模型上用 1024 长度训练、2048 长度测试，达到与 2048 长度 sinusoidal baseline 相同的 perplexity，同时报告训练快 11%、内存少 11%。[6]

Know-why ALiBi 的外推优势来自一个非常强的 inductive bias：距离越远，score 越被惩罚。这让“新位置”不会引入未见过的独立 embedding；但它也可能限制真正需要超长距离强依赖的场景。

优点	代价 / 注意点
实现简单；无需 position table / RoPE cache	距离惩罚是固定结构，不一定适合所有任务
长度外推行为清晰	过强 recency bias 可能压制远距离 dependency
与标准 causal attention 兼容	今天主流大模型更多采用 RoPE，而不是 ALiBi
无需修改 token embedding	不同 head slope 的设计本身就是超参数

5. RoPE：为什么它成为现代 Decoder LLM 的主流

RoPE 对 Q/K 的二维维度对施加与位置成比例的旋转。RoFormer 的关键性质是：虽然每个 token 使用绝对 position 产生 rotation，但 Q_m 与 K_n 的内积只依赖相对位移 $m-n$ ，因此同时获得绝对相位与显式相对位置结构。[5]

对第 i 个维度对，可把角频率写成 $\theta_i = \text{base}^{(-2i/d_{\text{head}})}$ 。位置 m 的二维向量旋转 $m \cdot \theta_i$ 。于是： $\langle R(m)q, R(n)k \rangle = \langle q, R(n-m)k \rangle$ 。这就是 RoPE 最核心的一行数学。

RoPE 设计量	控制什么	过小/过大或配置错误的影响
base / rope_theta	整套频率谱的尺度	改变低频波长；与目标 context length 强相关
head_dim	可用 frequency pairs 数量	维度越多，频率分辨率越丰富，但训练覆盖也更复杂
partial_rotary_factor	多少 Q/K 维度参与旋转	保留一部分 content-only dimensions；不同模型选择不同
position_ids	每个 token 的相位坐标	packing / reset / cache 不一致会直接破坏 attention
attention scaling	缩放后 softmax 的幅度校准	某些扩展算法需同步调整 attention factor




图 3 RoPE 不是单一频率：高频维度快速旋转、低频维度对应超长波长。长上下文扩展本质上是在重新安排这套频谱。

6. RoPE 为什么在训练长度之外会坏

常见解释“position 超出训练范围，所以 OOD”是对的，但还不够。更精确地说，RoPE 的每个频率维度都有不同周期；模型在训练长度内只见过某些相位组合。测试长度扩大后，一些维度进入从未充分训练的相位区间，attention kernel 的分布会变化。

失效机制	直觉	研究证据
Phase OOD	相位组合超出训练覆盖	PI 论文指出直接外推可能产生灾难性 attention score [9]
Frequency under-training	高/低频维度在训练长度内暴露不足	LongRoPE2 将 higher RoPE dimensions 的 insufficient training 作为核心假设 [15]
Long-term decay / oscillation	远距离内积分分辨率下降或振荡	xPos、Base-of-RoPE、2025 dimension-inefficiency 分析 [8][12][17]
Hidden-state OOD	即使位置函数可算，层间状态仍离开训练分布	长上下文 CPT 常仍有必要
Attention pattern mismatch	训练只见短依赖，推理要求远距离检索/推理	仅 NIAH 成功也不代表 reasoning 成功

Scaling Laws of RoPE-based Extrapolation 从周期角度研究 base 与 tuning context length 的关系，并报告在 LLaMA2 上用 16K 训练长度实现到 1M 的外推实验；Base of RoPE Bounds Context Length 则进一步提出 base 对可支持 context length 存在理论/经验下界。[11][12]

7. Position Interpolation：为什么“压回训练区间”比直接外推稳定

Position Interpolation (PI) 的核心不是让模型学习全新的 32K 位置，而是把 32K 的 position index 线性压缩回原始训练区间，再用少量 fine-tuning 适配。论文把 LLaMA 7B-65B 的 context 扩到 32K，fine-tuning 少于 1000 steps，并给出理论分析：其 interpolation attention-score 上界至少约比 direct extrapolation 小 $600\times$ 。[9]

直接外推	Position Interpolation
position 0...L_new 原样进入 RoPE	position 乘 $L_{\text{train}}/L_{\text{new}}$ 后再进入 RoPE
新相位大量落在训练外	相位被压回原训练范围
局部位置分辨率保持原样，但 OOD 强	稳定性更高，但相邻 position 被压得更近
可能出现 catastrophic score	通常需要短量 long-context fine-tune 重新校准

关键 Trade-off PI 用“位置分辨率”换“分布稳定性”。当压缩比很大时，高频/低频维度不应一视同仁，这正是后续 NTK-aware、YaRN、LongRoPE 一类方法继续改进的方向。

8. Dynamic NTK / YaRN：统一缩放 -> 频率分段

社区与主流框架中常见的 Dynamic NTK 会根据目标长度动态修改 RoPE base，使频率谱整体变慢。它比简单 linear scaling 更保留局部分辨率，但它本身更像一类工程配方而不是单一“定理”。Hugging Face Transformers 当前把 default、linear、dynamic、yarn、longrope、llama3 都作为可配置 RoPE 类型。[16]

YaRN 在 PI / NTK-by-parts 思路上进行频率分段：对不同旋转频率采用不同插值/外推策略，并配合 attention scaling。论文报告相比此前方法需要少 $10\times$ tokens、少 $2.5\times$ training steps；2026 修订版仍保留这一结论。[10]

方法	核心操作	更适合解决什么
Linear / PI	所有 position 统一压缩	稳定、简单、低成本扩展
Dynamic NTK	按目标长度调整 frequency base	保持更多局部分辨率
NTK-by-parts / YaRN	按频率区间混合 interpolation / extrapolation	高低频需求不同
Attention factor	同时校准 attention magnitude	避免改变频率后 softmax 温度失衡

9. LongRoPE：逐维搜索 + Progressive Extension

LongRoPE 不再假设所有 rotary dimensions 应共享一个缩放规则，而是利用 position interpolation 中的非均匀性，对逐维 scaling factor 进行搜索；随后先扩到 256K，再通过第二次 positional interpolation 推到 2048K，并单独做 8K readjustment 以恢复短上下文性能。论文报告在 LLaMA2/Mistral 上可到 2048K，最多只需约 1000 fine-tuning steps、训练长度不超过 256K。[13]



演进方向：从“所有频率统一缩放”走向“频率分段 / 逐维搜索 + 长短上下文混合训练 + 以真实检索能力驱动的标定”。

图 4 RoPE 长上下文扩展的演进：统一位置缩放 -> 频率感知 -> 逐维搜索 -> 混合上下文训练。

10. LongRoPE2：从“位置 OOD”转向“频率训练不足”

LongRoPE2 的关键假设是：持续 OOD 问题不只是“新 position index”造成，而与更高 RoPE dimensions 在预训练中没有被充分训练有关。它使用 needle-driven perplexity 指导 evolutionary search 选择 rescaling，并用 mixed context window training 同时适配长序列与原始短序列。[15]

其论文报告把 LLaMA3-8B 扩到 128K effective context，保留超过 98.5% short-context performance，只使用 10B tokens；作者称这比 Meta 的对应扩展训练 token 少 80×。这些数字来自该论文自身实验，适合视为方法级证据，不应直接泛化到任意模型/数据。[15]

2025-2026 的趋势 “长上下文扩展”越来越像一个小型系统工程：RoPE rescaling + mixed-length data + retrieval-driven calibration + short-context recovery，而不是修改一个 rope_theta 就结束。

11. Llama 3.1 / Hugging Face：工业实现如何表达 RoPE Scaling

Llama 3 Herd 论文公开的最大 context window 为 128K。Hugging Face Transformers 目前把 Llama3.1 scaling 单独实现为 `rope_type="llama3"`，参数包括 `factor`、`original_max_position_embeddings`、`low_freq_factor` 与 `high_freq_factor`：高频部分保持、低频部分缩放，中频做平滑过渡。[14][16]

HF rope_type	主要参数	理解方式
default	<code>rope_theta</code>	原始 RoPE
linear	<code>factor</code>	<code>position / factor</code>
dynamic	<code>factor</code> , <code>original_max_position_embeddings</code>	随目标长度动态调整 base
yarn	<code>factor</code> , <code>beta_fast</code> , <code>beta_slow</code> , <code>attention_factor</code>	按频率区间处理 + attention calibration
longrope	<code>short_factor[]</code> , <code>long_factor[]</code>	逐维短/长 context scaling factors
llama3	<code>low_freq_factor</code> , <code>high_freq_factor</code> , <code>factor</code>	低/中/高频分段缩放

这个实现细节很重要：工业框架已经把 RoPE 从“一个 theta 常量”演进成独立配置子系统。对训练框架，`position_ids`、`rope cache`、`KV cache`、FlashAttention kernel、`tensor parallel` 都要共享同一套 RoPE semantics。

12. Sequence Construction 与 Position Encoding 的耦合

Sequence 侧操作	Position Encoding 必须明确的语义	常见 Bug
多文档 packing	跨文档 position 是否连续	EOS 后 position 意外 reset / 不 reset 与 attention mask 不一致
intra-document mask	position 可连续但 attention 逻辑隔离	物理 sequence 与逻辑 context 混淆
position reset	每个 document 从 0 开始	KV/cache 与训练 <code>position_ids</code> 语义不同
variable length	不同 batch 使用不同 L	RoPE cache 长度不足或 dynamic scaling 不一致
long-context CPT	训练长度逐步扩展	只改 RoPE 不改变长度分布，模型仍没学远距离任务

Know-how Position Encoding 的单元测试不能只检查数值 shape。要同时验证：`position_ids`、`attention mask`、`packing boundary`、`cache_position`、`incremental decode` 与 `full-sequence forward` 是否严格一致。


13. Position Encoding 与 KV Cache / 推理系统

RoPE 通常在写入 K/V cache 前对 Q/K 应用 rotation，因此历史 K 可以直接复用；但 scaling 类型、position offset、cache position 一旦在 prefill 与 decode 阶段不一致，会造成难以察觉的生成质量退化。ALiBi 则主要在 attention score 阶段按 query-key distance 生成 bias，不需要旋转历史 K。

系统问题	RoPE	ALiBi / Bias-based
KV cache 内容	缓存已经旋转后的 K/V（实现依赖）	K/V 本身无位置旋转
增量 decode	必须准确维护 absolute/cache position	计算 distance bias
Context extension	改 frequency / scaling config	bias 公式通常无需新 position table
Kernel integration	FlashAttention 等需正确传 position/cos/sin	attention bias kernel 需支持 slope/bias
错误表现	通常不是 crash，而是 silent quality drop	同样可能 silent degradation

14. 如何正确评测“有效上下文”

长上下文 Position Encoding 的正确评测矩阵



“最大可输入长度”只是配置项；Effective Context 必须用多维评测证明。

图 5 最大可输入长度不是能力证明；长上下文 Position Encoding 至少应覆盖保真、PPL、检索、推理、代码和系统成本。

评测层	指标/任务	为什么需要
Short retention	原长度 PPL / MMLU / code baseline	发现 scaling 对原能力的损伤
Position-wise LM	按 token position 统计 NLL/PPL	找到从哪个位置开始退化
Synthetic retrieval	Passkey / Needle / KV retrieval	验证“能找回来”，但不能代替 reasoning
Lost-in-the-middle	答案放在不同百分位	检测中间位置 attention/retrieval 弱化
Multi-doc reasoning	跨文档 QA / aggregation	验证远距离组合而非单点复制
Long code	repo / long file completion	更接近真实结构化依赖
Length sweep	8K/16K/32K/...	寻找 effective context 而非只报最大长度
System	prefill latency, memory, throughput	长上下文能力必须可服务

2025 年研究指出 RoPE 在超长距离检索中可能造成部分 attention-head dimensions 利用率降低；另一项 layer-specific scaling 工作则把 lost-in-the-middle 与 RoPE 长程 decay 联系起来，并在其 key-value retrieval 设置中报告最高约 20% 平均准确率提升。这些结果提示：统一层级、统一频率的 scaling 可能并非最终形态。[17][18]

15. 2026 前沿：RoPE 仍在被重新解释

2026 年的 phase-modulation 理论工作把 RoPE 解释为一组复数振荡器，并从 aliasing、低频 phase drift、网络深度与有限浮点精度推导 base 的上下界。它提出“Goldilocks zone”式的可行区间。这是新的理论预印本，应视为前沿解释框架，而不是已经确立的工业定律。[19]

同年也出现更广泛的方向：让位置频率随 layer/head/context 动态变化，重新利用标准 RoPE 丢弃的复数相位分量，甚至尝试无显式 position encoding 的 hybrid state-space/attention 模型。核心趋势是：Position 不再被看成一个固定 preprocessing 常量，而是可学习、可调度、可分层的模型组件。

16. Production Position-Encoding Blueprint

阶段	推荐动作	产物
1. Base choice	新模型优先在 RoPE / relative-bias 类方法中做 proxy pretrain	method shortlist + baseline
2. Frequency design	联合选择 rope_theta、head_dim、partial rotary factor	frequency coverage report
3. Sequence integration	定义 packing / reset / cache_position 语义	position contract

阶段	推荐动作	产物
4. Short pretrain ablation	相同 token/compute 比较 short PPL + length sweep	base PE decision
5. Extension target	定义 32K/128K/1M 的真实任务需求	target context spec
6. Scaling search	linear/dynamic/YaRN/LongRoPE 类方法做搜索	candidate configs
7. Mixed-length CPT	长短样本联合，避免 short regression	extended checkpoint
8. Eval matrix	PPL + retrieval + reasoning + code + system	effective-context report
9. Serving validation	prefill/decode cache parity + kernel parity	production sign-off

Production 原则 不要先问“怎么把 8K 改成 128K”，先问“目标任务在 128K 里需要什么依赖模式、训练数据是否覆盖这些模式、Position Encoding 哪些频率会 OOD、以及我们愿意牺牲多少 short-context 与 serving efficiency”。

17. 常见失败模式与 Debug Checklist

失败模式	表象	优先排查
RoPE config 只在 inference 改	能跑 128K，但质量迅速下降	训练 length distribution / CPT 是否匹配
position_ids 与 packing 不一致	某些 batch loss spike / 长文本异常	document reset 与 attention boundary
prefill/decode offset bug	前几 token 正常，续写后变差	cache_position / rotary offset
只看 NIAH	检索很好但 QA/代码差	增加 reasoning / aggregation / long code
短上下文回归	32K+ 变好，8K benchmark 下降	mixed-context training / short readjustment
统一 factor 过激	局部 token order 分辨率下降	频率分段 / YaRN / search-based scaling
rope_theta 越大越好	长距离可能改善但局部/数值行为异常	做 base × length × layer sweep
配置声明长度 = 有效长度	max_position_embeddings 很大	position-wise PPL + task sweep

18. Know-Why / Know-How 总结

问题	Know-why	Know-how
为什么要 Position Encoding?	attention 本身只做内容相似性，顺序需要额外结构	把 order/distance 设计成稳定的 attention inductive bias
为什么 RoPE 有效?	绝对位置旋转后，QK 内积自然变成相对相位差	在 Q/K 上旋转，不污染 V；与 KV cache 兼容
为什么 RoPE 会外推失败?	训练只覆盖部分相位/频率组合；隐藏状态与 attention 也 OOD	监控 frequency coverage 与 position-wise degradation
为什么 PI 有效?	把新位置压回训练过的相位范围	用少量 CPT 恢复局部分辨率与下游能力
为什么 YaRN/LongRoPE 更进一步?	不同频率维度不应统一缩放	按频率分段或逐维 search；同步 attention scaling
为什么还需要 long-context data?	PE 只提供坐标，不教模型如何使用远距离信息	mixed-length CPT + retrieval/reasoning/code data
为什么要保 short context?	扩展改变 attention geometry，可能损伤原分布	短长混合训练 + retention gate
为什么 max context 不是能力?	配置只说明张量能算，不说明信息能被有效利用	报告 effective context curve，而不是单点长度

一句话沉淀 Position Encoding 的工程目标不是“给 token 一个位置编号”，而是为 Attention 构造一个在训练区间内可学习、在目标长度内可泛化、在 KV Cache 中可复用、并且不会牺牲短上下文能力的坐标与频率系统。

参考资料与证据等级

- [1] Vaswani et al., Attention Is All You Need, 2017 [基础论文] [source](#)
- [2] Shaw et al., Self-Attention with Relative Position Representations, 2018 [同行评审 / NAACL] [source](#)
- [3] Dai et al., Transformer-XL, 2019 [同行评审 / ACL] [source](#)
- [4] Raffel et al., T5, JMLR 2020 [同行评审 / JMLR] [source](#)
- [5] Su et al., RoFormer / RoPE, 2021 [核心 RoPE 论文] [source](#)
- [6] Press et al., ALiBi: Train Short, Test Long, 2021 [同行评审 / ICLR 2022] [source](#)
- [7] Haviv et al., Transformer LMs without Positional Encodings, 2022 [机制研究] [source](#)
- [8] Sun et al., A Length-Extrapolatable Transformer (xPos), 2022 [研究论文] [source](#)
- [9] Chen et al., Positional Interpolation, 2023 [长上下文基础方法] [source](#)
- [10] Peng et al., YaRN, 2023 / rev. 2026 [长上下文方法] [source](#)
- [11] Liu et al., Scaling Laws of RoPE-based Extrapolation, 2023 [RoPE scaling 研究] [source](#)
- [12] Men et al., Base of RoPE Bounds Context Length, 2024 [RoPE base 理论/经验] [source](#)
- [13] Ding et al., LongRoPE, 2024 [长上下文方法] [source](#)
- [14] Meta, The Llama 3 Herd of Models, 2024 [官方模型技术报告] [source](#)
- [15] Shang et al., LongRoPE2, ICML 2025 [同行评审 / ICML] [source](#)
- [16] Hugging Face Transformers, RoPE Utilities [官方实现文档] [source](#)
- [17] Chiang & Yogatama, RoPE Dimension Inefficiency, 2025 [近期机制研究] [source](#)
- [18] Wang et al., Layer-Specific Scaling of Positional Encodings, 2025 [近期研究] [source](#)
- [19] Liu, Rotary Positional Embeddings as Phase Modulation, 2026 [前沿预印本，需谨慎泛化] [source](#)

注：本文将 2025-2026 的新预印本与经典/同行评审论文明确区分。前沿结果用于识别研究趋势，不作为未经复现即可直接应用到任意基础模型的生产定律。