

LLM 预训练之 Transformer Stack

Block Architecture / Residual Stream / Normalization / Depth Scaling • 深度研究手册

把 Attention、MLP、Norm 与 Residual 重新组装成可训练的深层系统：为什么“重复 N 个 Block”是最危险的过度简化

核心视角：Transformer Stack = residual state machine + repeated feature routing/transform + scale-control system

Research cut-off: 2026-08-13 | 01-B-Agent

执行摘要：Transformer Stack 真正要解决什么

当 Attention 与 MLP 单独看都“能工作”时，把它们堆成几十、几百甚至上千层仍可能失败。原因是 Stack 引入了递归：每层都在读取 residual stream、产生 update、再把 update 写回同一条状态通道；同时梯度必须沿着这条深链反向传播。于是 normalization placement、residual topology、初始化、残差尺度和优化器共同决定模型能否稳定训练。

核心问题	Know-why	工程含义
Residual Stream 如何保持可用	每层都在同一状态通道上做 additive update	监控 residual RMS、update/residual ratio、层间漂移
Norm 放在哪里	Pre/Post/Peri-LN 改变 identity path 与梯度路径	Norm topology 是训练稳定性的架构变量，不只是算子选择
LayerNorm 还是 RMSNorm	RMSNorm 去掉 re-centering，计算更简单	现代 decoder LLM 常以 RMSNorm 作为成熟起点
串行还是并行 block	Attention→MLP 的依赖决定关键路径	PaLM parallel block 可减少依赖并提升吞吐
深度如何扩展	增加层数增加 sequential computation 与梯度路径长度	Depth/width 需在质量、延迟、通信、稳定性间联合搜索
超参数如何随规模迁移	大模型无法为每个 LR/init 重做完整 sweep	$\mu P/\mu Transfer$ 等方法把“scale consistency”本身变成设计目标

最重要的 Know-why Transformer Stack 的训练稳定性不是某一个 LayerNorm 的属性，而是 Residual Topology × Normalization × Initialization × Optimizer × Depth 的系统属性。只盯 loss curve，往往只能看到“已经出问题”，看不到问题从哪一层开始累积。

Normalization placement 改变的不是“有没有归一化”，而是残差路径与梯度路径




图 1 Post-LN、Pre-LN 与 Peri/Sandwich-LN: Normalization placement 改变了 residual shortcut 与 sublayer 的相对位置。

1. Block Anatomy：一个 Decoder Block 到底包含哪些状态转换

对现代 decoder-only LLM，可把一个 block 抽象成两次“读取 residual → 计算 update → 写回 residual”。最常见 Pre-Norm 形式为：

$$h' = h + \text{Attention}(\text{Norm}(h)) \quad ; \quad h'' = h' + \text{MLP}(\text{Norm}(h'))$$

这里真正贯穿所有层的不是 Attention output 或 MLP hidden，而是 residual stream h 。每个子层只生成一个增量 update；下一层再从更新后的 h 中读取。这个视角比“第 17 层在做语法、第 38 层在做推理”更适合作为工程起点。

组件	读什么	写什么	Stack 级风险
Norm	当前 residual state	归一化后的计算输入	scale/variance 不受控会扩散到后续层
Attention	Norm 后 token states	跨 token 的 context update	logit/attention outlier、长上下文放大
MLP	Norm 后 token state	position-wise feature update	gated activation spike、FFN output 过大
Residual Add	旧 state + update	新 residual state	update 太大破坏 shortcut；太小导致有效深度不足

2. Residual Stream：为什么它是整个 Stack 的“状态总线”

Residual connection 的价值不是单纯“防止梯度消失”。它建立了一个近似 identity 的高速通道：如果某一层的 Attention/MLP 暂时学不好，模型仍可以沿 shortcut 保留此前表示；训练时，参数更新也不必让每层都重新编码全部状态。

Takase et al. 2023 从 Jacobian spectral norm 视角分析 LLM pretraining loss spike，把稳定条件概括为“small sublayers + large shortcut”：子层更新不应在初期压过 residual 主干。[10]




图2 概念示意：深层 Stack 的核心不是单个层的数值，而是 residual scale 与 gradient flow 随深度如何演化。图中曲线为机制示意，不是任何论文的实测数据。

Know-how 建议给每一层记录：residual RMS、Attention update RMS、MLP update RMS、update/residual ratio、post-add RMS、gradient norm、parameter update/weight ratio。深度问题往往先表现为“少数层逐渐变成异常放大器”。

3. LayerNorm vs RMSNorm：Normalize 什么，决定保留什么不变量

LayerNorm 对每个 token 的 hidden vector 做 re-centering 与 re-scaling；RMSNorm 则只按 root mean square 做 re-scaling，不减均值。RMSNorm 论文的核心假设是 re-centering invariance 并非必须，并在多种网络上得到与 LayerNorm 相当的效果，同时简化计算。[3]

Norm	简化形式	保留的核心不变量	LLM 工程含义
LayerNorm	$(x - \text{mean}) / \text{std} * \gamma + \beta$	平移 + 尺度归一	表达最经典，但计算/参数略更多
RMSNorm	$x / \text{RMS}(x) * \gamma$	尺度归一	bias-free decoder LLM 常见；实现简单、融合友好
No/Implicit Norm	靠参数化与约束控制状态	取决于架构	nGPT 等前沿架构把归一化嵌入整个参数/状态几何

不要把 RMSNorm 的优势简化成“少算一个 mean 所以更快”。在大模型里，Norm 本身 FLOPs 占比通常不高；更重要的是它适配 bias-free、Pre-Norm、fused kernel 和稳定 scale control 的现代 block recipe。

4. Post-LN → Pre-LN：为什么现代 decoder LLM 发生了架构迁移

原始 Transformer 使用 Post-LN。Xiong et al. 2020 用 mean-field 理论分析指出：Post-LN 在初始化时靠近输出层的参数梯度期望值更大，较大的 learning rate 容易带来不稳定，因此 warmup 很关键；Pre-LN 把 Norm 放进 residual branch 后，初始化梯度更平滑，可显著降低对 warmup 的依赖。[1][2]

维度	Post-LN	Pre-LN
形式	$\text{Norm}(x + F(x))$	$x + F(\text{Norm}(x))$
Identity shortcut	每层输出必须再过 Norm	shortcut 更直接
深层训练	容易出现梯度传播困难	优化稳定性通常更好
表达/有效深度争议	经典架构，部分工作认为表达利用更充分	部分研究观察到深层表示变化可能减弱
现代 decoder LLM	较少作为纯默认	长期主流默认

关键 trade-off Pre-LN 的优势首先是 optimization；它不自动意味着“最终表达能力永远优于 Post-LN”。DeepNorm、ResiDual、Peri-LN、Keel 等后续工作，恰恰都在尝试同时拿到更好的深层优化与更强的表示利用。

5. DeepNorm / ResiDual / Magneto：如何让深层 Transformer 不靠运气

DeepNet 2022 提出 DeepNorm：修改 residual connection 并配合理论推导的初始化，使模型更新有界；论文将 Transformer 扩展到 1,000 layers（2,500 attention/FFN sublayers）。这是“极深 Transformer”路线的标志性结果。[4]

ResiDual 2023 将 Pre-LN 与 Post-LN 的 residual connection 融合，目标是同时避免 Post-LN 的梯度消失与 Pre-LN 的 representation collapse；Foundation Transformers / Magneto 则结合 Sub-LayerNorm 与 DeepNet-derived initialization，尝试形成跨模态通用的稳定 block。[7][8]

方法	主要改什么	核心目标	证据边界
DeepNorm	residual scaling + derived init	深度扩展时约束 model update	强于翻译/多语场景；对现代超大 decoder 需再验证
ResiDual	双 residual 路径	Pre-LN 梯度 + Post-LN 表达	以机器翻译等实验为主

方法	主要改什么	核心目标	证据边界
Magneto / Sub-LN	sub-layer norm + DeepNet init	跨任务稳定的统一 Transformer	覆盖多模态，但不是单一 decoder-LM 最终定论

6. Sandwich / Peri-LN：2024-2025 的 Normalization 再平衡

Gemma 2 明确报告每个 Attention 和 FFN sublayer 同时使用 pre-norm 与 post-norm RMSNorm；其技术报告把这一设计列为稳定训练的重要架构元素。[12]

Peri-LN 2025 将这类“在 sublayer 周围同时归一化”的拓扑系统化命名并分析。论文在最高 3.2B 参数实验中报告：相比 Pre-LN/Post-LN，Peri-LN 的 variance growth 与 gradient flow 更平衡。[13]

拓扑	直觉	可能收益	代价
Pre-LN	先控制输入 scale，update 直接加回 shortcut	易优化、成熟	residual variance 可随深度累积
Post-LN	add 后立刻重新规范状态	状态尺度受控、表达利用强	极深时梯度更难
Peri/Sandwich-LN	sublayer 输入与输出都规范	同时控制 update 输入/输出	增加 Norm 操作，长期 scaling 仍在研究

7. NormFormer：Pre-LN 稳了之后，梯度仍然不均匀

NormFormer 2021 发现 Pre-LN 仍存在层间 gradient magnitude mismatch：早层梯度明显大于后层。它在 self-attention 后、FFN 第一层后加入额外 normalization，并加入 per-head scaling；只增加约 0.4% 参数，却在其 1.3B baseline 上达到相同 perplexity 约快 24%。[5]

这说明“Pre-LN 能训练”与“所有层都以理想尺度训练”不是一回事。Stack 设计不能只问会不会 diverge，还要问各层是否在相似更新预算下有效学习。

诊断	仅看 loss 看不到什么	建议指标
早层过度更新	总 loss 仍可下降	per-layer grad norm / update ratio
后层学得慢	平均指标掩盖尾部层	layerwise activation drift / CKA / probe
Attention 与 MLP scale 不匹配	同层内部也可失衡	attn-update RMS vs mlp-update RMS

8. Serialized vs Parallel Block：Stack 也是关键路径设计

标准 serialized block 先计算 Attention，再把更新后的状态送进 MLP。PaLM 采用 parallel formulation：Attention 与 MLP 从同一 normalized input 计算，再一起加回 residual。论文报告在大规模训练上约 15% 更快；8B ablation 有小幅质量下降，但 62B 未观察到质量下降。[6]

Block topology 也影响吞吐：串行依赖 vs 可融合并行分支




图3 Serialized 与 Parallel block。Parallel 主要改变关键路径与 kernel fusion 机会，不等同于改变 Attention 或 MLP 本身。

维度	Serialized	Parallel
依赖	MLP 依赖 Attention 已更新的状态	Attention/MLP 同读一个 normalized state
critical path	更长	更短，可并行/融合部分 GEMM
表达	一层内先路由再变换	一层内两种 update 同时产生
工程	实现最普遍	需验证 kernel 与模型规模下质量/吞吐


9. Residual Scaling / Initialization：深层模型需要控制“每层写多大”

Admin 2020 指出 Transformer 的不稳定不应只归因于“不平衡梯度”，而与 residual branch 对输出扰动的 amplification effect 有关；其 Adaptive Model Initialization 在训练早期降低 residual dependency，随后允许模型利用更强的 residual branch。[9]

Spike No More 2023 将稳定性进一步归结为 small sublayers + large shortcut，并用 Jacobian spectral norm 分析 loss spikes。DeepNorm 则从另一方向给出深层残差 scaling 与初始化的理论 recipe。[10][4]

旋钮	作用	过大时	过小时
Weight init std	决定初始 sublayer 输出尺度	activation/update spike	信号太弱、学习慢
Residual scaling	控制每层 update 进入 shortcut 的幅度	深度累积/扰动放大	有效深度不足
Norm epsilon/gamma	控制归一化数值与可学习尺度	尺度漂移或低精度问题	表达/梯度受抑
LR + warmup	控制参数每步移动幅度	早期失稳/NaN	训练效率低

Transformer Stack Stability Control Plane



Stack 稳定性是系统属性：不能把 loss spike 或深层退化只归因于某一个 Norm。

图 4 Stack 稳定性控制面：拓扑、尺度、优化、可观测性需要联合设计。

10. μ P / μ Transfer：为什么 Stack 超参数不能每次扩大都重调

μ P / μ Transfer 的核心不是一个新的 Transformer block，而是一套 scale-consistent parameterization：让 learning rate、初始化等 optimal hyperparameters 在模型 width/size 改变时更稳定，从小 proxy model 调好的 HP 可以零样本迁移到大模型。Tensor Programs V 在 Transformer 上展示了这种迁移。[11]

传统 scaling	μ P/ μ Transfer 目标
模型变宽后重新 sweep LR/init	让参数化方式保持跨宽度的更新尺度一致
proxy model 只是便宜实验，但最优 HP 会漂	proxy model 成为可迁移的 tuning instrument
架构变化与 optimization 变化混在一起	先建立 scale-consistent baseline，再比较 block 设计

Know-how 如果要比较 Pre-LN / Peri-LN / DeepNorm / Parallel Block，最好不要同时让 LR、init、width parameterization 随规模任意漂移。否则大模型上的“架构胜负”可能只是某个 recipe 更接近它自己的稳定区间。

11. Depth vs Width：为什么“更深”不是免费能力

Depth 增加的是 sequential computation steps：同一 token 经过更多 Attention/MLP transformations。Width 增加的是每一步的 state / feature capacity。参数量相同并不意味着 latency、KV cache、通信和可训练性相同。

Petty et al. 2023 在固定参数规模的 Transformer LM 上比较 depth/width，观察到更深模型在 language modeling 与 compositional generalization 上通常更好，但收益快速递减；论文同时强调 latency 近似随层数线性增长，因此可以比常见配置更浅而不显著损失性能。[17]




图5 Depth 的表示收益与 sequential latency 的概念 trade-off。曲线是机制示意，不代表特定 scaling law。

增加 Depth	增加 Width
更多串行计算步骤	每一步更高维表示/更宽矩阵
推理 latency 更敏感	单层 GEMM 更大但可并行
更长梯度路径与 residual recursion	更高 activation / KV / parameter memory
可能提升组合计算深度	可能提升每层 feature capacity
需要更强的稳定化 recipe	需要更好的 tensor parallel / kernel tiling

12. Stack Heterogeneity：为什么每层完全同构也开始被挑战

Gemma 2 已在 Attention 层级上交替 local sliding-window 与 global attention，同时使用更深网络，说明“每层完全同构”并不是必要条件。[12]

2026 的 Variable-Width Transformers 进一步探索非均匀 width allocation：早/晚层更宽、中间层更窄，在 200M-2B dense 与 3B MoE 实验中优于参数匹配的 uniform baseline，并报告在 loss-matched scaling curve 下约 22% FLOPs 降低、15% KV cache I/O 降低。该工作非常新，应视为前沿证据。[18]

可异构维度	传统默认	新方向
Attention pattern	每层 full attention	local/global 交替、sparse/dense 交替
Layer width	全层同 d_model	hourglass / variable-width
FFN width	全层同 d_ff	layerwise capacity allocation
Norm topology	全层同一 Pre-LN	Peri-LN / mixed / learned scaling
Block schedule	Attention+MLP 每层固定	parallel branches、shared modules、conditional layers

13. 2024-2026 前沿：Normalization 本身仍在快速演进

nGPT 2024 把 embedding、attention/MLP weights 与 hidden states 都约束到 hypersphere，并把每层视为在球面上朝目标方向做 displacement；论文报告达到相同 accuracy 所需训练 step 可减少 $4-20\times$ （取决于 sequence length）。这是对传统“偶尔做 Norm”的更激进重构。[14]

2026 的 Keel 重新打开 Post-LN 路线：它把 ResNet-style residual path 改成 Highway-style connection，论文报告可稳定训练超过 1,000 层并改善 depth scaling。由于发布时间很新，应把它视作前沿信号，而非已替代 Pre-LN 的结论。[15]

前沿路线	在挑战什么默认假设	成熟度
Peri-LN	只在 sublayer 输入做 Norm 就足够	2025 系统研究 + 多模型实践信号
nGPT	hidden/weight 只需局部归一化	2024 新架构，需更多规模化复现
Keel	Post-LN 天生不适合超深模型	2026 新预印本，极深 depth scaling 很有启发
Variable Width	每层相同 residual width 最优	2026 前沿，compute/latency 价值值得跟踪

14. Stack Observability：训练时真正应该看哪些层级指标

指标	回答的问题	典型异常
Residual RMS by layer	state scale 是否随深度漂移	中后层单调膨胀或骤降
Attn/MLP update RMS	哪个 sublayer 在主导写入	少数层 update $\gg$ residual
Update / Residual Ratio	每层实际“改了多少”	长期接近 0 或突然 >1
Per-layer Grad Norm	梯度是否均匀传播	顶层/底层相差多个数量级
Param Update / Weight Norm	优化器每步对 layers 改动	少数层更新过激
Activation max / outlier rate	是否接近 BF16/FP8 风险区	loss spike 前局部暴涨
Layerwise representation delta	深层是否仍在做有效变换	中后层长期几乎不变化
Tokens/s / MFU / bubble	深度是否造成系统关键路径瓶颈	加层后质量增益小但 wall-clock 大增

15. 严格 Stack Ablation：怎样避免把优化 recipe 当成架构收益

必须控制	原因
总 non-embedding params / training FLOPs	Depth/width/topology 会改变容量与计算
数据、token budget、sequence length	长序列会放大 Attention 与 Norm 数值差异
LR / warmup / optimizer / clipping	不同 Norm topology 稳定区间不同
init / residual scaling	它们与 Pre/Post-LN 强耦合
kernel maturity / compiler fusion	Parallel block 的 wall-clock 收益依赖实现
pipeline/tensor parallel mapping	更深网络会改变 pipeline bubble 与通信
多 seed + loss-vs-token/FLOPs/time	把质量、算力效率、系统效率分开

建议至少同时报告：validation loss vs tokens、loss vs FLOPs、loss vs wall-clock、layerwise residual/grad statistics、peak memory、MFU/tokens-per-second、downstream capability matrix。Stack 研究尤其容易在“小模型能训”与“大模型能稳定训”之间发生结论反转。

16. Production Transformer Stack Blueprint

阶段	推荐动作	产物
1. Baseline	Pre-RMSNorm + serial residual block + 已验证 Attention/FFN	稳定可复现 baseline
2. Scale audit	记录 residual/update/grad layer profiles	Stack health dashboard

阶段	推荐动作	产物
3. Norm sweep	Pre-LN vs Sandwich/Peri-LN; 必要时 DeepNorm/ResiDual	quality-stability frontier
4. Topology sweep	Serialized vs Parallel branches	quality-throughput frontier
5. Init/scale sweep	residual scale、init std、LR/warmup 联合	loss-spike-free recipe
6. Depth/width search	iso-param + iso-FLOPs + latency constraints	architecture frontier
7. Scale transfer	μ P/ μ Transfer 或系统化 proxy scaling	降低大模型 tuning 成本
8. Long-run validation	真实训练 horizon + long-context + low precision	最终生产 Stack

推荐默认起点 新 dense decoder-only LLM 的成熟起点仍是 Pre-RMSNorm + residual + serial Attention/MLP；但当目标变成更深、更低精度、更高吞吐时，应把 Peri/Sandwich-LN、Parallel Block、Residual Scaling 与 scale-consistent parameterization 作为联合实验空间，而不是孤立开关。

17. 方法选择决策表

目标	优先研究	为什么
通用稳定 baseline	Pre-RMSNorm	成熟、实现广、梯度路径直接
进一步控制 residual variance	Peri/Sandwich-LN	同时规范 sublayer 输入/输出
极深模型	DeepNorm / ResiDual / Keel 前沿路线	显式处理 residual/gradient depth scaling
提升训练吞吐	Parallel Block	减少 Attention→MLP 串行依赖
减少 tuning 成本	μ P / μ Transfer	小模型超参数更可迁移
避免 loss spikes	Residual scale + init + layerwise observability	问题通常是系统性 scale amplification
降低顺序延迟	减少层数 / 非均匀 depth-width 分配	depth 直接进入 sequential path

18. Know-Why / Know-How 总结

Know-why	Know-how
Stack 的本质是重复 residual state update	用 residual/update ratio 而不是只看 activation 均值
Norm placement 决定梯度与 shortcut topology	Pre/Post/Peri-LN 必须和 init、LR、residual scale 一起测
RMSNorm 是现代 decoder 的成熟工程默认	优先 fused/bias-free 实现，同时监控 scale drift
Pre-LN 易优化但并非表达最优的终局	关注 DeepNorm/Peri-LN/Keel 等深度路线，但按证据成熟度采用
Depth 增加 sequential computation，而非免费参数	联合搜索 depth、width、latency、parallelism
Parallel Block 是系统-架构共设计	同时报告质量和 wall-clock，不只看 FLOPs
大模型 recipe 应追求 scale consistency	用 μ P/代理模型减少超大规模 brute-force tuning
Stack 稳定性必须可观测	建立 per-layer residual/grad/update dashboard

最终心智模型 把 Transformer Stack 想成一台由 N 个 residual update stage 组成的状态机：Attention 和 MLP 每层提出“修改建议”，Norm/Residual/Init 决定这些修改以多大幅度、沿什么路径进入全局状态。真正的架构工程，就是让这条状态主干在深度、规模和低精度下既不失控，也不变成“很多层几乎什么都没改”。

参考资料与证据等级

- [1] Vaswani et al. (2017), Attention Is All You Need. [\[奠基论文 / 一手\] source](#)
- [2] Xiong et al. (2020), On Layer Normalization in the Transformer Architecture. [\[Pre-LN/Post-LN / 一手\] source](#)
- [3] Zhang & Sennrich (2019), Root Mean Square Layer Normalization. [\[RMSNorm / 一手\] source](#)
- [4] Wang et al. (2022), DeepNet: Scaling Transformers to 1,000 Layers. [\[DeepNorm / 一手\] source](#)
- [5] Shleifer et al. (2021), NormFormer: Improved Transformer Pretraining with Extra Normalization. [\[Normalization / 一手\] source](#)
- [6] Chowdhery et al. (2022), PaLM: Scaling Language Modeling with Pathways. [\[Parallel Block / 模型技术报告\] source](#)

- [7] Xie et al. (2023), ResiDual: Transformer with Dual Residual Connections. [[Residual topology / 一手](#)] [source](#)
- [8] Wang et al. (2022), Foundation Transformers. [[Magneto / 一手](#)] [source](#)
- [9] Liu et al. (2020), Understanding the Difficulty of Training Transformers. [[Admin / residual dynamics](#)] [source](#)
- [10] Takase et al. (2023), Spike No More: Stabilizing the Pre-training of Large Language Models. [[LLM stability / 一手](#)] [source](#)
- [11] Yang et al. (2022), Tensor Programs V: Tuning Large Neural Networks via Zero-Shot Hyperparameter Transfer. [[μP / μTransfer / 一手](#)] [source](#)
- [12] Gemma Team (2024), Gemma 2: Improving Open Language Models at a Practical Size. [[Pre+Post RMSNorm / 模型技术报告](#)] [source](#)
- [13] Kim et al. (2025), Peri-LN: Revisiting Layer Normalization in the Transformer Architecture. [[Peri-LN / 一手](#)] [source](#)
- [14] Loshchilov et al. (2024), nGPT: Normalized Transformer with Representation Learning on the Hypersphere. [[前沿 normalization / 一手](#)] [source](#)
- [15] Chen & Wei (2026), Post-LayerNorm Is Back: Stable, ExpressivE, and Deep. [[Keel / 2026 预印本](#)] [source](#)
- [16] Grattafiori et al. (2024), The Llama 3 Herd of Models. [[现代 dense Transformer / 模型技术报告](#)] [source](#)
- [17] Petty et al. (2023), The Impact of Depth on Compositional Generalization in Transformer Language Models. [[Depth/width / 一手](#)] [source](#)
- [18] Wu et al. (2026), Variable-Width Transformers. [[2026 前沿 / 预印本](#)] [source](#)

说明：本文把论文中的实验事实、本文的机制化解释、以及工程建议分开处理。图 2/5 等标注为 *schematic* 的曲线仅用于解释 *trade-off*，不代表原文数据。2025-2026 的 *Peri-LN*、*Keel*、*Variable-Width* 等结果较新，已在证据等级中标记，应在目标模型规模与训练预算上重新 *ablation* 后再采用。