

LLM 预训练之数据质量评分

Data Quality Scoring • 深度研究手册

从“好/坏数据”到“目标相关 Utility 估计”：Heuristic、Classifier、LLM Judge、Pairwise、Predictive Score 与 Multi-rater

研究快照：2026-08-13

核心资料：Gopher • RefinedWeb • Dolma • DCLM • FineWeb/FineWeb-Edu • QuRating • DataDecide • PreSelect • FIRE • BETR • Apple 2026

核心判断 数据质量不是文档的一个客观标量。更准确的工程定义是：给定目标模型、训练预算、任务分布与数据配方，文档对最终模型能力的预期边际效用。Quality scorer 因此是 utility proxy；真正的“ground truth”仍然是受控预训练实验。

阅读地图

本册只讨论“评分（scoring / rating / ranking）”，不把 Parsing、Cleaning、Dedup、Mixing 混在一起。评分的输出最好是 metadata，而不是立即删除数据；后续 selection policy 再决定阈值、采样权重和领域配额。

章节	核心问题	关键 Know-how
1. 定义	“质量”到底是什么？	把 quality 从固有属性改写为 target-dependent utility proxy
2. 质量向量	为什么单一 score 不够？	至少拆成可读性、知识/教育、推理、领域、风险、独特性等维度
3. 规则/统计	Heuristic 还有价值吗？	Cheap gate 负责过滤明显噪声，不承担高级“价值判断”
4. 分类器	DCLM 为什么成功？	正样本定义 > 分类器复杂度；score inference 与 threshold 解耦
5. LLM Teacher	FineWeb-Edu 如何把昂贵判断扩到 15T token？	抽样 LLM 标注 → 小 scorer 蒸馏 → 全量推理 → ablation 定阈值
6. Pairwise	为什么 pairwise 常优于直接打分？	把绝对标尺困难转成相对偏好，再学习 scalar utility
7. Predictive	能否直接估计“什么数据会教会模型”？	利用 loss/benchmark correlation 或可预测性作为训练价值 proxy
8. Multi-rater	多个 scorer 怎样融合？	先保留 score vector，再校准/归一化/融合，避免一个模型垄断定义
9. 反例	高分是否等于“本质高质量”？	CQF 可能是分布匹配器而非纯质量测量器
10. 决策	score 怎样变成训练数据？	hard threshold、top-k、soft sampling、temperature、quota、curriculum
11. Eval	怎样证明 scorer 有用？	分类 F1 只是中间指标；最终看 fixed-compute pretraining ablation
12. 生产	怎样上线可重放？	Score-first / Decide-later；版本化 scorer、校准、阈值和 retention curves

1. 数据质量评分的真正定义

最常见但最危险的抽象是 $q(x) \in [0,1]$ ：仿佛每个文档 x 都有一个天然“质量”。现代实验更支持下面的定义：

$U(x \mid M, B, T, D)$ = 文档 x 在模型 M 、预算 B 、目标任务 T 、其余训练分布 D 下的预期边际训练效用

我们实际上无法直接计算 U ，只能训练或设计 scorer $s(x)$ 去逼近它。不同 scorer 的差异，本质上是“用什么代理目标定义有用数据”。

Scorer 家族	隐含的“好数据”定义	优点	主要盲点
Heuristic	像自然、连贯的人类文本	便宜、可解释	只能排明显噪声
Reference classifier	像某个高质量 reference set	高吞吐、效果强	把 reference 偏好当成质量
Educational scorer	能教学/解释知识	知识与推理任务强	可能压低叙事、口语、常识覆盖
Perplexity / LM loss	某模型认为“自然/可压缩”	简单连续信号	低 PPL 可能只是常见/重复；高 PPL 也可能是珍贵知识
Pairwise LLM judge	相对更符合人类质量直觉	标尺稳定性更好	昂贵、judge bias
Predictive scorer	该文本上的 loss 能预测能力	更接近 downstream utility	依赖目标 benchmark/模型群
Influence / gradient	训练该样本会怎样改变目标	理论更直接	计算昂贵、规模化困难

Know-why 质量评分的核心问题不是“模型能否准确复刻人工标签”，而是“这个标签体系是否定义了你真正想训练

出来的能力”。DCLM、FineWeb-Edu 与 2025-2026 的研究都在反复证明：定义正样本/目标分布，往往比 scorer 架构本身更重要。

2. Quality 应该先是向量，再决定是否压成标量

单一总分易部署，但会把互相冲突的价值揉成一个不可解释数字。更稳健的设计是先保留质量向量：

$s(x) = [\text{readability, coherence, educational, expertise, factual-density, reasoning, code/math, domain-fit, safety, novelty, ...}]$

维度	高分意味着	典型代理信号	为什么不能替代其他维度
可读性/语言完整	句法连贯、非乱码/模板	长度、标点、字符比例、LM score	可读不等于有知识
Educational value	解释概念、可学习	LLM teacher / student classifier	叙事、新闻、对话可能被低估
Required expertise	需要专业背景	pairwise/LLM judge	高专业不等于更适合所有模型阶段
Facts & trivia	事实/实体信息密度	judge/classifier	可能鼓励百科式分布
Reasoning density	推导/论证/步骤结构	LLM/rationale tags	文本可能“看起来会推理”但事实错误
Domain fit	与目标能力接近	embedding/benchmark similarity	容易 benchmark hill-climb
Novelty/diversity	提供新的表达/知识	dedup cluster、embedding density	独特不等于正确
Risk / governance	隐私/违法/不适宜风险低	PII/toxicity/license tags	风险控制不是能力质量的同义词

设计原则 Quality vector 与 Mixing 之间应有清晰接口：scorer 负责“描述文档”，selection/mixing 负责“基于训练目标做决策”。不要在 scorer 内偷偷写死最终数据配方。

3. 第一代：规则与统计特征 - 便宜、稳定、仍然不可替代

Gopher/MassiveText 明确选择简单、可解释的启发式，而不是拿 Wikipedia 等“金标准”训练质量分类器，以降低特定人口/方言被系统性抹去的风险。其 Web 过滤使用文档长度、平均词长、符号比例、bullet/ellipsis 比例、字母词比例与 stop-word 等信号。[1]

C4 的历史也说明了另一面：简单规则能显著去除模板、占位符和碎片文本，但后续审计发现 blocklist 会不成比例地删除与少数群体相关的文本。规则“可解释”不代表“无偏”。[2]

规则类型	典型 feature	适合做	不适合做
长度/结构	word/sentence/line count	去空页、碎片、异常超长	判断知识价值
字符组成	alphabetic ratio、symbol ratio	去乱码/表格/代码噪声	跨语言统一阈值
重复度	duplicate lines/n-grams	去 SEO/模板 spam	替代 corpus-level dedup
语言概率	lang-id score	路由到对应语言 pipeline	判断文本本身质量
关键词/URL	placeholder、成人/风险域	治理 gate	用词表代替语义安全判断
PPL / n-gram	自然度/域相似	异常检测/排序	单独定义“高质量”

工程定位 把 heuristic 当 Cheap Gate，而不是 Gold Scorer：先用 O(文本长度) 的规则删明显失败样本，再把剩余候选交给 learned scorer。这样最贵的计算只花在“难判断”的数据上。




图 1 不同评分方法在成本与可表达质量语义上的相对位置（概念图）。

4. DCLM：为什么一个 fastText 质量分类器能如此强？

DataComp-LM 提供 240T-token Common Crawl pool 和统一训练/评测协议，系统对比数据过滤方法，结论之一是 model-based filtering 对高质量训练集非常关键。DCLM-Baseline 的 7B 模型用 2.6T token 达到 64% 5-shot MMLU，并以更少 compute 接近当时更昂贵的开放模型。[3]

其公开模型卡显示，fastText scorer 的高质量正类来自 OpenHermes 2.5 与 Reddit ELI5，低质量类来自 Common Crawl；生产流程先 enrich 每个文档的高质量概率，再用独立 threshold 过滤。官方配置中 OH2.5+ELI5 scorer 的阈值为 0.018112，对应论文所用的大致 top-10% 策略。[4][5]

环节	DCLM 做法	可迁移 Know-how
定义 HQ	OH2.5 + ELI5	最重要的是 reference distribution：你在定义“模型应该更像什么”
定义 LQ	Web crawl samples	负类不只是垃圾，而是“普通 web 分布”
Scorer	fastText unigram/bigram classifier	非常轻量也能强，因为标签目标已经携带大量归纳偏置
Inference	只写 quality probability	推理和决策解耦，便于重扫阈值
Selection	top percentile / threshold	绝对概率通常不具跨版本意义；排名/分位数更稳健
Validation	真实预训练 + 53 evals	classifier F1 不是最终验收标准

关键洞察 DCLM 的成功容易被误读成“fastText 很神奇”。更准确的解释是：一个便宜 scorer 可以高效复制一个强 reference-set 偏好。于是 scorer architecture 是放大器，reference definition 才是“质量哲学”。

5. FineWeb-Edu : LLM Teacher → 小 Scorer → Trillion-scale

FineWeb 团队用 Llama-3-70B-Instruct 对约 500k FineWeb 样本按 0-5 教育价值评分，采用 additive scale，并把重点放在小学/中学层面的“可教学性”以避免 judge 只偏爱高度技术页面。随后用约 450k 标注训练一个轻量回归分类器，再把它应用到 FineWeb 的 15T token。[6][7]

公开说明中， $\text{score} \geq 3$ 的二分类 F1 约 82%；全量分类消耗约 6,000 H100 GPU-hours。阈值 3 的 ablation 在整体 benchmark 上最好；继续提高阈值虽然提高部分知识/推理 benchmark，却显著损害 HellaSwag 和 PIQA。最终 $\text{score} \geq 3$ 只保留约 8% 数据，形成约 1.3T token FineWeb-Edu； $\text{score} \geq 2$ 则保留更多数据形成约 5.4T token 版本。[6][7]

步骤	为什么这样做	常见错误
1 抽样	把昂贵 LLM 判断限制在 10^5 - 10^6 样本	只抽“看起来好”的样本，导致 label coverage 偏
2 设计 rubric	让每一档分数对应可解释增量	只说“quality 0-5”，judge 标尺漂移
3 Teacher 标注	获得复杂语义标签	把单一 judge 当绝对真理
4 Student 蒸馏	把每 token 推理成本降低数个数量级	只看 student F1，不看下游训练结果
5 全量 scoring	写 score metadata	边推理边删，失去阈值重放能力
6 Threshold ablation	用 proxy model 找 Pareto 点	阈值越高越好




图 2 高质量阈值存在能力 trade-off；图中曲线为机制示意，不是 FineWeb 原始实验数值。

Know-how Teacher 不需要直接处理全部训练语料。最常见的可扩展模式是：LLM 负责定义“什么叫高价值” → Student 负责把这个判断扩散到 trillions tokens。真正要花实验预算的是 rubric、抽样分布、student capacity、阈值和 retention ratio。

6. QuRating：从绝对打分转向 Pairwise Preference

QuRating 研究四个抽象质量维度：writing style、required expertise、facts & trivia、educational value。作者发现 LLM 对“两个文本谁更符合某质量”比直接给单文档绝对分数更可靠，因此先收集 pairwise judgments，再训练 QuRater 学习 scalar ratings，并给 260B 语料打分。[8]

Pairwise ranking 可写成 Bradley-Terry 风格：

$$P(x_i > x_j) = \sigma(r(x_i) - r(x_j))$$

在 30B-token、1.3B 模型实验中，直接 top-k 高分选择并不总稳定；把质量 rating 当作 sampling logits、用温度做 soft sampling 更能兼顾质量与多样性。基于 educational value 的最佳设置表现接近 uniform sampling 多训练 50% steps 的模型；rating 还可用于 curriculum，而无需改变数据集本身。[8]

策略	公式/直觉	优点	风险
Top-k	只保留最高分	简单、高纯度	模式收缩、长尾消失
Threshold	$s(x) \geq \tau$	易解释	τ 对 scorer 版本/语言不稳定
Softmax sampling	$p(x) \propto \exp(s/T)$	保留低分数据的一部分概率	T 需要通过训练实验调
Rank percentile	按分位数映射权重	跨 score calibration 更稳	不同域比例仍可能漂移
Curriculum	早/晚阶段改变 score 偏好	同一数据不同使用顺序	课程收益依赖模型阶段

核心转变 Quality scorer 的输出不一定用来“删除”。QuRating 说明，更成熟的用法是把它当作采样能量函数：低质量数据降权，高质量数据升权，但保留一定多样性。

7. 从“看起来高质量”到“预测训练价值”

7.1 Perplexity correlation：用现成模型群找“能力相关文本”

ICLR 2025 的 Improving Pretraining Data Using Perplexity Correlations 观察到：多种现成 LLM 在某些文本上的 loss 与它们的下游 benchmark 表现存在相关性；当文本域与目标 benchmark 对齐时，可利用这种相关性筛选预训练数据，在受控实验中优于 DSIR，并匹配 DataComp-LM 的强 selector。[9]

7.2 PreSelect：把“predictive strength”蒸馏成 fastText scorer

ICML 2025 的 PreSelect 将上述思想进一步工程化：数据如果能让不同模型的 normalized loss 排名预测下游能力排名，就可能更“有教学价值”。作者最终只部署一个 fastText scorer；其 1B/3B 实验报告，30B selected tokens 可超过 300B random baseline，并在 3B/100B 设定中优于 DCLM 与 FineWeb-Edu。[10]

范式	评分目标	相比“教育价值”优势	新风险
PPL / loss	模型对文本的可压缩性	无需人工 rubric	“容易” / “难”与“有用”不是同义词
PPL-correlation	文本上的 loss 是否预测 benchmark 能力	直接把 target ability 纳入定义	容易被 benchmark/domain 绑架
PreSelect	蒸馏 predictive strength	可大规模部署	训练 scorer 依赖一组现成模型与目标 eval
Influence-style	样本对目标 loss/参数的影响	更接近边际贡献	计算成本高、近似误差复杂

Know-why 这条研究线把“质量”从静态内容属性推进到因果问题：什么数据会让模型学会我们关心的能力？它更贴近真正目标，但也更暴露 target dependence：换 benchmark、换模型规模，优先数据可能就变。

8. Multi-rater：不要让一个 scorer 垄断质量定义

EMNLP 2025 的 FIRE 指出单一 quality signal 难以全面评价数据，提出把多个 rater 对齐到统一空间再融合，并使用 progressive selection。其论文报告，在目标性能上可把 token 需求降到 Random baseline 的 37.5% 以下。[11]

QuaDMix 则把 quality 与 diversity 明确放入同一采样函数，并通过小模型模拟实验和参数搜索寻找分布；论文报告多模型/多数据集上平均提升，核心不是“只选高分”，而是让高质量与覆盖度共同决定 sampling probability。[12]

一个生产友好的 score record 可以是：

```
{heuristic, dclm_hq, edu, reasoning, expertise, domain_fit, predictive, risk, novelty, lang_conf, scorer_versions...}
```

融合方法	什么时候适合	问题
线性加权 $\Sigma w_i s_i$	score 已校准、目标明确	权重难解释且有共线性
Rank/quantile fusion	不同 scorer 标尺差异大	牺牲绝对 margin 信息
Learned fusion	有 proxy pretraining labels	可能过拟合 proxy regime
Pareto / rule policy	有硬治理约束+多能力目标	实现复杂，但最可审计
Domain-specific fusion	多语言/代码/科学分域	维护 scorer matrix 成本高

推荐 优先保存原始多维 scores，再在 selection layer 版本化地融合。这样当目标从“通用模型”切换到“数学/代码/多语言”时，不必重新做全部昂贵 scoring。

9. 2025-2026 的反思：Quality Score 可能只是“分布选择器”

2026 年 Apple Research 的 Removing Noise, not Finding Gold 对 classifier-based quality filtering (CQF) 做了系统分析：CQF 能改善 downstream performance，但不一定改善在所谓高质量 reference set 上的 language modeling；更令人警惕的是，用 CQF 选出的 web 数据甚至可能优于直接训练该 reference set。作者因此质疑“分类器学到了普适质量”的解释，更倾向把它看成一种复杂的分布选择机制。[13]

NeurIPS 2025 的 dataset fingerprint 研究也发现，C4、RefinedWeb、DolmaCC、RedPajama-V2、FineWeb、DCLM-Baseline 等同源 Common Crawl 数据在过滤后呈现可被神经网络识别的强“数据集指纹”，并且这种指纹会传播到训练出的模型。过滤管线并非中性清洁剂，而是在主动写入分布偏好。[14]

Apple 2025 的 BETR 把这种 target dependence 公开化：直接按 benchmark similarity 排序预训练文档可显著改善目标任务，且 scaling 分析显示模型越大，最佳过滤往往越不激进。它进一步说明“高质量”可能只是“更适合某组目标能力”。[15]

错误认知	更准确的解释
高 quality probability = 文档客观更好	它更像训练 reference/test 定义下的密度比或偏好分数

错误认知	更准确的解释
阈值越高越好	阈值提高同时损失覆盖、长尾与训练 horizon
一个 scorer 可以全域通吃	语言、代码、数学、对话、论文需要不同 rubric / calibration
分类 F1 高就说明 scorer 好	F1 只证明复制标签；标签是否有训练价值要靠预训练实验
小模型实验排名一定可迁移	多数时候有用，但协议/学习率/模型规模会影响 ordering

最重要的 Know-why Quality scoring 不是在“发现黄金”，而是在定义训练分布。每一次打分与过滤都应该被视作模型能力塑形决策，而不是数据卫生操作。

10. Score Calibration：跨 scorer / 跨语言 / 跨版本必须校准

一个 0.8 的 score 没有天然含义。它只在特定模型、训练数据、采样分布、文本长度与语言下有意义。生产系统至少应把“raw score”和“calibrated rank/quantile”都保存。

问题	检测方法	修复方法
Score drift	按时间/CC dump 画 score histogram	固定校准集；版本化 quantile mapping
Length bias	score vs token length 曲线	分长度 bucket 校准/加入长度特征
Domain bias	各 domain retention curve	domain-specific threshold 或 quota
Language bias	每语言 score 分布 + 人审	per-language scorer/threshold；FineWeb2 式语言适配
Teacher bias	多 judge disagreement / audit	小规模 jury + human audit，但不要默认平均一定更好
Source fingerprint	source classifier / embedding shift	控制 reference mix；source-stratified ablation
Score saturation	高分区分不开	pairwise/ranking 或更难 calibration set

FineWeb-Edu 的公开实验本身就是一个校准案例：不同 open-weight teacher 的打分尺度并不一致；Mixtral-8x7B 更“宽松”，简单 jury 平均会把 score distribution 右移，而且用 jury annotations 训练出的过滤器在他们的预训练实验中反而更差。[6]

规则 不要把“0-5”“0-1 probability”当绝对标准。对 trillion-scale corpus，更稳定的控制量通常是：每来源/语言的 percentile、retention ratio、token yield 与下游 scaling curve。

11. 从 Score 到 Selection Policy

Scoring 结束后，才进入真正的决策问题。建议至少并行保留 4 种 policy 进行 proxy ablation：

Policy	核心参数	优点	适合场景
Hard threshold	τ	简单、可审计	明显质量断层/治理 gate
Top-k / Top-p percentile	retention ratio	控制预算直接	scorer calibration 不稳定时
Temperature sampling	T / β	质量-多样性连续可调	通用预训练、QuRating 类策略
Stratified quota	domain/lang/source quota	防止高分域吞掉长尾	多语言、多源混合
Quality bucket mix	Q0..Q5 权重	易版本化、易分析	长期训练/课程
Curriculum	time→weight schedule	同一语料多阶段利用	中后期强化知识/推理

soft sampling 的典型形式：

$$p(x) \propto \exp(\beta \cdot s(x)) \times w_{\text{domain}}(x) \times w_{\text{novelty}}(x)$$

β 越大越接近 top-k; β 越小越接近 uniform。实际系统还应给低资源语言、代码、数学等领域单独 quota，避免“质量 scorer 偏好最多的域”垄断 token budget。

12. 怎样证明一个 Quality Scorer 真有效？

DataDecide 用 25 个不同数据配方、模型最高到 1B、训练最高到 100B token 的控制实验研究“小模型是否能帮助选大模型数据”。一个 150M 模型的单尺度排名就能正确预测约 80% 的 1B 配方比较；连续 likelihood proxy 对多个 benchmark 的可预测性可在极低 compute 下超过 80%。这给数据评分工程一个重要方法论：先做大量小而严格的 ablation。[16]


但 2025 年底的新研究提醒，固定同一 proxy training hyperparameters 可能让“数据配方排名”随着学习率等小改动而翻转；数据方案应该在更公平的数据特定调参或更稳健 protocol 下比较。这个结果尚较新，但足以说明 proxy experiments 不是自动可靠。[17]

层级	指标	能回答什么	不能回答什么
Label-level	F1/AUC/Kendall/Spearman	scorer 是否复刻 teacher/human	标签是否真正提升预训练
Corpus-level	retention、token yield、source/lang/domain shift	过滤改变了什么分布	模型最终能力
Proxy training	fixed-token loss + benchmark likelihood	score policy 是否值得继续	大模型上一定同序
Scale transfer	多模型 size / token budget	policy 是否随 scale 变化	最终生产训练的所有相互作用
Full recipe	目标模型规模 + 完整 mix	最终 ROI	成本高，不能用于每个小改动

最低实验标准 固定模型架构、token budget、训练超参和评测；只改变 scoring/selection policy。至少 2-3 个 retention ratios；报告平均能力 + 分任务能力 + loss + token yield。更重要的是记录“被删掉的是什么”，而不仅是最终分数。

13. Production Blueprint : Score-first, Decide-later

推荐生产架构：Score first, decide later



所有原始分数保留为 metadata；昂贵 scorer 只对 cheap gate 后的候选运行；阈值/权重与 scorer 推理解耦

图 3 推荐生产架构：评分、校准、决策三层解耦。

字段	示例	用途
doc_id / content_hash	稳定 ID	跨版本追踪

字段	示例	用途
source / snapshot / lang	CC-MAIN-2025-xx / en	分布审计与校准
cheap_features	length, alpha_ratio, repetition...	Cheap gate / debug
score_raw.*	edu=3.42, dclm=0.021...	保留原始 scorer 输出
score_rank.*	edu_pct=0.91	跨 scorer/version 更稳定比较
score_version.*	fineweb-edu-v1.4	重放与 provenance
quality_bucket	Q0-Q5	mixing / curriculum
risk_tags	pii/toxic/license...	治理，不与 quality 混成一个分
dedup_meta	cluster_id,size,novelty	避免高质量但高度重复的内容占满 budget
decision_version	policy-2026-08-A	解释为什么被采样/过滤

成本优化 最贵的 LLM scorer 不要全量跑：cheap gate → stratified sample teacher labels → student scorer → uncertainty / disagreement 样本再升级到 LLM judge。把 active learning 用在“scorer 最不确定、但 token 价值可能很高”的区域。

14. 多语言 / Code / Math：Quality 评分必须域适配

FineWeb2 的多语言工作显示，把英语的 stop-word、word length、alphabetic ratio 等过滤规则直接复制到低资源语言会产生系统性错误，必须适配 tokenization、script 与语言特定阈值。这个结论同样适用于 learned quality scorer：reference data 和 calibration set 必须覆盖目标语言。[18]

域	评分重点	特别要避免
多语言	language confidence、script、自然度、本地知识、教育价值	用 English/Wikipedia scorer 全局统一阈值
代码	语法/可解析、repo context、文档与实现一致、测试/依赖信息	把符号密度/低自然语言比例当低质量
数学	公式完整、推导连贯、问题-解答一致、难度层级	只按一般 web readability 过滤
学术论文	结构完整、引用/公式/表格恢复、专业性	把高 expertise 误当唯一高质量
对话/论坛	上下文、信息增量、经验性知识	因口语风格低分而丢掉真实交互分布
合成数据	正确性、覆盖、模式多样性、teacher agreement	“格式很干净”掩盖事实错误与 mode collapse

实践 最好维护 scorer matrix，而不是 one-model-for-all：通用可读性 scorer + language/domain-specific scorer + task utility scorer + risk tags。最终 selection layer 再按目标模型组合。

15. 最终 Know-Why / Know-How Checklist

问题	推荐答案
Quality 是什么？	相对于模型规模、预算、目标能力和其余数据分布的 utility proxy，不是客观属性。
先规则还是先模型？	Cheap heuristic gate → learned scorer；不要用昂贵 scorer 处理明显垃圾。
单分还是多分？	先 score vector；标量融合放到 selection layer。
Teacher 怎么用？	LLM 做 rubric/标注，student 扩到 trillions token；保留 teacher disagreement。
Direct rating 还是 pairwise？	抽象质量优先尝试 pairwise，尤其当绝对尺度漂移明显时。

问题	推荐答案
阈值怎么定？	不是看 F1；扫 retention ratios，用 fixed-compute pretraining ablation 定。
高分是否 top-k？	通常先试 soft sampling / temperature + domain quota，避免 diversity collapse。
score 是否可跨版本？	不要默认；保留 raw + percentile + scorer version + calibration snapshot。
怎么防 bias？	按 source/lang/domain/group 做 retention audit；审计被删除数据。
怎么判断 scorer 失效？	高 F1 但 downstream 不升；score 与 domain/source 强耦合；高分区 diversity 急降。
小模型实验可信吗？	常有预测价值，但要检查 scale/hyperparameter transfer；不能机械外推。
生产最重要的数据结构？	可重放 metadata：所有 score、版本、bucket、decision reason 和分布统计。

一句话沉淀 不要问“怎样找到全世界最高质量的数据？”；要问“在给定模型、预算和目标能力下，怎样用可审计的多维评分与受控实验，估计并分配每类 token 的训练价值？”

参考资料与证据等级

以下优先列出论文、官方研究页面、官方数据/模型卡。2025-2026 的新工作用于呈现前沿趋势；其中尚未形成长期复现共识的结论在正文中已明确作为“新证据/反思”处理。

编号	资料 / 用途
[1] Rae et al., 2021/2022	Scaling Language Models: Methods, Analysis & Insights from Training Gopher. arXiv:2112.11446. MassiveText heuristic quality filtering.
[2] Dodge et al., 2021	Documenting Large Webtext Corpora: A Case Study on C4. EMNLP 2021. Blocklist/filter bias audit.
[3] Li et al., 2024	DataComp-LM: In search of the next generation of training sets for language models. arXiv:2406.11794.
[4] ML Foundations	fasttext-oh-eli5 model card. Positive=OpenHermes2.5+ELI5; negative=Common Crawl.
[5] ML Foundations	DCLM baseline configuration / README. Scoring enricher + threshold filter; threshold 0.018112.
[6] Penedo et al., 2024	The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale. NeurIPS 2024 / arXiv:2406.17557.
[7] Hugging Face FineWeb-Edu	Dataset/model cards: Llama-3-70B annotations, 0-5 educational score, student classifier, threshold ablations.
[8] Wettig et al., 2024	QuRating: Selecting High-Quality Data for Training Language Models. ICML 2024.
[9] Thrush et al., 2025	Improving Pretraining Data Using Perplexity Correlations. ICLR 2025.
[10] Shum et al., 2025	Predictive Data Selection: The Data That Predicts Is the Data That Teaches. ICML 2025.
[11] Xu et al., 2025	FIRE: Flexible Integration of Data Quality Ratings for Effective Pretraining. EMNLP 2025.
[12] Liu et al., 2025	QuaDMix: Quality-Diversity Balanced Data Selection for Efficient LLM Pretraining. arXiv:2504.16511.
[13] Nait Saada et al., 2026	Removing Noise, not Finding Gold: Quality Filtering for Large-Scale Pretraining. Apple ML Research / arXiv:2510.00866.
[14] Mansour & Heckel, 2025	Measuring Fingerprints of Web-filtered Text Datasets and Fingerprint Propagation Through Training. NeurIPS 2025.

编号	资料 / 用途
[15] Mizrahi et al., 2025	Language Models Improve When Pretraining Data Matches Target Tasks (BETR). arXiv:2507.12466 / Apple ML Research.
[16] Magnusson et al., 2025	DataDecide: How to Predict Best Pretraining Data with Small Experiments. ICML 2025.
[17] Wang et al., 2025	Can Small Training Runs Reliably Guide Data Curation? Rethinking Proxy-Model Practice. arXiv:2512.24503.
[18] FineWeb2, 2025	One Pipeline to Scale Them All - Adapting Pre-Training Data Processing to Every Language. arXiv:2506.20920.
[19] Meta, 2024	Introducing Meta Llama 3 / The Llama 3 Herd of Models. Llama 2 used to help create text-quality classifiers; 15T+ pretraining tokens.
[20] Soldaini et al., 2024	Dolma: an Open Corpus of Three Trillion Tokens for Language Model Pretraining Research. arXiv:2402.00159.

研究边界：本册聚焦预训练数据评分。SFT/RLHF 数据选择、reward modeling、样本难度 curriculum 等只在能解释预训练 scoring 原理时类比，不作为主体。