

Agent架构、上下文、规划与工具

把一个会调用工具的模型变成可持续、可恢复、可验证的执行系统

研究范围	2025-08-20 至 2026-08-19; 另列少量边界基线
语料规模	重点引用 27 篇相关论文和多个官方harness案例
证据原则	优先论文原文、作者项目页、官方工程博客和GitHub仓库; 主张与推断分开
版本	v1.0 生成日期 2026-08-19


本报告不是排行榜。它是一套研究地图:
解释哪些结果可以相信、哪些只是方向性证据、哪些工程选择会改变结论。

本卷导航

01	参考架构与双循环模型
02	上下文工程: 选择、隔离、压缩、重建
03	规划: 从清单到策略图
04	工具设计、MCP与代码元工具
05	长时harness与崩溃恢复
06	失败模式与工程检查表
07	代表论文精读卡

1. 参考架构与双循环模型

生产Agent最好拆成两个循环。内循环负责一次决策：读取受控上下文、选择动作、获得观察。外循环负责工作生命周期：预算、任务队列、checkpoint、权限、验证、重试、人工升级和最终交付。把两者混在一个prompt里，会让关键控制依赖模型“记得遵守”。



闭环是否可靠，取决于验证信号能否阻止错误写入长期状态。

建议的最小组件

组件	职责	避免的问题
Goal contract	目标、范围、完成条件、禁止项、预算	防止目标漂移和过早完成
Planner	生成/修订里程碑，不直接决定高风险动作	分离方向与执行细节
Context builder	按任务选择规则、状态、证据、工具	让每一步只看需要的信息
Action policy	工具/代码/GUI选择与参数	连接模型意图和实际动作
Executor	沙箱、凭证代理、网络和资源限制	控制真实影响与可重复性
State store	事件、产物、事实、承诺、检查点	跨窗口和崩溃恢复
Verifier	测试、规则、约束、裁判、人审	阻止错误进入完成态或长期记忆
Supervisor	超时、重试、回滚、升级和审计	处理模型无法自愈的情况

控制权分配原则

把可枚举、可测试、关系到权限和资金的规则放在确定性层；把需要语义判断、开放检索和路径探索的部分交给模型；把模型生成的计划视为候选，而不是授权；把工具输出视为不可信输入；把验证结果作为状态转换条件。

2. 上下文工程: 选择、隔离、压缩、重建

上下文不是记忆的同义词。上下文是某一步实际提供给模型的工作集；记忆是可能被选入未来上下文的持久信息。有效上下文工程不是追求“更多”，而是提高相关信息密度、降低冲突并保留来源。

操作	正确做法	主要防御
选择	按子任务、风险和工具阶段选择规则/状态/证据	全量历史稀释约束
隔离	子代理和子任务拥有独立工作集	跨任务串扰、角色污染
压缩	阶段结束后总结决定、产物、未决项和证据	上下文溢出和重复推理

操作	正确做法	主要防御
重建	从事件日志、文件和数据库重建当前状态	依赖不可审计的自由文本摘要
缓存	复用稳定提示、规则、工具目录和只读证据	重复token与延迟
遗忘	删除过期、中间、错误或低价值信息	错误累积和检索污染

阶段摘要应包含什么

- 已验证事实: 带来源、时间和验证方法。
- 已做决定: 选择、理由、替代方案和可撤销条件。
- 当前产物: 文件路径、版本、测试状态和所有者。
- 未决问题: 阻塞项、下一动作、所需权限和风险。
- 失败记录: 尝试、错误类别、为何失败、是否可重试。
- 禁止把模型猜测、计划或未验证工具输出写成事实。

设计判断

长时Agent的真正能力是“以低损失恢复工作状态”，而不是“连续保持同一段对话”。文件、测试、状态表和事件日志比自然语言聊天历史更适合作为长期主干。

3. 规划: 从清单到策略图

规划范式	适用	主要风险
一次性线性计划	路径稳定、步骤少	环境变化后计划失效; 容易为了完成清单忽略目标
里程碑 + 局部动作	长时任务、依赖清晰	需要判断何时重规划和如何验证里程碑
递归子目标	层级深、可局部验证	递归成本和上下文碎片化
策略图/DAG	存在替代路径、探索与复用	图维护成本; 旧策略可能误导新环境
搜索/MCTS	可模拟、可评分的组合空间	评估器不稳定时搜索放大误差
反应式执行	短任务、环境反馈密集	易局部贪心和目标漂移

重新规划触发器

- 关键假设被工具结果否定，或依赖状态发生变化。
- 连续两次动作没有减少与完成条件的距离。
- 预算消耗超出计划曲线，或等待外部条件的时间变长。
- 验证器发现当前路径即使继续也无法满足不变量。
- 出现更低风险、成本或更高可验证性的替代路径。
- 用户修改目标、范围或约束。

Planner与executor必须分开吗

不是必须，但高复杂度系统值得逻辑分离。Planner输出里程碑和约束；executor选择下一动作；verifier确认进展；supervisor决定继续、回滚或升级。分离带来可观察性和独立评测，代价是额外token和接口。小任务可以合并，但仍应记录动作前目标与动作后验证。

4. 工具设计、MCP与代码元工具

工具是Agent的动作语言。工具名、描述、参数、返回结构和错误信息共同塑造模型策略。写给Agent的工具不应照搬写给人类开发者的API: 需要更少的歧义、更强的结果语义、更清晰的失败分类和可组合性。

原则	实现	收益
语义清晰	动作动词 + 目标对象; 明确副作用	避免多个相似工具混淆
参数受限	枚举、类型、默认值、互斥与范围	减少近似字符串和隐式转换
返回可用	结构化结果 + 摘要 + 状态变化 + provenance	避免Agent重新解析长文本
失败可恢复	AUTH/NETWORK/VALIDATION/CONFLICT/NOT_FOUND	使重试策略与错误类型匹配
幂等和预演	dry-run、idempotency key、diff	降低重复调用和误操作
权限最小化	每任务短期能力、参数级范围	限制被注入后可做的事
可验证	返回对象ID、版本、校验和、后置条件	把“调用成功”升级为“目标达成”

为什么代码是元工具

面对大量工具，模型可以先通过目录或SDK发现能力，再编写小程序完成过滤、循环、并行和数据转换。这样中间大结果留在执行环境，不必全部穿过上下文。代码还提供精确控制流、类型检查和可复用产物。但这把风险转移到沙箱、依赖、秘密管理和代码审查，因此必须配合资源限制与输出验证。

MCP、A2A与Skills的分工

层	连接对象	解决	不解决
MCP	Agent/模型连接工具、资源和提示	能力发现与调用	不自动解决权限、信任和业务语义
A2A	Agent应用之间交换任务、消息和产物	跨框架协作	不保证对方能力真实或结果正确
Skills	按需加载说明、代码和资源	程序性知识复用	需要来源、版本、测试和权限治理
代码/SDK	在沙箱内组合能力	精确控制流与大数据处理	执行安全、依赖和秘密风险

5. 长时harness与崩溃恢复

长时系统不能假设进程、上下文、网络或模型调用永不失败。正确模型是可中断任务系统: 每个阶段产生可提交产物和持久状态，任何新会话都能在有限读取后继续。

机制	实现	防止
任务分解	feature/task清单带依赖、完成条件、所有者	避免Agent每次重新决定整个项目
小批提交	一次只完成一个可验证增量	降低上下文跨度和回滚成本
状态快照	版本化state + append-only event log	同时支持当前读取与审计重放
产物交接	文件、测试、截图、数据表、diff	用外部对象承载上下文

机制	实现	防止
失败分类	可重试、需换路径、需权限、需人工	防止盲目重试和错误放大
幂等恢复	动作ID、检查目标状态后再执行	避免崩溃后的重复副作用
结束判据	验收脚本 + 未决项为空 + 风险清单	防止 “看起来完成”

推荐状态机

INIT -> PLAN_READY -> EXECUTING -> VERIFYING -> (REPLAN | RETRY | NEEDS_HUMAN | DONE)。状态转换必须由可记录事件触发；DONE必须由验收结果触发；模型可以建议状态，但不能直接越过验证。对于外部副作用，使用PREPARED -> COMMITTED两阶段记录，崩溃后先查询真实状态再决定补偿。

6. 失败模式与工程检查表

失败	表现	控制
目标漂移	优化局部方便而忽略原目标	每轮注入完成条件; verifier对目标而非计划评分
上下文锁定	早期错误假设持续支配后续	显式假设表; 反证触发重规划
工具混淆	选错相似工具或参数	工具检索、命名消歧、schema约束、dry-run
错误恢复失败	把AUTH当网络错误反复重试	稳定错误分类和不同策略
过早完成	局部测试通过即宣布结束	端到端验收和独立验证角色
摘要失真	交接摘要丢掉条件或把猜测写成事实	结构化字段、来源、状态重建
循环	反复搜索/编辑/测试无净进展	进展函数、预算曲线、重复检测
隐藏副作用	工具成功但改变了额外对象	diff、审计日志、最小权限、补偿动作
并发冲突	多代理同时修改共享对象	锁、分支、版本条件、合并队列
环境漂移	依赖、网页、数据或时间改变	镜像、版本、快照和环境指纹

上线前检查表

- 是否能从任意checkpoint在新进程中恢复，并且不会重复副作用？
- 是否记录了模型、harness、工具、prompt、环境、随机性和预算版本？
- 是否存在确定性完成条件，或经过校准的多评审流程？
- 外部内容能否直接影响高权限工具? 是否有数据/指令分离？
- 每个工具是否有最小权限、dry-run、幂等、错误分类和后置条件？
- 是否能解释某次失败的最早决定性步骤，而不是只看到最终错误？
- 是否计算每个可验证成功的总成本，包括人工复核与返工？
- 模型升级后是否会自动跑回归集，而不是假设更强模型一定更好？

7. 代表论文精读卡

P01 | 2025-08 | long-horizon/eval | 窗口内

OdysseyBench: Evaluating LLM Agents on Long-Horizon Cross-Application Workflows

主要贡献: 300 real-use tasks plus 302 synthesized office tasks expose cross-application state and dependency failures.

阅读限制: Synthetic tasks and application versions can bias difficulty; report partial progress, not only completion.

[原文](#)

P02 | 2025-08 | tools/MCP | 窗口内

MCPVerse: An Expansive, Real-World Benchmark for Agentic Tool Use

主要贡献: More than 550 executable tools create a tool-description space above 140k tokens and stress routing at scale.

阅读限制: Live tools improve realism but reduce longitudinal reproducibility.

[原文](#)

P03 | 2025-08 | tools/MCP | 窗口内

MCP-Bench: Benchmarking Tool-Using LLM Agents with Real MCP Servers

主要贡献: 28 live servers and 250 tools test cross-tool planning and parameter control rather than isolated function calling.

阅读限制: Environment drift and secret/API availability complicate replication.

[原文](#)

P10 | 2025-08 | planning | 窗口内

HiPlan: Hierarchical Planning with Adaptive Global-Local Guidance

主要贡献: Milestone libraries and local hints reuse demonstrations without placing complete trajectories in context.

阅读限制: Retrieval quality and domain similarity bound transfer.

[原文](#)

P15 | 2025-09 | reliability | 窗口内

Where LLM Agents Fail and How Errors Cascade

主要贡献: Root-cause errors propagate through planning, memory, reflection and tool modules; final failure labels hide the first decisive mistake.

阅读限制: Taxonomies are sensitive to annotator access to hidden state and intended plans.

[原文](#)

P16 | 2025-09 | long-horizon/eval | 窗口内

Benchmarking Agent Capabilities in Ultra Long-Horizon Tasks

主要贡献: Heavy settings exceed 200k tokens and 400 tool calls; simple scale fails under in-context locking and capability gaps.

阅读限制: One environment cannot settle how general the identified failure causes are.

[原文](#)

P21 | 2025-09 | planning/RL | 窗口内

Planner-R1: Reward Shaping for Agentic RL with Smaller Models

主要贡献: Structured reward shaping improves planning and tool-use learning with limited training samples.

阅读限制: Reward design may encode the benchmark solution and reduce open-world transfer.

[原文](#)

P24 | 2025-10 | planning/context | 窗口内

ReCAP: Recursive Context-Aware Reasoning and Planning

主要贡献: Recursive subgoals and context updates improve alignment in long-horizon environments.

阅读限制: Recursion adds model calls and may amplify evaluator error.

[原文](#)

P28 | 2025-10 | tools/eval | 窗口内

TRAJECT-Bench: Trajectory-Aware Tool-Use Evaluation

主要贡献: Separates tool selection, arguments, dependency order and final answer to expose parameter-blind choices.

阅读限制: Reference trajectories are not always unique; outcome-equivalent alternatives require careful grading.

[原文](#)

P31 | 2025-11 | tools/planning | 窗口内

TPS-Bench: Tool Planning and Scheduling

主要贡献: 200 compounding tasks distinguish sequential completion from parallel scheduling efficiency; small-sample RL improves both time and completion.

阅读限制: Timing depends on infrastructure and service latency, not only policy.

[原文](#)

P37 | 2025-12 | eval/reliability | 窗口内

Beyond Task Completion: Agent Assessment Framework

主要贡献: Four pillars cover model, memory, tools and environment, revealing runtime deviations missed by binary success.

阅读限制: One CloudOps validation case limits generalization.

[原文](#)

P38 | 2025-12 | data-science/tools | 窗口内

ML-Tool-Bench: Tool-Augmented Planning for ML Tasks

主要贡献: Deterministic shaped feedback and decomposition outperform tree search when state scoring is inconsistent.

阅读限制: Only 15 Kaggle challenges and in-memory state reduce production comparability.

[原文](#)

P42 | 2026-01 | tools/reliability | 窗口内

When Agents Fail to Act: Tool Invocation Reliability

主要贡献: 1,980 deterministic tests across models and hardware classify 12 procedural error types.

阅读限制: Tool initialization results may not transfer to complex reasoning-heavy workflows.

[原文](#)

P43 | 2026-02 | tools/eval | 窗口内

MCP-Atlas: Real MCP Server Tool Competency

主要贡献: 36 servers, 220 tools and 1,000 tasks use claims-based partial credit and internal diagnostics.

阅读限制: Claims scoring still needs validation against actual external state changes.

[原文](#)

P64 | 2026-07 | reliability/survey | 窗口内

Beyond the Leaderboard: Tool, Planning and Reasoning Failures

主要贡献: Across 19 benchmarks, failures compound nonlinearly and more scaffolding does not consistently improve reliability.

阅读限制: Cross-paper taxonomies inherit inconsistent setups and metrics.

[原文](#)

本卷结论

好的Agent架构不会把更多智能塞进prompt，而是明确分配控制权：

模型负责探索，harness负责生命周期，环境负责隔离，验证器负责状态转换，组织负责最终责任。