

Coding、Web、Computer Use与行业Agent

哪些能力已经可用, 哪些仍停留在受控演示, 怎样判断业务适配

研究范围	2025-08-20 至 2026-08-19; 另列少量边界基线
语料规模	覆盖编码、深度研究、浏览器/桌面、科学、金融、医疗与安全场景
证据原则	优先论文原文、作者项目页、官方工程博客和GitHub仓库; 主张与推断分开
版本	v1.0 生成日期 2026-08-19

本报告不是排行榜。它是一套研究地图:
解释哪些结果可以相信、哪些只是方向性证据、哪些工程选择会改变结论。

本卷导航

01	应用成熟度框架
02	编码Agent: 从补丁到持续开发
03	深度研究与Web Agent
04	GUI与Computer Use
05	科学、金融、医疗与安全Agent
06	人机协作与责任边界
07	业务选型与试点路线
08	关键论文与博客索引

1. 应用成熟度框架

Agent是否“可用”不能用一个通用答案。成熟度取决于任务可验证性、环境稳定性、动作可逆性、数据权限、失败成本和人工复核。相同模型在写测试和转账之间应有完全不同的自主级别。

级别	模式	适合	最低控制
L0 建议	只生成分析/方案，不执行	高风险、难验证	人工完全负责
L1 草稿	生成可审阅产物	文档、代码、查询	自动检查 + 人审
L2 受限执行	沙箱或影子环境中行动	编码、数据、模拟	确定性验证
L3 可回滚执行	生产中小范围、可撤销	工单、配置、低风险运营	权限租约 + 监控 + 回滚
L4 条件自治	在清晰策略内长时运行	监控、批处理、研究	SLA、升级、持续评测
L5 高影响自治	不可逆或重大决定	资金、医疗、法律、安全	目前一般不建议无人工授权

适配性六问

- 结果能否通过测试、规则、状态查询或专家rubric验证？
- 环境是否稳定，或至少能快照和重放？
- 错误动作能否回滚或补偿？
- 任务是否存在开放路径，需要动态搜索而非固定workflow？
- 人工检查Agent产物是否比人工完成任务明显便宜？
- 是否能限制数据、权限和外部影响到可接受范围？

2. 编码Agent: 从补丁到持续开发

编码是Agent最成熟的场景之一，因为代码、终端和测试形成密集反馈。但年度研究也显示，传统SWE-bench补丁任务已经不足以代表真实工程。新基准扩展到多语言、测试生成、代码审查、性能、安全、对话澄清和跨数十次CI迭代。

阶段	代表	新增能力	限制
单文件生成	语法/单测	局部正确	不代表仓库理解
Issue修复	SWE-bench类测试	检索、编辑、测试循环	污染、测试缺陷、仅Python
多类工程任务	OmniCode	测试、review、style、多语言	仍是离线任务
非功能目标	PerfBench/SecureAgentBench	性能与安全	环境噪声和漏洞覆盖
持续演化	SWE-CI	数十轮提交和可维护性	重建历史环境成本高
互动开发	Dialogue SWE-Bench	澄清、协作、用户模型	模拟用户有效性
工业长时	Confucius/Claude/Codex案例	记忆、任务队列、并行与回归	厂商与作者系统证据需独立复核

编码Agent的工程共识

- 仓库本身是外部记忆: 清晰结构、类型、测试、ADR和机器可读规则提高Agent表现。
- 小批量、可测试提交优于一次性大改；每步保留diff和回滚点。
- 搜索/读取工具通常比复杂规划提示更影响早期成功。

- 端到端测试、视觉检查和运行真实应用能减少过早完成。
- 并行Agent适合独立模块，前提是接口和CI先行。
- 沙箱、网络和秘密边界比逐命令确认更可扩展。
- 基准分数必须附harness、环境和任务质量审计。

成熟度判断

在有强测试和代码审查的中低风险仓库中，编码Agent可达到L2至L3；对核心基础设施、大规模迁移和安全关键代码，应保留架构评审、威胁建模和人工批准。

3. 深度研究与Web Agent

深度研究的难点不是找到一个答案，而是制定搜索计划、覆盖分散证据、判断停止、去重实体、处理矛盾、计算和引用来源。DeepSearchQA强调完整列表和停止条件；BrowseComp-Plus把动态Web固定为语料，分离检索与推理；SAGE发现关键词型子查询下，BM25甚至可大幅胜过更复杂的LLM检索器。

阶段	做法	目的
问题结构化	实体、时间、范围、排除、输出schema	防止宽泛搜索
搜索计划	子问题、依赖、停止条件	避免过早停止或无限浏览
证据获取	原始来源优先、时间戳、快照	抵御二次转述和网页变化
实体对齐	去重、别名、版本、单位	避免重复和口径错误
冲突处理	列出冲突、质量和适用条件	防止无依据合并
推理/计算	代码、表格、可复现步骤	减少心算和文本误差
引用	结论到证据的局部映射	可核验而非文末堆链接
停止	覆盖率、边际新信息、预算和风险	平衡召回与精度

常见失败

- 把搜索摘要当原文，导致日期、数字和条件丢失。
- 围绕最初假设搜索，缺乏反证和替代解释。
- 多Agent重复找到相同来源，但误以为是独立证据。
- 长报告引用存在，但无法定位哪个来源支持哪个句子。
- 为了召回而列出低置信答案，或为了精度过早停止。
- 网页提示注入影响工具选择、数据访问或最终内容。

4. GUI与Computer Use

Computer Use的进步明显：2026 AI Index记录OSWorld性能从约12%升到66.3%。但更难的OSWorld 2.0把任务扩展到中位1.6小时和数百次动作后，最佳报告完成率又降到20.6%。这不是矛盾，而是任务分布变化：旧基准的单应用操作接近饱和，新基准转向跨来源、动态状态和职业工作流。

层	内容	瓶颈
感知	截图/DOM/OCR/可访问性树	视觉遗漏、坐标漂移、隐藏状态

层	内容	瓶颈
操作	鼠标键盘、快捷键、应用API	低级误操作和效率
任务状态	跨窗口、文件、剪贴板、账户	丢失约束和应用间依赖
计划	子目标、等待、条件分支	动态页面和异步事件
验证	最终文件/界面/后台状态	“点击成功”不等于任务成功
安全	登录态、敏感数据、交易、下载	提示注入和高影响副作用

API优先还是GUI优先

若有稳定、授权且覆盖目标的API，应优先API：
可结构化、快、易验证。GUI适合没有API、遗留系统或需要视觉判断的任务。混合模式通常最佳：
API获取/修改结构化状态，GUI处理最后一公里，并用后端查询验证GUI动作。

效率不应被忽略

Computer-use Agent常用远多于人类的步骤，且后期每步因上下文增长变慢。必须记录人类最短/常见轨迹、Agent动作数、无效动作、等待和每步延迟。一个20分钟完成3分钟人工任务的Agent，即使成功，也未必有业务价值。

5. 科学、金融、医疗与安全Agent

领域	Agent机会	验证优势	主要风险
科学计算	代码、实验工具、长时任务	测试预言机和物理/数学约束	错误可重复但结论可能被错误模型假设
生物	数据库、序列、文献、分析	数据来源、版本、完整性	强Agent仍难稳定构造准确数据集
金融研究	申报文件、市场数据、计算	时间点、口径、引用和计算	结论价值判断与事实正确性分离
医疗	EHR/FHIR、指南、用户互动	隐私、主体、临床验证	高风险且数据语义复杂
网络安全	漏洞发现、补丁、利用	隔离靶场、授权、经济影响	明显双重用途和越权风险
智能合约	链上状态、漏洞、交易	本地分叉、可重放、价值度量	模拟收益不等于现实攻击可行性
企业运营	多系统工单、邮箱、CRM	权限、状态一致性、人工升级	长尾规则和例外主导失败

领域Agent的关键不是更长prompt

真正壁垒通常是高质量环境和oracle: 可信数据库连接、领域schema、检查规则、模拟器、专家rubric、审计流程与许可。通用模型升级会提高基线，但没有领域验证的Agent仍会把流畅错误转成真实动作。

6. 人机协作与责任边界

人机协作不应只理解为“Agent做完，人点批准”。好的协作在任务开始、关键不确定点和结果验证三个阶段分配责任。Agent应知道何时缺少信息，用户应看到决定、证据、影响和可撤销性。

阶段	人负责	Agent应提供
开始	目标、范围、禁区、预算	goal contract和权限租约
中途	高风险、低置信、冲突、不可逆	结构化升级请求，不是泛泛提问
交付	结果、证据、测试、未决项、风险	可审阅包和变更diff

阶段	人负责	Agent应提供
事故	影响、已做动作、恢复选项	完整轨迹、状态图和建议
学习	哪些反馈可写入记忆/技能	明确同意、版本和删除机制

避免确认疲劳

把确认放在边界变化而非每个动作： 例如允许Agent在任务分支内编辑并运行测试，但推送、发布、改数据库、发送消息和访问新域名必须升级。每次确认展示动作、目标、影响范围、所用凭证、验证和回滚，而不是只显示一条命令。

7. 业务选型与试点路线

阶段	动作
1 选择任务	高频、可验证、可回滚、人工耗时高、权限低
2 建基线	记录人工时间、质量、错误和成本; 不先假设Agent更便宜
3 影子运行	Agent不产生真实副作用，仅生成方案和轨迹
4 沙箱试点	真实工具但隔离数据/环境; 建立失败分类
5 小流量生产	低风险对象、短期权限、人工复核
6 优化	优先改工具、状态、验证和流程，再换模型/多Agent
7 扩权	只有可靠性、恢复、成本和安全达到门槛才提升自治

选型评分维度

维度	建议权重	测量
任务成功	30%	真实任务、多次运行、部分成功和尾部失败
可验证性	20%	测试/状态/证据和故障定位
安全治理	20%	权限、沙箱、数据、监控、回滚
总成本	15%	推理、工具、计算、人审和返工
运维	10%	可部署、可观察、可恢复、版本兼容
生态锁定	5%	模型/协议/存储可替换性

8. 关键论文与博客索引

P01 | 2025-08 | long-horizon/eval | 窗口内
OdysseyBench: Evaluating LLM Agents on Long-Horizon Cross-Application Workflows
主要贡献: 300 real-use tasks plus 302 synthesized office tasks expose cross-application state and dependency failures.
阅读限制: Synthetic tasks and application versions can bias difficulty; report partial progress, not only completion.
[原文](#)

P07 | 2025-08 | domain/eval | 边界基线

Finance Agent Benchmark

主要贡献: Recent SEC-filing tasks test research, calculation, provenance and synthesis under time-sensitive evidence.

阅读限制: Finance answers can be verifiable while investment conclusions remain judgment-dependent.

[原文](#)

P08 | 2025-08 | computer-use/eval | 边界基线

NaturalGAIA: Verifiable Long-Horizon GUI Tasks

主要贡献: A hierarchical framework and verifiable tasks connect GUI action sequences to measurable end states.

阅读限制: The benchmark may reward its own hierarchy; cross-harness replication is needed.

[原文](#)

P12 | 2025-08 | web/domain | 边界基线

ShoppingBench: Intent-Grounded End-to-End Shopping Agents

主要贡献: Budget, vouchers and multi-product constraints move shopping evaluation beyond search-only tasks.

阅读限制: Dynamic catalogs and commercial interfaces can quickly invalidate results.

[原文](#)

P13 | 2025-08 | coding/eval | 窗口内

GitTaskBench: Code Agents on Real Repository Workflows

主要贡献: 54 tasks across seven modalities test repository use beyond patch generation.

阅读限制: Small task count limits fine-grained model ranking.

[原文](#)

P17 | 2025-09 | interaction/eval | 窗口内

VitaBench: Versatile Interactive Tasks in Real-World Applications

主要贡献: Tests extensive information, diverse resources and dynamic user interaction in one suite.

阅读限制: Breadth can dilute causal diagnosis unless component-level metrics are retained.

[原文](#)

P19 | 2025-09 | coding/security | 窗口内

SecureAgentBench: Secure Code Generation in Real Repositories

主要贡献: Best evaluated setup achieves only 15.2% correct-and-secure solutions, showing that functional tests miss security regressions.

阅读限制: 105 tasks are valuable but insufficient to cover language and vulnerability diversity.

[原文](#)

P20 | 2025-09 | coding/eval | 窗口内

PerfBench: Can Agents Resolve Real-World Performance Bugs?

主要贡献: Performance repairs require agents to create measurements and beat developer baselines, not merely pass tests.

阅读限制: Hardware variance and noisy benchmarks can dominate small improvements.

[原文](#)

P38 | 2025-12 | data-science/tools | 窗口内

ML-Tool-Bench: Tool-Augmented Planning for ML Tasks

主要贡献: Deterministic shaped feedback and decomposition outperform tree search when state scoring is inconsistent.

阅读限制: Only 15 Kaggle challenges and in-memory state reduce production comparability.

[原文](#)

P39 | 2025-12 | coding/architecture | 窗口内

Confucius Code Agent: Industrial-Scale Open Coding Agent

主要贡献: Combines hierarchical working memory, persistent notes and a build-test-improve meta-agent; reports 54.3% on SWE-Bench Pro.

阅读限制: Leaderboard claims require reruns under controlled infrastructure and clean tasks.

[原文](#)

P41 | 2026-01 | research/eval | 窗口内

DeepSearchQA: Comprehensiveness for Deep Research Agents

主要贡献: 900 prompts in 17 fields test exhaustive collection, de-duplication, entity resolution and stopping.

阅读限制: Open-web ground truth and answer sets require continual maintenance.

[原文](#)

P48 | 2026-02 | coding/eval | 窗口内

OmniCode: Broad Software Engineering Agent Evaluation

主要贡献: 1,794 tasks span bug fixes, test generation, review fixes and style work in Python, Java and C++.

阅读限制: Synthetic and recent tasks improve contamination resistance but change ecological realism.

[原文](#)

P49 | 2026-03 | coding/long-horizon | 窗口内

SWE-CI: Maintaining Codebases through Continuous Integration

主要贡献: 100 tasks average 233 days and 71 commits, shifting evaluation from one patch to maintainability across evolution.

阅读限制: Reconstructing historical CI environments is costly and may introduce infrastructure noise.

[原文](#)

P52 | 2026-04 | computer-use/eval | 窗口内

WindowsWorld: Cross-Application Professional GUI Agents

主要贡献: 181 tasks across 17 apps show under 21% success on multi-application workflows and early stalling beyond three apps.

阅读限制: Windows configuration and automation interfaces materially affect results.

[原文](#)

P61 | 2026-06 | computer-use/eval | 窗口内

OSWorld 2.0: Long-Horizon Real-World Computer Use

主要贡献: 108 workflows take humans a median 1.6 hours; the best reported system completes only 20.6% at 500 steps.

阅读限制: Benchmark environments are expensive and sensitive to application state.

[原文](#)

P62 | 2026-06 | coding/interaction | 窗口内

Dialogue SWE-Bench: Dialogue-Driven Coding Agents

主要贡献: User simulation shows that better autonomous coding does not guarantee better clarification dialogue.

阅读限制: Simulator fidelity and persona assumptions can alter measured dialogue quality.

[原文](#)

关键工程博客

B08 | 2025-10-21 | Microsoft Research | 窗口内

Tell me when: agents that wait, monitor and act

SentinelStep wraps dynamic polling with context management for hours- or days-long monitoring.

类型: long-running | [原文](#)

B13 | 2025-11-24 | Microsoft Research | 窗口内

Fara-7B: efficient computer-use model

Argues that smaller on-device agents can improve latency and privacy but still require sandboxing and oversight.

类型: computer-use | [原文](#)

B15 | 2025-12-01 | Anthropic | 窗口内

AI agents find simulated smart-contract exploits

SCONE-bench links agent capability to economic impact and emphasizes sandboxed, reproducible execution.

类型: security/cyber | [原文](#)

B16 | 2025-12-04 | Hugging Face | 窗口内

Coding agents can run an open-model fine-tuning lifecycle

Demonstrates data checks, training submission, monitoring and conversion as one agent workflow.

类型: coding/science | [原文](#)

B23 | 2026-02-05 | Anthropic | 窗口内

Building a C compiler with parallel Claude agents

A large autonomous experiment highlights parallelism gains, merge pressure and the need for testable interfaces.

类型: multi-agent/coding | [原文](#)

B24 | 2026-02-11 | OpenAI | 窗口内

Harness engineering in an agent-first repository

Repository rules, mechanical invariants and cleanup routines turn the codebase into durable context for future agents.

类型: coding/organization | [原文](#)

B25 | 2026-02-18 | Anthropic | 窗口内

Measuring AI agent autonomy in practice

Tail turn duration grows, but autonomy duration is not equivalent to correctness or value.

类型: usage/autonomy | [原文](#)

B27 | 2026-02-26 | Microsoft Research | 窗口内

CORPGEN and multi-horizon workplace tasks

Under multi-task load, completion drops sharply; hierarchical planning, memory isolation and experience improve results.

类型: multi-task/office | [原文](#)

B30 | 2026-03-23 | Anthropic | 窗口内

Long-running Claude for scientific computing

Applies persistent memory, test oracles and orchestration to multi-day scientific work.

类型: science/long-running | [原文](#)

B31 | 2026-03-24 | Anthropic | 窗口内

Harness design for long-running application development

Feature lists, artifacts and specialized passes improve sustained frontend and application work.

类型: harness/coding | [原文](#)

B38 | 2026-06-08 | Anthropic | 窗口内

Paving the way for AI agents in biology

Even strong research agents fail to consistently construct accurate sequence datasets, emphasizing domain-specific verification.

类型: science/reliability | [原文](#)

B39 | 2026-06-16 | Anthropic | 窗口内

How Claude Code is used in practice

Usage data shows expanding adoption and higher-level delegation, but self-reported productivity is not causal proof.

类型: usage/coding | [原文](#)

B43 | 2026-08-03 | Microsoft Research | 窗口内

Orchard: scalable agentic AI framework

A Kubernetes environment service supports data collection, RL rollouts and evaluation across harnesses.

类型: training/runtime | [原文](#)

本卷结论

编码、研究和低风险运营Agent已经具备实用价值，但必须用任务可验证性和影响可控性决定自治级别。跨应用、动态状态、多人协作和高风险领域仍需要强harness与人工责任。