

OpenAI o1 → o3 推理模型训练路线深度调查

公开证据、技术推断、可复现参照与产业含义



版本：2026-08-16 | 研究口径：只把公开可核实信息写作“事实”，其余明确标注为推断

执行摘要

核心结论：OpenAI 的公开 “o 系列” 并不存在 o2。公开产品路线是 o1（2024）→ o3 / o3-mini（2024 年底预览，2025 年发布）。因此任何 “o2 训练配方” 的具体描述，如果没有内部材料，只能视为误传或猜测。
[1][7]

训练范式的真正变化，不是简单增加提示词里的 “Let’s think step by step”，而是把 “产生有用推理轨迹” 本身变成强化学习可优化的策略。OpenAI 明确披露：o1 的性能会同时随着训练阶段投入更多 reinforcement learning compute、以及推理阶段投入更多 test-time compute 而提升。[1][2]

o3 延续并放大这条路线。OpenAI 的竞赛编程论文显示：早期 o3 checkpoint 已经能够在没有 o1-IOI 那类手工领域推理策略的情况下达到 IOI 金牌水平；论文将其归因于 “更大规模、通用化的强化学习”。正式 o3 又进一步把工具选择/调用和视觉信息纳入推理与强化学习训练。[5][6]

外界最容易误判的一点是：OpenAI 没有公开 o1/o3 的完整 RL 算法、奖励函数、采样策略、base model、训练数据规模、是否使用 PRM/MCTS/GRPO 等关键实现细节。因此 “o1=某个特定算法” “o3=某种树搜索” 都不能当成事实。DeepSeek-R1、Kimi k1.5、QwQ 等开放工作更适合作为 “可能的工程实现空间” 和旁证，而非 OpenAI 配方的直接证据。[9][10][11]

1. 研究方法 with 证据等级

本报告按证据强度分为四级，避免把博客推测写成训练事实。

等级	含义	本报告使用方式
A	OpenAI 官方博客、System Card、OpenAI 作者论文	可直接表述为事实
B	OpenAI 研究员公开演讲/采访、可靠媒体引述	可表述为高可信补充
C	ARC Prize 等独立测评机构的实验/分析	用于解释行为与 test-time scaling，不反推内部实现
D	学术界复现、博客、同类开放模型	用于构建假设空间，必须标 “推断/参照”

重要边界：性能曲线能证明 “更多计算有效”，但不能单凭曲线判断内部究竟使用 best-of-N、树搜索、过程奖励、价值模型还是纯长轨迹采样。

2. 从 Q*/Strawberry 到 o1、再到 o3



图 1 | 公开时间线。o2 没有作为公开模型出现。

2023-2024：媒体把 OpenAI 的推理研究先后称为 Q* / Strawberry。到 2024 年 9 月，OpenAI 发布 o1-preview，并明确将其描述为“通过强化学习学习在回答前思考”的新系列。[2][13]

2024 年 12 月：OpenAI 发布正式 o1，并预览 o3 / o3-mini；公开报道指出 OpenAI 跳过 o2，至少部分原因是避免与英国电信品牌 O2 混淆/商标冲突。由于 OpenAI 没有发布 o2，因此不存在可验证的“o2 技术代际”。[7]

2025 年 1-4 月：o3-mini 与 o3 正式发布。o3 的产品能力从“纯文本慢思考”进一步演化到工具调用、视觉输入、复杂多步工作流。[4][6]

3. o 系列的训练范式：从 next-token scaling 到 reasoning scaling




图 2 | 基于公开证据抽象出的 o1→o3 训练范式。底层具体算法未公开。

传统大模型主要沿着 pretraining scaling 扩展：更多参数、更多数据、更多训练 FLOPs。o1 引入了两个新的可扩展轴：

- Train-time reasoning scaling：在后训练阶段投入更多大规模强化学习，让模型学会产生更有效的推理轨迹。
- Test-time reasoning scaling：同一个模型在推理时允许使用更多隐藏推理 token / 时间 / 计算，复杂任务准确率继续上升。

这意味着“模型能力”不再只由一次性预训练决定，而部分取决于每个问题愿意花多少计算。OpenAI 将这描述为不同于传统预训练约束的新 scaling regime。[1]

4. o1：公开能确认的训练方法

4.1 已确认：大规模强化学习训练隐藏 Chain-of-Thought

OpenAI o1 System Card 明确写明：o1 系列通过 large-scale reinforcement learning 学习用 chain-of-thought 进行复杂推理；模型会在最终回答前产生较长的内部推理，并在训练中学会改进思考过程、尝试不同策略、识别错误。[2]

Noam Brown 的公开演讲也把 o1 描述为“通过强化学习训练、在回答前生成 hidden chain of thought 的 LLM”。[14]

4.2 已确认：训练时与测试时存在双重 scaling law

OpenAI 官方发布页给出的最重要实验不是某个单点 benchmark，而是两条趋势：随着 RL 训练 compute 增加，能力持续提高；随着 test-time thinking compute 增加，能力也持续提高。[1]

这可解释 o1 的核心工程经济学：对困难题，系统可以把额外算力从“重新训练一个更大的模型”转移到“对当前题多思考一段时间”。

4.3 可能但未公开确认：奖励设计、搜索与过程监督

OpenAI 没有公开 o1 的具体 RL objective、policy optimization 算法、奖励模型结构，也没有确认使用 PRM、MCTS、best-of-N 或某个固定搜索算法。

学术界通常把 o1 类系统拆成四块：policy initialization、reward design、search、learning。Zeng 等人的“Scaling of Search and Learning”是一个合理的复现路线图，但它是研究者对 o1 的抽象，不是 OpenAI 配方泄露。[8]

OpenAI 更早的“Let’s Verify Step by Step”证明，在数学推理任务上，step-level process supervision 可以优于只看最终答案的 outcome supervision，并发布了 PRM800K。这说明 OpenAI 具备过程奖励研究积累，但不能据此断言 o1 一定使用 PRM800K 或同一种 PRM。[12]

4.4 安全训练：Deliberative Alignment

o1 时代另一个重要分支是 deliberative alignment：不是只让模型记住安全分类，而是直接教给模型安全规范文本，并训练它在 CoT 中先对规范进行推理再作答。[3]

这一点说明 o 系列的 “reasoning policy” 不仅用于数学和代码，也被用于安全决策。

5. “o2”到底是什么？——必须纠正的命名误区

结论：截至公开资料，OpenAI 没有发布过 o2，也没有公开过一套名为 “o2” 的训练方案。OpenAI 的研究/产品目录直接从 o1 跳到 o3。[4]

可靠媒体在 2024 年 12 月报道：OpenAI 跳过 o2，是为了避免与英国电信公司 O2 的名称冲突/混淆。[7] 这属于命名层面的解释，不意味着技术上存在一个完成后被隐藏的 “o2 代模型”。

因此，本报告不制作 “o2 技术细节表”。更合理的技术路线理解是：o1 后续研究继续扩大 RL 与推理计算，最终公开版本命名为 o3。

6. o3：从“会推理”到“通用推理策略 + 工具/视觉”

6.1 核心证据：继续扩大 general-purpose RL

OpenAI 与 o3 contributors 的论文 “Competitive Programming with Large Reasoning Models” 提供了最直接的训练路线证据：o1-IOI 依赖大量手工设计的竞赛推理策略，而后来的 early o3 checkpoint 在标准约束下即可达到 IOI 金牌水平。作者总结，扩大 “通用强化学习” 比依赖领域手工启发式更具可扩展性。[5]

这说明 o3 的方向不是把越来越多任务写成专用 pipeline，而是把 “如何思考、如何验证、如何选择策略” 更多交给一个统一的 RL-trained policy 自己学。

6.2 o3 的 test-time compute：更明显的搜索/长思考行为




图 3 | ARC Prize 报告的 o3-preview 结果：low compute 约 75%，higher compute 约 87%。该图证明 test-time compute 的能力增益，不证明具体内部搜索算法。

ARC Prize 记录显示，o3-preview 在 ARC-AGI-1 上从较低 test-time compute 的约 75% 提升到更高 compute 下的约 87%。[15] 这强化了 o1 已出现的 test-time scaling 规律。

François Chollet/ARC Prize 将 o3 的行为解释为在自然语言“程序”（CoT）空间里进行 test-time program search。[16] 这一解释对理解行为很有价值，但属于外部分析，不能等同于 OpenAI 已确认使用显式 MCTS 或某种树搜索实现。

6.3 工具使用进入强化学习训练

o3 正式版的重大变化是 agentic tool use。OpenAI 明确披露：模型通过 reinforcement learning 学习如何使用工具，而且不只是“会调用 API”，还学习“何时应该调用、调用哪个工具、如何把结果组合回推理”。[6] 这会把 RL 环境从“题目→文本答案”扩展为“题目→思考→工具动作→观察→继续思考→最终答案”的多步交互轨迹。换句话说，o3 已经开始从 reasoning model 向 reasoning agent 过渡。

6.4 视觉信息进入推理链

OpenAI 还称 o3/o4-mini 首次可以把图像直接整合进 chain-of-thought：不仅识别图像，还能在思考过程中结合图像，并在有工具时执行旋转、缩放、转换等操作。[6]

这意味着训练数据/环境至少需要覆盖“视觉观察→推理→动作/答案”的联合策略，而不再局限于纯文本数学题。

7. o1 vs “o2” vs o3：一张表看清楚

维度	o1	o2	o3
公开状态	2024 发布	不存在公开发布	2024 预览，2025 发布
核心训练	大规模 RL 训练 CoT	无可验证信息	继续扩大通用 RL
test-time scaling	明确存在	-	更强，ARC 等显示显著 compute scaling
工具训练	早期产品能力有限	-	RL 训练何时/如何用工具
视觉推理	不是最初 o1 主轴	-	图像可进入推理链
领域工程	可叠加专用策略，如 o1-IOI	-	更倾向用通用 RL 吸收专用策略能力
已公开 RL 算法	未公开	-	未公开
已公开奖励细节	未公开	-	未公开

8. 最可信的“训练流水线重建”——哪些是事实，哪些是推断

下面给出一个工程上合理、且与公开证据一致的抽象流水线。注意：第 1、2、4、5 层有较强官方依据；第 3 层中的具体算法选择属于推断空间。

1. 强 base model：先有具备广泛知识、代码和语言能力的预训练模型。Reuters 报道 o1 的“secret sauce”是对 base model 之上的另一阶段训练。[13]
2. 构造可验证/可评分任务环境：数学、代码、科学等领域尤其适合，因为最终答案能自动验证，降低奖励噪声。

- 3. 生成多样推理轨迹并评分：可能包括长 CoT、重试、自检、采样多个候选，以及 outcome/process reward 的某种组合；具体机制 OpenAI 未公开。
- 4. 通过大规模 RL 更新 policy：让高奖励的推理模式更可能出现，低收益/错误路径概率下降。o1/o3 的官方资料都明确支持这一层。
- 5. 推理阶段动态分配 compute：困难问题允许模型生成更长的内部推理，或进行更多探索与验证；o1/o3 都体现 test-time scaling。
- 6. o3 扩展到交互式环境：把工具调用、视觉观察、Python/web/file 等动作也纳入 RL 轨迹，学习“何时行动、如何行动”。

9. 用开放模型反推“可能的工程空间”：DeepSeek-R1、Kimi k1.5、QwQ

这些模型不是 o1/o3 的复制品，但它们证明：只要奖励可验证、RL rollout 足够大、基础模型足够强，长推理能力可以通过后训练显著涌现。因此它们是理解 OpenAI 路线的最佳旁证之一。

系统	公开训练关键信息	对理解 o1/o3 的意义
DeepSeek-R1-Zero / R1	R1-Zero 可从 base model 直接做大规模 RL；R1 加 cold-start/SFT + 多阶段 RL；使用 GRPO	证明“reasoning via RL”可公开复现；但不能证明 OpenAI 使用 GRPO
Kimi k1.5	长上下文 RL、改进 policy optimization；论文强调不依赖 MCTS/value function/PRM	说明强推理并不必然要求复杂显式树搜索
QwQ-32B	在强 base model 上继续扩大 RL	说明 RL scaling 可显著提高中等参数规模模型推理能力

一个关键方法论结论：看到 o3 会“回溯/验证/尝试多个思路”，不能自动推出“内部一定有 MCTS”。长 CoT + RL 本身就可能学出类似搜索的行为；Kimi k1.5 的公开结果正说明复杂树搜索不是唯一可行路径。[10]

10. “搜索”到底发生在哪里？

讨论 o1/o3 时，“search”经常混用，至少应区分三类：

- 训练数据搜索：为了产生高质量 trajectory，训练系统可以并行采样很多答案，过滤正确轨迹再学习。
- 策略内部的序列搜索：模型在单条长 CoT 中通过“等等、换一种方法、检查一下”等 token 序列执行隐式回溯。
- 显式推理时搜索：系统在推理阶段并行生成多个 trajectory、打分、选择/继续扩展。公开资料不能确认 o1/o3 对普通请求究竟采用哪一种固定实现。

ARC Prize 对 o3 的“natural-language program search”描述更接近行为层面的第 2/3 类解释，不是内部软件架构披露。[16]

11. 为什么 o3 会比 o1 强：从训练经济学解释

从现有证据看，o3 的进步更像“四个 scaling 同时发生”，而不是单一算法突破：

- 更大的 reasoning RL run：OpenAI 论文直接强调 scaled-up general-purpose RL。[5]
 - 更强/更多样的 reasoning environments：代码、数学、科学、视觉、多工具任务更广。
 - 更大的 test-time compute budget：ARC-AGI 显示高 compute 下能力显著上升。[15]
 - 把工具反馈变成环境 observation：模型能把搜索、代码执行、文件分析等外部信息接进推理循环。[6]
- 这四项共同把系统从“一个更会做题的 LLM”变成“能够探索、验证、调用外部能力并持续修正方案的策略模型”。

12. OpenAI 仍然没有公开的关键细节

未知项	为什么重要	当前可否断言
o1/o3 的 base model 架构/参数量	决定预训练能力上限与 RL 可塑性	不能
RL 算法（PPO/GRPO/自研）	决定稳定性、样本效率、基础设施	不能
reward model / verifier 结构	决定错误信号与泛化	不能
process reward 是否为主	影响信用分配与可解释性	不能
是否常规使用 MCTS/树搜索	影响 test-time compute 形态	不能
训练 rollout 数量/上下文长度	决定探索覆盖度与成本	不能
synthetic data 比例	决定数据扩展方式	不能
o3 与 o1 的 base-model 关系	决定提升来自 base 还是 post-training	不能完全确定

13. 对企业训练 reasoning model 的可借鉴路线

如果目标不是复刻 OpenAI 的商业机密，而是复现其“路线”，公开证据给出的工程优先级相当清楚：

7. 先把任务改造成可验证环境：代码单测、数学答案、SQL 执行、规则检查、模拟器得分，比先设计复杂 RL 算法更重要。
 8. 从强 base model 出发，建立高吞吐 rollout 基础设施，能并行生成并过滤大量 reasoning trajectories。
 9. 先做 outcome-verifiable RLVR；只有在稀疏奖励或长链信用分配成为瓶颈时，再考虑 PRM/process reward。
 10. 把 test-time compute 当成产品参数：低/中/高 reasoning effort，按任务价值动态分配成本。
 11. 下一阶段是 tool-use RL：让模型在真实工具环境中学习动作策略，而不是只做函数调用 SFT。
- 这与公开模型的经验一致：DeepSeek-R1 展示 RLVR 的强度，Kimi k1.5 展示长上下文 RL 可以不依赖复杂 MCTS，o3 则显示通用 RL 最终可以吸收大量原本靠手工 pipeline 才能实现的能力。[5][9][10]

14. 对 o1/o3 内部机制的“可证伪假设”

为了避免玄学推测，可以把外界常见观点改写成可证伪假设：

假设	支持证据	反证/保留意见	可信度
核心是 RL 训练长 CoT	OpenAI 官方反复确认	算法细节未知	高
o3 主要靠放大通用 RL	OpenAI o3 作者论文明确总结	base model 改进也可能贡献	高
o3 使用显式树搜索/MCTS	ARC 行为看起来像 search	OpenAI 未确认；Kimi 强结果无需 MCTS	低-中
o1/o3 依赖 PRM	OpenAI 有 PRM 研究积累	无 o1/o3 官方确认	中-低
奖励主要来自可验证终局	数学/代码特别受益；同类开放模型证实	开放域任务仍需其他 reward	中

推理计算可作为新 scaling axis	o1/o3 官方与独立曲线均支持	边际收益最终会递减	高
-----------------------	------------------	-----------	---

15. 总结：OpenAI o 系列真正的路线

如果把所有宣传、命名和 benchmark 都剥离掉，OpenAI o1→o3 的主线可以浓缩为一句话：

把“推理”从提示技巧变成可通过大规模强化学习优化、并能在推理时继续投入计算的策略；随后把这个策略从文本推理扩展到工具、视觉和多步行动。

o1 证明了 reasoning RL + test-time compute 是新的 scaling 轴；o3 证明这条轴可以继续扩大，并逐步替代手工领域 pipeline。所谓 o2，并不是一代有公开训练配方的模型，而是命名上被跳过的一环。

因此，研究 o 系列时最值得追踪的不是“某个神秘提示词”，而是四个变量：可验证奖励环境、RL rollout 规模、推理上下文/计算预算、工具交互环境。它们共同决定下一代 reasoning agent 的上限。

参考资料与证据索引

- [1] OpenAI, Learning to reason with LLMs, 2024-09-12. 证据等级: A
<https://openai.com/index/learning-to-reason-with-llms/>
- [2] OpenAI, OpenAI o1 System Card, 2024-12-05. 证据等级: A
<https://openai.com/index/openai-o1-system-card/>
- [3] OpenAI, Deliberative alignment: reasoning enables safer language models, 2024-12-20. 证据等级: A
<https://openai.com/index/deliberative-alignment/>
- [4] OpenAI Research / o-series index; OpenAI o3-mini, 2025-01-31. 证据等级: A
<https://openai.com/research/>
- [5] OpenAI et al., Competitive Programming with Large Reasoning Models, arXiv:2502.06807, 2025. 证据等级: A
<https://arxiv.org/abs/2502.06807>
- [6] OpenAI, Introducing OpenAI o3 and o4-mini, 2025-04-16. 证据等级: A
<https://openai.com/index/introducing-o3-and-o4-mini/>
- [7] The Verge, OpenAI previews o3 and explains skipping o2, 2024-12-20. 证据等级: B
<https://www.theverge.com/2024/12/20/24326036/openai-o1-o2-o3-reasoning-model-testing>
- [8] Zeng et al., Scaling of Search and Learning: A Roadmap to Reproduce o1..., arXiv:2412.14135. 证据等级: D
<https://arxiv.org/abs/2412.14135>
- [9] DeepSeek-AI et al., DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning, arXiv:2501.12948. 证据等级: D
<https://arxiv.org/abs/2501.12948>
- [10] Kimi Team, Kimi k1.5: Scaling Reinforcement Learning with LLMs, arXiv:2501.12599. 证据等级: D
<https://arxiv.org/abs/2501.12599>
- [11] Qwen Team, QwQ-32B: Embracing the Power of Reinforcement Learning, 2025-03-06. 证据等级: D
<https://qwenlm.github.io/blog/qwq-32b/>
- [12] Lightman et al., Let's Verify Step by Step, arXiv:2305.20050, 2023. 证据等级: A/D
<https://arxiv.org/abs/2305.20050>
- [13] Reuters, OpenAI and rivals seek new path to smarter AI as current methods hit limitations, 2024-11-11. 证据等级: B
<https://www.reuters.com/technology/artificial-intelligence/openai-rivals-seek-new-path-smarter-ai-current-methods-hit-limitations-2024-11-11/>
- [14] Noam Brown, Learning to Reason with LLMs, Simons Institute talk, 2024-09-26. 证据等级: B
<https://simons.berkeley.edu/talks/noam-brown-openai-2024-09-26>
- [15] ARC Prize, ARC-AGI-1 / o3-preview results and test-time compute analysis. 证据等级: C
<https://arcprize.org/arc-agi/1>
- [16] ARC Prize, OpenAI o3 Breakthrough High Score on ARC-AGI-Pub, 2024-12-20. 证据等级: C
<https://arcprize.org/blog/oai-o3-pub-breakthrough>
- [17] ARC Prize, Analyzing o3 and o4-mini with ARC-AGI, 2025-04-22. 证据等级: C
<https://arcprize.org/blog/analyzing-o3-with-arc-agi>
- [18] OpenAI, o3 and o4-mini System Card / Deployment Safety Hub. 证据等级: A
<https://deploymentsafety.openai.com/>

注: OpenAI 不公开原始隐藏 Chain-of-Thought。本报告讨论的是训练范式与公开行为证据, 不试图重建或披露任何模型的私有内部思维文本。

检索日期: 2026-08-16。对于后续产品(如 GPT-5 系列)只在必要时作为路线背景, 不将其训练细节倒推为 o1/o3 的已知事实。