

苏剑林研究专题 01：研究思想与时间线

从任务建模、Transformer 到现代 LLM 架构

2026-08-14

Contents

摘要	1
1. 研究时间线：从任务建模到基础架构	2
1.1 2017-2019：概率生成模型与数学建模	2
1.2 2019-2021：BERT、信息抽取与句向量	2
1.3 2021-2023：RoPE 与 Transformer 基础结构	2
1.4 2023-2025：Long Context、Attention、Optimizer	2
1.5 2025-2026：团队级大模型研究	2
2. 五种最有辨识度的研究方法	2
2.1 重新定义预测对象	2
2.2 先写约束，再求满足约束的结构	3
2.3 优先找简单数学解释	3
2.4 把工程故障升级为研究问题	3
2.5 建立统一视角	3
3. 研究版图：按“问题”而不是“论文”分类	3
4. 为什么这些路线最终会汇合	3
5. 评价研究贡献时的三个边界	4
5.1 原创方法、公开分析、团队论文应分开	4
5.2 工业采用不是理论证明	4
5.3 博客的价值常在推导过程	4
6. 推荐的系统阅读顺序	4
7. Know-how / Know-why	4
8. Gotchas	4
复习清单	4
参考资料（精选）	5

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

苏剑林的研究不能被压缩成“RoPE 作者”这一单点标签。更准确的观察是：他的研究长期围绕**如何重新表述问题**展开，并不断把数学结构转化为可实现的深度学习模块。早期工作涉及 GAN、VAE、概率距离与生成模型；BERT 时代进入信息抽取、句向量与任务建模；随后集中到 Transformer 位置编码、长上下文、训练稳定性、

优化器和高效 Attention；最近又参与 Kimi 系列关于 RL scaling、MoE、MuonClip 和 Kimi Linear/KDA 的团队研究。

本专题不按论文列表机械罗列，而是给出一张“问题谱系图”：哪些问题来自 NLP 任务建模，哪些来自 Transformer 基础结构，哪些来自大规模训练的工程瓶颈，以及它们为什么会自然汇合到现代 LLM 架构。

1. 研究时间线：从任务建模到基础架构

1.1 2017-2019：概率生成模型与数学建模

这一阶段的重要关键词包括 GAN、VAE、概率距离、对偶形式、Lipschitz 约束以及生成模型训练稳定性。GAN-QP 与“Training GANs via Turing Test”都体现出一个共同特征：不是在已有目标函数上加一个小修补，而是重新追问“判别器究竟在估计什么”“两个分布应该以何种比较对象出现”。

这段经历很重要，因为后续 RoPE、GlobalPointer、Muon 等工作依旧采用同样的研究姿势：先找 **formulation** 中最别扭的地方，再换一种数学对象表示它。

1.2 2019-2021：BERT、信息抽取与句向量

BERT 时代的研究重点转向三个问题：

- 信息抽取是否一定要写成 token-level sequence labeling？
- 关系抽取是否一定要先枚举实体对再分类？
- BERT 的句向量空间为什么高度各向异性，是否一定需要一个复杂神经网络才能修复？

由此可以串起 CasRel、BERT-whitening、SimBERT，以及后来 GlobalPointer 的思想背景。

1.3 2021-2023：RoPE 与 Transformer 基础结构

RoFormer/RoPE 把位置编码从“在 token embedding 上加一个向量”改写成“让 Q/K 的内积自然产生相对位置”。之后研究继续进入 Transformer 初始化、归一化、深度稳定性和长度外推。此时研究对象已经从下游任务模块转移到 Transformer 的底层数学结构。

1.4 2023-2025：Long Context、Attention、Optimizer

RoPE 外推、NTK 视角、ReRoPE、MHA/MQA/GQA/MLA、Linear Attention，以及 Muon/Moonlight，都在回答同一类 scaling 问题：

当序列长度、模型宽度、训练 token 和总参数量提升几个数量级时，原来在小模型上“能跑”的结构是否仍然稳定、高效？

1.5 2025-2026：团队级大模型研究

在 Kimi k1.5、Kimi K2、Kimi Linear 等公开团队论文中，可以看到几条历史研究线汇合：

- long context 与 inference-time / RL scaling；
- matrix-aware optimizer 与 MuonClip；
- MoE 与万亿参数规模；
- linear/recurrent attention 与 KDA；
- MLA、KV-cache 与高效解码。

需要强调：这些是团队成果。作者列表表明参与，但公开材料通常不足以精确拆分每个模块由谁主导。

2. 五种最有辨识度的研究方法

2.1 重新定义预测对象

GlobalPointer 不再预测每个 token 的 BIO 标签，而是对 (i, j, c) 这个 span-category 三元组打分；CasRel 不直接枚举实体对，而把关系视为 subject 到 object 的映射。换对象后，许多“异常情况”会从补丁问题变成自然情况。

2.2 先写约束，再求满足约束的结构

RoPE 的典型要求是：位置 m, n 的 Q/K 变换后，内积中的位置因素最好只依赖 $m - n$ 。于是寻找满足

$$R_m^\top R_n = R_{n-m}$$

的变换族，二维旋转自然出现。这种推导路线比“试很多 embedding 看哪个分高”更接近结构设计。

2.3 优先找简单数学解释

BERT-whitening 用均值与协方差的线性变换修复句向量空间；NBCE 用概率组合与窗口分解扩展可利用上下文；很多优化器文章先从范数、尺度和矩阵几何解释，而不是先增加一个复杂网络。

2.4 把工程故障升级为研究问题

loss spike、QK logit 失控、update RMS 不匹配、超深 Transformer 不稳定，本来都可以被当成“调参问题”。但如果持续追踪变量尺度、初始化、残差路径和矩阵更新，就可能产生新的 parameterization 或 optimizer 设计。

2.5 建立统一视角

典型统一关系包括：

- Attention 与 RNN / recurrent state;
- RoPE 与复数旋转;
- 多标签分类与 pairwise ranking;
- Muon 与矩阵正交化/极分解;
- 长上下文与频率尺度;
- MQA/GQA/MLA 与 KV-cache 的信息压缩。

3. 研究版图：按“问题”而不是“论文”分类

问题层	代表主题	真正矛盾
NLP 任务建模 表示学习 Transformer 结构 Long Context 推理效率	CasRel, GlobalPointer, ZLPR Whitening, SimBERT RoPE, 归一化, 初始化 NTK 视角, ReRoPE, NBCE MQA/GQA/MLA, Linear Attention	标签空间/预测对象设计不自然 语义空间几何与生成/检索统一 位置、深度、尺度稳定性 训练长度与推理长度不匹配 KV cache 与 $O(n^2)$
优化	Muon, Moonlight, MuonClip	参数是矩阵，但 Adam 是逐元素缩放
大模型系统 推理能力	MoE, Kimi K2 Kimi k1.5	参数规模、激活规模、稳定训练 RL compute / long CoT scaling

4. 为什么这些路线最终会汇合

在小规模 NLP 中，一个任务 formulation 的收益可能只是 F1 的几个点；在 LLM 中，同类思想会放大为训练与推理成本问题。例如：

- 位置编码决定能否稳定做长上下文;
- Attention 结构决定 KV-cache 和吞吐;
- 参数更新尺度决定 10T+ token 训练是否出现 loss spike;
- 数据/任务表示决定监督信号是否容易学习。

因此，“重新定义问题”并不是风格偏好，而是 scaling 后决定系统上限的方法。

5. 评价研究贡献时的三个边界

5.1 原创方法、公开分析、团队论文应分开

研究博客可以包含很深的原创推导，但“公开分析某方法”和“论文中提出该方法”不是同一件事。阅读时应记录：idea 来源、论文作者、博客推导、代码实现、工业采用分别是谁。

5.2 工业采用不是理论证明

RoPE、Muon、MLA/KDA 等技术在大模型中取得效果，并不意味着它们在所有规模、所有数据和所有硬件下都占优。规模、训练预算、上下文和 kernel 实现都会改变结论。

5.3 博客的价值常在推导过程

很多“科学空间”文章的价值不在最后一句结论，而在中间如何把现象写成公式、如何从边界情况否定一个解释、如何用最小实验区分假设。

6. 推荐的系统阅读顺序

如果目标是理解现代 LLM，建议采用下面的依赖链：

1. RoPE 第一性原理；
2. 长度外推与频率视角；
3. 初始化、归一化与稳定性；
4. MHA -> MQA -> GQA -> MLA；
5. AdamW -> Muon -> Moonlight -> MuonClip；
6. Linear Attention -> Delta Rule -> KDA；
7. MoE / Kimi K2；
8. RL scaling / Kimi k1.5。

而如果目标是学习“如何做研究”，建议反过来先看 GlobalPointer、Whitening、RoPE 这类结构非常干净的工作，再看大规模系统问题。

7. Know-how / Know-why

Know-how: 阅读一项工作时建立四列笔记：原问题、旧 formulation、重新定义后的对象、最关键等式。只要四列写不清楚，通常说明还停留在“知道方法名”。

Know-why: 真正高复用的能力不是记某个模块，而是识别“当前困难究竟来自模型能力不足，还是问题表示方式本身不自然”。后者一旦被修正，往往同时简化 loss、decode、边界条件和实现。

8. Gotchas

- 不要把所有科学空间文章都自动视为正式论文结论。
- 不要把 Kimi 团队成果按个人博客风格推测作者分工。
- 不要把“公式更漂亮”当成效果更好；需要训练消融。
- 不要忽略硬件实现。Attention/optimizer 的理论 FLOPs 与实际吞吐可能差距很大。
- 不要把历史时间线理解成完全线性；生成模型、矩阵分析等主题后来会再次回流。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. **定义题：**核心对象、公式和变量分别是什么？
2. **推导题：**为什么这种结构能够解决原问题？关键等式如何得到？
3. **工程题：**实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. **迁移题：**如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- RoFormer: Enhanced Transformer with Rotary Position Embedding —<https://arxiv.org/abs/2104.09864>
- CasRel —<https://arxiv.org/abs/1909.03227>
- BERT-whitening —<https://arxiv.org/abs/2103.15316>
- GlobalPointer —<https://arxiv.org/abs/2208.03054>
- GAN-QP —<https://arxiv.org/abs/1811.07296>
- Muon is Scalable for LLM Training —<https://arxiv.org/abs/2502.16982>
- Kimi k1.5 —<https://arxiv.org/abs/2501.12599>
- Kimi K2 —<https://arxiv.org/abs/2507.20534>
- Kimi Linear —<https://arxiv.org/abs/2510.26692>
- 科学空间—<https://spaces.ac.cn/>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。