

苏剑林研究专题 02：RoPE 从第一性原理完整推导

从旋转群、复数相位到工程实现与边界条件

2026-08-14

Contents

摘要	1
1. 问题：Attention 为什么“不认识顺序”	2
2. 从目标性质开始	2
3. 二维旋转：RoPE 的最小单元	2
4. 复数形式：为什么旋转写起来更简单	3
5. 从 2D 推到 d 维	3
6. 与原始 Sinusoidal Position Encoding 的关系	3
7. 实现：rotate-half 到底在做什么	3
8. 为什么通常只旋转 Q/K，不旋转 V	4
9. “远距离衰减”应该怎么理解	4
10. RoPE 的优势来自什么	4
11. Gotchas	4
11.1 位置索引错一位	4
11.2 cos/sin cache 的 dtype	4
11.3 不同 RoPE 实现的维度配对	4
11.4 “RoPE 支持无限长度”是错误说法	4
12. Know-how	5
13. Know-why	5
复习清单	5
参考资料（精选）	5

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

RoPE (Rotary Position Embedding) 最值得学习的不是 $\sin/\cos$ 代码，而是其从目标约束反推结构的推导方法。本专题从 Attention 为什么需要位置信息出发，先构造理想性质，再从二维旋转、复数表示到高维分块旋转完整推导 RoPE；随后解释频率、相对距离、衰减直觉、实现方式与常见错误。

1. 问题：Attention 为什么“不认识顺序”

标准 self-attention 的核心是

$$A_{mn} = \frac{q_m^\top k_n}{\sqrt{d}}.$$

如果输入 token 的内容向量相同，仅仅交换序列位置，而 Q/K 的计算又没有位置依赖，那么内积结构本身对排列是等变的。语言却强依赖顺序，因此必须向 Q/K/V 或 hidden state 注入位置。

最经典的绝对位置方案是

$$h_m = x_m + p_m,$$

但这只是“让 hidden state 知道绝对位置”，并没有直接保证 Attention score 以一种自然方式表示相对距离。

2. 从目标性质开始

设内容向量是 q, k ，位置分别为 m, n 。希望找到位置相关变换 $f_q(q, m)$ 、 $f_k(k, n)$ ，使

$$\langle f_q(q, m), f_k(k, n) \rangle$$

中的位置因素主要依赖相对位置 $m - n$ ，而不是必须单独记住 m, n 。

一个极自然的构造是

$$f_q(q, m) = R_m q, \quad f_k(k, n) = R_n k,$$

并要求

$$R_m^\top R_n = R_{n-m}.$$

如果 R_t 是正交旋转且满足群性质 $R_a R_b = R_{a+b}$ ，则要求自动成立。

3. 二维旋转：RoPE 的最小单元

二维旋转矩阵为

$$R(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

令位置 m 对应角度 $m\theta$:

$$R_m = R(m\theta).$$

那么

$$R_m^\top R_n = R(-m\theta)R(n\theta) = R((n-m)\theta).$$

所以

$$(R_m q)^\top (R_n k) = q^\top R_{n-m} k.$$

这就是 RoPE 最核心的一行推导：**Q/K 各自使用绝对位置旋转，但两者做内积后只剩相对位置。**

4. 复数形式：为什么旋转写起来更简单

把二维向量 (x_1, x_2) 写成复数

$$z = x_1 + ix_2.$$

乘以单位复数

$$e^{im\theta} = \cos(m\theta) + i \sin(m\theta)$$

正好对应旋转。于是位置编码可以写成

$$q_m = q e^{im\theta}, \quad k_n = k e^{in\theta}.$$

复内积中的共轭会产生

$$e^{-im\theta} e^{in\theta} = e^{i(n-m)\theta}.$$

因此 RoPE 的“相对位置”性质不是偶然的 trig trick，而是复数相位差的直接结果。

5. 从 2D 推到 d 维

高维向量按相邻维度两两分组。对第 j 个二维子空间使用频率 θ_j ：

$$R_m = \text{diag}(R(m\theta_0), R(m\theta_1), \dots, R(m\theta_{d/2-1})).$$

常见频率为

$$\theta_j = \text{base}^{-2j/d},$$

其中 base 常见取 10000，但在现代长上下文模型中也会出现其他 base 与缩放策略。

不同维度对应不同“空间频率”：高频维对短距离相位变化敏感，低频维在很长距离上仍缓慢变化。于是一个 token pair 的相对位置由多尺度相位共同编码。

6. 与原始 Sinusoidal Position Encoding 的关系

两者都使用多频 sin/cos，但注入位置的方式不同。

方案	位置注入	Attention 中相对位置如何出现
Sinusoidal PE	加到 hidden state	由网络间接学习
RoPE	旋转 Q/K	内积代数上直接产生相位差

所以“都用了 sin/cos”不是最关键的相似性；更关键的是 RoPE 把位置结构放到了内积几何里。

7. 实现：rotate-half 到底在做什么

常见代码形式是

```
q_rot = q * cos + rotate_half(q) * sin
k_rot = k * cos + rotate_half(k) * sin
```

其中 `rotate_half` 对每个二维 `pair` 完成

$$(x_1, x_2) \mapsto (-x_2, x_1),$$

即乘以 90 度旋转矩阵。再结合 `cos` 与 `sin` 得到任意角旋转。

实现时有两种常见排列：

1. `interleaved`: $(x_0, x_1), (x_2, x_3), \dots$;
2. `half-split`: 前半维与后半维配对。

二者只要训练与推理保持一致都可以工作，但权重不能在不做转换的情况下跨实现直接混用。

8. 为什么通常只旋转 Q/K，不旋转 V

Attention score 是由 Q/K 内积决定“看谁”，因此相对位置最直接地作用在权重上。V 是被加权聚合的内容载体。旋转 V 不是代数上构造相对 score 的必要条件，而且会改变内容聚合的表示语义。

9. “远距离衰减”应该怎么理解

RoPE 论文和后续分析常讨论相对距离增大时的相关性变化。需要谨慎：RoPE 不是一个显式的单调距离衰减函数。多频余弦项会振荡，不同频率叠加后整体呈现某种距离敏感性，但并不保证每个距离都严格更小。

更好的理解是：

相对位移越大，多频相位的整体对齐模式越复杂，固定内容向量维持高相似的条件通常变得更苛刻。

10. RoPE 的优势来自什么

- 不需要一个随最大长度增长的位置 embedding 表；
- 内积中天然携带相对位置；
- 计算成本低，只是逐元素 `sin/cos` 与重排；
- 与多头 Attention、MQA/GQA 等结构容易组合；
- 频率结构为后续长度缩放提供了可分析对象。

11. Gotchas

11.1 位置索引错一位

padding、KV-cache offset、prefix cache 和 chunked prefill 都可能让 `position_ids` 不再从零简单递增。一旦 Q/K 使用的绝对位置不一致，Attention score 的相位差就会错。

11.2 cos/sin cache 的 dtype

在很长位置上用低精度直接计算 trig 可能产生显著相位误差。常见做法是高精度生成频率/角度，再 cast 到模型 dtype。

11.3 不同 RoPE 实现的维度配对

`interleaved` 与 `half-split` 的差异会导致加载权重后结果不一致。必须确认模型实现与 checkpoint 一致。

11.4 “RoPE 支持无限长度”是错误说法

公式可以在任意位置求值，不等于模型在训练长度外仍保持能力。外推问题来自频率分布、训练支持集和 Attention 行为，而不是能否计算 $\sin(m\theta)$ 。

12. Know-how

调试 RoPE 时，最有效的单元测试不是直接跑语言模型，而是构造两个随机向量，验证

$$(R_m q)^\top (R_n k) \approx q^\top R_{n-m} k$$

在不同位置、不同 dtype、不同 cache offset 下都成立。然后再测 KV-cache incremental decoding 与 full-sequence decoding 是否一致。

13. Know-why

RoPE 的真正启发是：位置编码不一定是一个“加到 token 上的东西”，它可以是对内积空间的坐标变换。当任务依赖 pairwise interaction 时，把先验结构设计到 interaction operator 里，往往比把信息塞进输入后让网络自己恢复更直接。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. **定义题**：核心对象、公式和变量分别是什么？
2. **推导题**：为什么这种结构能够解决原问题？关键等式如何得到？
3. **工程题**：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. **迁移题**：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- RoFormer: Enhanced Transformer with Rotary Position Embedding —<https://arxiv.org/abs/2104.09864>
- 科学空间：Transformer 升级之路系列—<https://spaces.ac.cn/>
- Hugging Face Transformers 中各类 RoPE 实现可用于对照工程细节—<https://github.com/huggingface/transformers>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。