

苏剑林研究专题 03: RoPE -> NTK -> ReRoPE -> 长度外推

频率、坐标、相对距离与推理侧扩展的统一视角

2026-08-14

Contents

摘要	1
1. 什么叫长度外推	2
2. 频率视角：为什么超长位置会改变模型看到的分布	2
3. Position Interpolation：压缩坐标	2
4. NTK-aware 的直觉：不要所有频率一刀切	2
5. Dynamic NTK：长度变化时动态调整尺度	3
6. YaRN / 分频率缩放：把“短程”和“长程”职责分开	3
7. ReRoPE / 窗口化思路：限制相对距离而不是压整个坐标	3
8. 为什么“局部窗口 + 全局机制”经常有效	3
9. NBCE：从模型外部扩展“可利用上下文”	3
10. 如何评价长度外推方法	4
11. Gotchas	4
11.1 把“训练长度”当硬物理边界	4
11.2 只调 RoPE 不做继续训练	4
11.3 长度扩展与 KV-cache 是两个问题	4
11.4 “更大 base 一定更长”是误解	4
12. Know-how：如何做一套最小外推实验	4
13. Know-why	4
复习清单	5
参考资料（精选）	5

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

长度外推 (length extrapolation) 不是“把 `max_position_embeddings` 改大”这么简单。对 RoPE 模型而言，真正的问题是：训练阶段看到的位置与相位分布有限，而推理阶段把同一组频率推到更大的位置后，某些维度进入模型从未适应的相位区域。本专题围绕苏剑林长期分析的 RoPE 长度外推路线，串起 Position Interpolation、

NTK-aware scaling、Dynamic NTK、ReRoPE/窗口化思想及推理侧 NBCE，并解释各方法是在改“位置坐标”、改“频率”、改“Attention 范围”还是改“概率组合”。

1. 什么叫长度外推

设训练最大长度为 L_{train} ，推理希望处理 $L_{test} > L_{train}$ 。需要区分三种能力：

- 可计算：模型代码能接受这么长的位置；
- 不崩溃：loss/logit 没有数值异常；
- 有效外推：长距离检索、推理和生成能力仍然可靠。

RoPE 通常满足第一条，但第二、第三条需要额外技术。

2. 频率视角：为什么超长位置会改变模型看到的分布

第 j 个 RoPE 子空间的相位为

$$\phi_j(m) = m\theta_j.$$

训练时位置 $m \leq L_{train}$ ，因此该维度相位主要落在

$$[0, L_{train}\theta_j].$$

推理长度放大 s 倍后，相位区间也放大 s 倍。对于高频维，推理时可能经历大量训练阶段未覆盖的周期结构；对于极低频维，训练阶段甚至可能没走完一个完整周期。

所以长度外推可被理解为一个频率与坐标的 **out-of-distribution** 问题。

3. Position Interpolation：压缩坐标

最直接的方法是把推理位置 m 缩小：

$$m' = \frac{m}{s}, \quad s = \frac{L_{test}}{L_{train}}.$$

于是

$$\phi_j(m) = m\theta_j \rightarrow \phi'_j(m) = \frac{m}{s}\theta_j.$$

这样在 L_{test} 位置处的最大相位接近训练期的最大相位。

优点：简单、稳定、容易 finetune。

代价：所有频率都统一缩放，短距离 token 的相位差也被压小，可能降低局部位位置分辨率。

4. NTK-aware 的直觉：不要所有频率一刀切

苏剑林的相关分析强调：不同频率承担的相对位置尺度不同，统一插值未必最合理。高频更影响局部辨别，低频更关系长程。于是可以通过改变 RoPE base 或对不同频率做非均匀缩放，使伸长主要由低频维承担，同时尽量保留高频局部结构。

常见 RoPE 频率为

$$\theta_j = b^{-2j/d}.$$

改变 base b 会以随维度变化的方式改变频率，因此不是简单的全局 $1/s$ 。

5. Dynamic NTK：长度变化时动态调整尺度

静态 scaling 在目标长度已知时容易设置，但实际服务请求长度变化很大。Dynamic NTK 类策略会根据当前序列长度决定缩放强度：短序列尽量使用原始 RoPE，只有超过训练长度时才逐渐改变 base/频率。

核心目标是兼顾：

short-context fidelity 与 long-context coverage.

6. YaRN / 分频率缩放：把“短程”和“长程”职责分开

更细致的方法会根据每个维度对应的波长

$$\lambda_j = \frac{2\pi}{\theta_j}$$

决定是否缩放。直觉上：

- 波长远小于训练窗口：已经见过很多周期，适合尽量保留；
- 波长远大于训练窗口：训练阶段几乎没有完整周期，需要更积极地扩展；
- 中间区域：平滑过渡。

这类方法的本质是频率选择性插值。

7. ReRoPE / 窗口化思路：限制相对距离而不是压整个坐标

另一条路线是直接处理相对位移。假设模型训练时可靠的相对距离范围大约在窗口 w 内，那么对于距离超过 w 的 token pair，不必继续把 RoPE 相位推向越来越大的未见区域，而可以做截断、重映射或分段处理。

概念上可以写成

$$\Delta' = g(\Delta), \quad \Delta = m - n,$$

其中 g 在小距离近似恒等，在大距离进行限制或压缩。

这种路线与 Position Interpolation 的差别是：

- PI 先改变每个 token 的绝对坐标；
- ReRoPE 类方法更直接控制 pairwise 相对距离进入 Attention 的方式。

8. 为什么“局部窗口 + 全局机制”经常有效

自然语言中大量依赖是局部的：语法、短语、指代、代码局部结构。长距离能力更像稀疏需求。如果为所有 token pair 都强制保留最高精度的超长相对位置，成本和 OOD 风险都很大。

因此许多现代长上下文方案隐含采用分层思想：

local high-resolution + global low-resolution / retrieval / memory.

9. NBCE：从模型外部扩展“可利用上下文”

Naive Bayes-based Context Extension (NBCE) 展示了另一种路线：不一定修改位置编码或模型权重，而把超长 context 拆成多个模型可处理的窗口，再对各窗口给出的条件概率进行组合。

设问题/目标为 y ，多个 context chunk 为 $c_1, \dots, c_K$ 。在近似条件独立假设下，可以构造类似

$$p(y \mid c_1, \dots, c_K) \propto p(y)^{1-K} \prod_{k=1}^K p(y \mid c_k)$$

的组合形式。它不是把模型真正变成 1M context Transformer，而是让有限窗口模型在推断层面融合更多证据。

10. 如何评价长度外推方法

仅看 perplexity 不够。至少需要：

- passkey / needle retrieval;
- 多 needle;
- 长文问答;
- 长代码依赖;
- 位置鲁棒性 (needle 放在头/中/尾);
- short-context regression;
- 不同长度的 loss/logit/entropy;
- KV-cache 与吞吐。

一个方法如果 128k retrieval 很好但 2k 常规任务明显下降，不能简单称为“更强”。

11. Gotchas

11.1 把“训练长度”当硬物理边界

模型实际见到的位置分布还受 packing、样本长度分布、document boundary 影响。标称 32k 训练并不代表每个 batch 都充分覆盖 32k 相位。

11.2 只调 RoPE 不做继续训练

某些 scaling 可以 zero-shot 生效，但高质量长上下文通常仍需要 continued pretraining / long-context finetuning 让模型适应新的 Attention 分布。

11.3 长度扩展与 KV-cache 是两个问题

即使数学上可以处理 1M context, MHA 的 KV cache 仍可能不可接受。必须和 MQA/GQA/MLA, quantized KV 或 linear attention 联合考虑。

11.4 “更大 base 一定更长”是误解

改变 base 同时改变各频率尺度和局部位置区分，效果依赖模型宽度、head dim、训练长度与后续训练。

12. Know-how: 如何做一套最小外推实验

1. 固定一个小模型与同一 checkpoint;
2. 实现原始 RoPE、PI、base scaling、动态 scaling 四组;
3. 先做不训练的 retrieval 曲线;
4. 再做少量 long-context continued pretraining;
5. 同时记录短上下文基准;
6. 对每个 head 分析 Attention entropy 与最大 logit;
7. 画长度 L 与准确率/损失的连续曲线，而不是只报 32k/128k 两点。

13. Know-why

长度外推的深层问题不是“模型有没有一个长位置编号”，而是训练得到的函数在新的相位/距离分布上如何延拓。任何 scaling 方法都在做归纳偏置选择：保局部、保全局、保频率还是保原分布，没有免费的统一最优。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. **定义题**：核心对象、公式和变量分别是什么？
2. **推导题**：为什么这种结构能够解决原问题？关键等式如何得到？
3. **工程题**：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. **迁移题**：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- RoFormer —<https://arxiv.org/abs/2104.09864>
- NBCE: Naive Bayes-based Context Extension —<https://arxiv.org/abs/2403.17552>
- 科学空间：Transformer 升级之路/长度外推复盘—<https://spaces.ac.cn/archives/9948>
- 科学空间（RoPE/NTK/ReRoPE 相关系列）—<https://spaces.ac.cn/>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。