

# 苏剑林研究专题 04: GlobalPointer / ZLPR / 多标签统一理论

从 BIO 标签到 span scoring, 从 BCE 到集合级排序

2026-08-14

## Contents

|                                       |   |
|---------------------------------------|---|
| 摘要                                    | 1 |
| 1. BIO 序列标注的隐含假设                      | 2 |
| 2. 重新定义对象：实体就是 (start, end, type)     | 2 |
| 3. GlobalPointer 的 score              | 2 |
| 4. 为什么它比“分别预测 start/end”更完整           | 2 |
| 5. 从二分类 BCE 到多标签全局损失                  | 3 |
| 6. ZLPR: zero-bounded + pairwise rank | 3 |
| 7. LogSumExp 为什么频繁出现                  | 3 |
| 8. Efficient GlobalPointer            | 3 |
| 9. 复杂度与 mask                          | 3 |
| 10. 解码为什么简单                           | 4 |
| 11. Gotchas                           | 4 |
| 11.1 不平衡不是“负样本多所以加权”这么简单              | 4 |
| 11.2 padding mask 必须在 loss 前彻底屏蔽      | 4 |
| 11.3 长实体与 RoPE                        | 4 |
| 11.4 threshold 不是永远等于 0               | 4 |
| 12. Know-how: 一个可复用的任务重构流程            | 4 |
| 13. Know-why                          | 4 |
| 复习清单                                  | 4 |
| 参考资料 (精选)                             | 5 |

**系列定位。**本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

**阅读方法。**不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

## 摘要

GlobalPointer 与 ZLPR 可以放在同一个思想框架里理解：把“标签判定”改写为正负集合之间的排序/边界问题，并让 **span** 本身成为预测对象。这条路线把 flat NER、nested NER、多标签分类和 span scoring 连

接起来。本专题从 BIO 序列标注的结构限制出发，推导 GlobalPointer 的 span score 与多标签交叉熵，再解释 ZLPR 为什么要把正负标签放进 LogSumExp 结构。

## 1. BIO 序列标注的隐含假设

传统 NER 把每个 token 赋予一个标签，例如 B-PER/I-PER/O。这相当于假设每个位置在一个单一标签链中具有唯一状态。对于嵌套实体：

[北京大学]  
[北京]

同一 token 同时属于多个 span，单一 BIO 状态不再自然。可以扩展标签集或堆多个层，但 formulation 变得越来越复杂。

## 2. 重新定义对象：实体就是 (start, end, type)

一个实体本来就可以写成

$$e = (i, j, c),$$

其中  $i$  是起点， $j$  是终点， $c$  是实体类型。于是任务直接变成：对每个候选三元组计算分数

$$s_{c,i,j},$$

并判断它是否为真实体。

嵌套实体不再特殊，因为  $(i_1, j_1, c_1)$  与  $(i_2, j_2, c_2)$  可以同时为正。

## 3. GlobalPointer 的 score

设编码器输出  $h_i$ 。对每个类别构造 start/end 表示：

$$q_{c,i} = W_{q,c} h_i, \quad k_{c,j} = W_{k,c} h_j.$$

最基本 span score 可以写为

$$s_{c,i,j} = q_{c,i}^\top k_{c,j}.$$

如果 Q/K 进一步使用 RoPE，则 score 自然携带相对位置信息，能更好表达 span 长度与边界关系。

## 4. 为什么它比“分别预测 start/end”更完整

分别预测 start probability 与 end probability 的方法隐含近似

$$p(i, j | c) \approx p(i | c)p(j | c),$$

但实际 start/end 是耦合的。GlobalPointer 直接对 pair 打分，相当于建模 joint compatibility。

## 5. 从二分类 BCE 到多标签全局损失

一个类别下可能存在多个正 span，也有大量负 span。最直接是对每个  $(i, j)$  做独立 BCE，但负样本数量巨大，而且独立 BCE 没有显式表达“所有正样本应整体高于负样本”的排序关系。

多标签交叉熵的一个典型形式可写为

$$L = \log \left( 1 + \sum_{i \in P} e^{-s_i} \right) + \log \left( 1 + \sum_{j \in N} e^{s_j} \right),$$

其中  $P$  是正集合、 $N$  是负集合。

第一项惩罚正样本分数过低，第二项惩罚负样本分数过高。

## 6. ZLPR: zero-bounded + pairwise rank

ZLPR 的思想可理解为：既希望正标签相对零边界为正、负标签相对零边界为负，又希望正负之间有合理排序。LogSumExp 充当平滑最大值：

$$\text{LSE}(z_1, \dots, z_n) = \log \sum_i e^{z_i}.$$

当某个最困难样本特别糟时，它会主导梯度；同时其他样本仍提供平滑信号。这比逐标签 BCE 更像一个集合级 margin/ranking 目标。

## 7. LogSumExp 为什么频繁出现

LogSumExp 有三个重要性质：

1. 近似 max，关注 hardest positive/negative；
2. 可微且所有样本都有梯度；
3. 数值上可以通过减去最大值稳定计算。

因此在多标签、对比学习、CRF partition function、Attention softmax 中都非常常见。

## 8. Efficient GlobalPointer

朴素 GlobalPointer 为每个类别维护独立的大投影矩阵，参数量随类别数增长。高效版本会共享主要投影，再通过较小的类别相关参数产生 score bias/调制，从而降低参数与显存开销。

核心思想是：span compatibility 的大部分几何可以跨类别共享，类别差异无需完全独立的一套 Q/K 空间。

## 9. 复杂度与 mask

长度为  $L$  时，所有  $(i, j)$  组合是  $O(L^2)$ 。实际需要：

- mask 掉  $j < i$ ；
- mask padding；
- 可选限制最大实体长度；
- 大类别数时注意  $B \times C \times L \times L$  的显存。

因此 GlobalPointer 非常适合中等长度 NER，但如果直接搬到超长文档，需要 window/chunk/sparse span 策略。

## 10. 解码为什么简单

若使用零阈值，多标签预测只需

$$s_{c,i,j} > 0.$$

没有 CRF 的 Viterbi，也不需要复杂 BIO 合法性修复。结构约束已经通过 span 坐标天然表达。

## 11. Gotchas

### 11.1 不平衡不是“负样本多所以加权”这么简单

大多数 span 为负，但 LogSumExp 聚合会让 hardest negative 主导。盲目再加极大的 class weight 可能导致训练不稳定。

### 11.2 padding mask 必须在 loss 前彻底屏蔽

如果把 padding span 以普通负样本加入 LSE，长短样本会产生不同数量的无意义负项，改变 loss 标度。

### 11.3 长实体与 RoPE

RoPE 对相对距离敏感，但“更长实体分数应该更低”不是目标本身。需要观察训练语料中的实体长度分布，避免模型只学长度先验。

### 11.4 threshold 不是永远等于 0

零边界来自目标函数的自然解释，但实际评测可根据 precision/recall 在验证集调 threshold，尤其在类别严重偏移时。

## 12. Know-how：一个可复用的任务重构流程

当遇到新的抽取任务时，先问：最终答案能否表示为一个结构化坐标，例如

$$(start, end, type, relation, role, \dots)?$$

如果可以，优先直接对“最终结构”打分，而不是先发明一套 token 标签再从标签恢复结构。这样通常能减少 decode mismatch。

## 13. Know-why

GlobalPointer 的价值不是“NER 又一个 head”，而是说明：**很多序列任务之所以难，是因为训练对象与最终评价对象不一致**。评价实体 span，却训练 token 标签，会额外引入编码/解码误差；直接训练 span score 则使目标对齐。

## 复习清单

建议在完成本专题后，能够回答下面四类问题：

1. **定义题**：核心对象、公式和变量分别是什么？
2. **推导题**：为什么这种结构能够解决原问题？关键等式如何得到？
3. **工程题**：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. **迁移题**：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

## 参考资料（精选）

- GlobalPointer: Novel Efficient Span-based Approach for Named Entity Recognition — <https://arxiv.org/abs/2208.03054>
- ZLPR: A Novel Loss for Multi-label Classification — <https://arxiv.org/abs/2208.02955>
- 科学空间: GlobalPointer / 多标签分类相关推导—<https://spaces.ac.cn/>

---

**版本说明：**2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。