

苏剑林研究专题 05: CasRel 与信息抽取 Formulation

把 relation classification 重写为 subject-to-object 映射

2026-08-14

Contents

摘要	1
1. 传统关系抽取的两个难点	2
2. CasRel 的核心重构	2
3. 第一级: Subject Tagger	2
4. 第二级: Relation-specific Object Tagger	2
5. Overlapping Triples 为什么自然了	3
6. 训练时的 teacher forcing	3
7. 与“联合抽取”是什么关系	3
8. 为什么不直接预测所有三元组张量	3
9. 与 GlobalPointer 的连接	3
10. 数据构建 Gotchas	3
10.1 字符级标注到 tokenizer 对齐	3
10.2 同名实体多次出现	3
10.3 subject/object 方向	4
11. 评价指标	4
12. Know-how: 如何判断是否适合 CasRel	4
13. Know-why	4
复习清单	4
参考资料 (精选)	4

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分: (1) 苏剑林本人署名论文/项目; (2) 其在“科学空间”中长期公开推导与分析的研究性文章; (3) 其参与的团队论文 (例如 Kimi 系列)。对于团队工作, 不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开, 并单独列出 gotchas、know-how 与 know-why。

摘要

CasRel(Cascade Binary Tagging Framework)代表了苏剑林早期信息抽取研究中非常典型的 formulation 重构: 把关系抽取从“实体对分类”改写为“关系是一类 subject-to-object 映射”。这样可以自然处理同一实体参与多个关系、一个 subject 对应多个 object 等 overlapping triples。本专题从传统 pipeline 的误差传播出发, 拆解 CasRel 的两级标注器、训练目标、推理流程与失败模式。

1. 传统关系抽取的两个难点

给定文本，目标是抽取三元组

$$(s, r, o).$$

常见 pipeline 是：

1. 先 NER 找实体；
2. 枚举实体对 (e_i, e_j) ；
3. 对每对做 relation classification。

问题包括：实体识别错误会向后传播；实体对数量近似 $O(E^2)$ ；同一实体对可能有多关系；重叠三元组需要额外规则。

2. CasRel 的核心重构

把每个关系 r 看成一个从 subject 到 object 的映射：

$$r : s \mapsto o.$$

于是抽取流程变成：

$$\text{text} \rightarrow \text{subjects} \rightarrow \text{objects conditioned on subject and relation}.$$

它不是先产生一个完整实体集合再做所有 pair classification，而是先确定 subject，再用 subject 条件化后续 object 抽取。

3. 第一级：Subject Tagger

对每个 token 预测是否为 subject 的 start/end。可用两个 sigmoid：

$$p_i^{s,start} = \sigma(w_s^\top h_i),$$

$$p_i^{s,end} = \sigma(w_e^\top h_i).$$

通过阈值和配对得到一个或多个 subject span。

4. 第二级：Relation-specific Object Tagger

选定 subject s 后，把 subject 表示注入 token hidden state：

$$\tilde{h}_i = h_i + g(h_s),$$

再对每个关系 r 预测 object start/end：

$$p_{i,r}^{o,start} = \sigma(W_{r,start} \tilde{h}_i),$$

$$p_{i,r}^{o,end} = \sigma(W_{r,end} \tilde{h}_i).$$

因此同一个 subject 可以在不同 relation head 下产生不同 object。

5. Overlapping Triples 为什么自然了

考虑：

```
Jobs --founded--> Apple
Jobs --CEO_of--> Apple
```

在实体对分类中，需要允许同一 pair 多标签；在 CasRel 中两个 relation channel 本来就是独立预测，因此不存在结构冲突。

再考虑：

```
Apple --located_in--> California
Google --located_in--> California
```

多个 subject 逐个条件化即可。

6. 训练时的 teacher forcing

训练阶段通常可以使用 gold subject 作为第二级条件，这让 object tagger 学到稳定映射。但推理时 subject 来自第一级预测，存在 train-test mismatch。

这是 CasRel 的一个重要 gotcha：第一级 recall 低时，整个三元组 recall 上限被锁死。可以通过 subject sampling、scheduled sampling 或联合训练缓解，但不能完全消除级联误差。

7. 与“联合抽取”是什么关系

CasRel 常被称为 joint extraction，因为同一编码器中联合学习 subject 与 relation-specific object，而不是完全独立的 NER + relation pipeline。但它仍然有级联结构：

$$\text{subject prediction} \rightarrow \text{object prediction}.$$

所以“joint”不等于“单步”。

8. 为什么不直接预测所有三元组张量

可以构造一个 $L \times L \times R$ 的 subject-object pair tensor，但序列较长时成本大，而且还要表示实体边界。CasRel 通过两级 boundary tagging 把搜索空间分解，计算更经济。

9. 与 GlobalPointer 的连接

CasRel 的 subject/object 都使用 start-end binary tag；GlobalPointer 后来进一步说明，start 与 end 可以直接联合成 span score。于是可以设想：

- subject 用 span scoring；
- 给定 subject 后，对每个 relation 的 object 再用 span scoring。

这体现研究脉络从“边界二分类”向“完整 span 作为基本对象”演化。

10. 数据构建 Gotchas

10.1 字符级标注到 tokenizer 对齐

中文数据常给字符 offset，而 BERT tokenizer 可能产生 wordpiece。必须保存 offset mapping，避免简单字符串查找在重复实体名时匹配错误。

10.2 同名实体多次出现

如果三元组只给实体字符串，没有 occurrence offset，需要决定标注哪一次。盲目把所有 occurrence 都标正可能创造数据集中不存在的关系。

10.3 subject/object 方向

某些关系在语义上可逆或数据标注方向不统一。模型会学习标注 schema，而不是自动理解“自然方向”。

11. 评价指标

关系抽取通常以 triple-level exact match 计算 precision/recall/F1。需要明确实体边界是否必须完全一致、relation label 是否包含 direction、文本 normalization 是否影响匹配。

仅看 relation classification accuracy 会掩盖实体定位错误。

12. Know-how: 如何判断是否适合 CasRel

CasRel 特别适合：

- 关系集合有限；
- 一段文本中 subject 数量不太大；
- 允许一个实体参与多个关系；
- 目标是精确三元组抽取。

如果关系种类上千、开放关系抽取或超长文档，则可能更适合 generative IE、span graph 或 retrieval-based schema linking。

13. Know-why

CasRel 最值得复用的思想是：不要把“关系”只看成 pair 的分类标签，也可以把它看成条件化的映射算子。一旦用 $r : s \mapsto o$ 表述，重叠关系从 exception 变成正常输出。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. **定义题**：核心对象、公式和变量分别是什么？
2. **推导题**：为什么这种结构能够解决原问题？关键等式如何得到？
3. **工程题**：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. **迁移题**：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- CasRel: A Novel Cascade Binary Tagging Framework for Relational Triple Extraction — <https://arxiv.org/abs/1909.03227>
- GlobalPointer — <https://arxiv.org/abs/2208.03054>
- 科学空间：信息抽取与关系抽取相关文章—<https://spaces.ac.cn/>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。