

苏剑林研究专题 06: BERT Whitening / SimBERT / Sentence Embedding

从各向异性、协方差到语义检索与生成统一

2026-08-14

Contents

摘要	1
1. 为什么 BERT hidden state 不天然就是句向量	2
2. Whitening 的统计学目标	2
3. 为什么 Whitening 可能提升语义相似度	2
4. Whitening 与 PCA 降维	3
5. 这和“去掉 top PCs”有什么不同	3
6. 数据泄漏与统计量估计	3
7. SimBERT: 检索与生成统一的动机	3
8. 为什么生成与检索可能互相帮助	3
9. 与后来对比学习句向量的关系	3
10. Gotchas	4
10.1 协方差矩阵病态	4
10.2 归一化顺序	4
10.3 训练集好不等于跨域好	4
11. Know-how: 最小实现	4
12. Know-why	4
复习清单	4
参考资料 (精选)	4

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

BERT 在 token-level 任务很强，但直接取 [CLS] 或平均池化得到的句向量往往并不是良好的语义度量空间。苏剑林参与的 BERT-whitening 工作用非常经典的均值/协方差变换修复各向异性，并可同时降维；SimBERT 则尝试把语义检索与相似句生成统一起来。本专题从 embedding geometry 出发，解释 anisotropy、whitening、PCA 降维与语义生成的联系。

1. 为什么 BERT hidden state 不天然就是句向量

BERT 的预训练目标主要是 MLM 等 token-level prediction，并没有直接优化

$$\cos(e(s_1), e(s_2))$$

去表示句子语义相似度。直接 pooling 后常出现：

- 不同句子之间余弦相似度整体偏高；
- embedding 集中在少数主方向；
- 某些频繁词/句法因素主导几何。

这被称为 anisotropy（各向异性）。

2. Whitening 的统计学目标

给定句向量 x ，均值为

$$\mu = \mathbb{E}[x],$$

协方差为

$$\Sigma = \mathbb{E}[(x - \mu)(x - \mu)^\top].$$

希望找线性变换 W ，使

$$y = W(x - \mu)$$

满足

$$\text{Cov}(y) = I.$$

因为

$$\text{Cov}(y) = W\Sigma W^\top,$$

如果做特征分解

$$\Sigma = U\Lambda U^\top,$$

可以取

$$W = \Lambda^{-1/2}U^\top.$$

3. 为什么 Whitening 可能提升语义相似度

如果原 embedding 的某些主方向拥有巨大方差，却主要反映词频、长度或模板，而非我们关心的语义，那么余弦距离会被这些方向支配。Whitening 把各方向方差归一，相当于重新平衡特征尺度。

它不是“创造新语义”，而是改变已有表示的度量几何。

4. Whitening 与 PCA 降维

如果只保留最大的 k 个特征方向，则

$$y = \Lambda_k^{-1/2} U_k^\top (x - \mu).$$

因此可以同时做到：

- 去相关；
- 方差归一；
- 降维。

这在大规模向量检索中很重要，因为存储和 ANN 计算量与 embedding dimension 直接相关。

5. 这和“去掉 top PCs”有什么不同

一些方法直接删除最强的几个主成分，假设这些方向是公共偏置。Whitening 更系统：不是简单删除，而是所有保留方向都按方差重标度。

两者都有风险：如果最大方差方向其实包含重要任务语义，删除或强压会伤害性能。因此 whitening matrix 应在与目标域相近的语料上估计。

6. 数据泄漏与统计量估计

Whitening 需要估计 μ, Σ 。如果直接使用测试集统计量，会形成 transductive leakage。严格实验应只用训练语料或独立无标签语料计算变换，再固定应用到 dev/test。

当领域变化很大时，例如从新闻迁移到代码/医疗，原统计量可能不再适合。

7. SimBERT：检索与生成统一的动机

纯 embedding 模型解决“这两句话是否相似”，但很多应用还希望“生成一个意思相近但表达不同的句子”。SimBERT 利用 UniLM 式 attention mask 与 BERT 参数，把生成目标和语义相似目标结合，使模型既能产生 paraphrase，又能提供用于检索的 representation。

可以把它理解为两个方向的联合：

$$\text{semantic encoding} \leftrightarrow \text{semantic-preserving generation}.$$

8. 为什么生成与检索可能互相帮助

如果模型要生成同义表达，就必须区分“语义核心”和“表面形式”；如果 embedding 训练又要求同义句接近，则两种目标共同鼓励表示对词面变化不敏感。

但多任务也可能冲突：生成喜欢保留细节，检索可能希望压缩到低维语义。权重比例需要消融。

9. 与后来对比学习句向量的关系

SimCSE 等方法随后证明，对比学习可以非常有效地直接优化句向量几何。BERT-whitening 的意义并没有因此消失：它展示了表示后处理本身就可能带来大收益，并提供了分析 anisotropy 的简单基线。

在工程中，一个合理顺序通常是：

1. 先测 mean pooling / CLS；
2. 再测 whitening/PCA；
3. 再考虑有监督或无监督 contrastive finetuning；
4. 最后评估 ANN 检索性能与线上成本。

10. Gotchas

10.1 协方差矩阵病态

维度高、样本少时 Σ 可能接近奇异。需要加

$$\Sigma_{\epsilon} = \Sigma + \epsilon I$$

或截断很小的 eigenvalue。

10.2 归一化顺序

通常先 whitening，再做 L2 normalization 用于 cosine。若先 L2 再估协方差，统计含义不同。

10.3 训练集好不等于跨域好

Whitening 是 domain-dependent 变换。跨域评估必须单独测，不要只在一个 STS benchmark 得出“普遍改善”。

11. Know-how: 最小实现

```
X = X - X.mean(0, keepdims=True)
C = X.T @ X / len(X)
vals, vecs = eigh(C)
W = vecs @ diag(1.0 / sqrt(vals + eps))
Y = X @ W
Y = Y / norm(Y, axis=1, keepdims=True)
```

真实实现要注意 eigenvalue 排序、截断维度、float64 统计和线上保存 μ, W 。

12. Know-why

这一研究线的重要启发是：**模型输出空间的几何不是训练完就不可改变**。很多表示学习问题先做一个统计学诊断（均值、谱、协方差、有效秩）往往比直接堆网络更能说明问题来自哪里。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. **定义题**：核心对象、公式和变量分别是什么？
2. **推导题**：为什么这种结构能够解决原问题？关键等式如何得到？
3. **工程题**：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. **迁移题**：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- Whitening Sentence Representations for Better Semantics and Faster Retrieval — <https://arxiv.org/abs/2103.15316>
- SimBERT project — <https://github.com/ZhuiyiTechnology/simbert>
- 科学空间：句向量、BERT whitening、SimBERT 相关文章—<https://spaces.ac.cn/>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。