

苏剑林研究专题 07: GAN-QP / VAE / Flow

早期概率生成模型研究与后来 LLM 数学思维的连接

2026-08-14

Contents

摘要	1
1. 生成建模的基本目标	2
2. GAN: 通过判别器定义差异	2
3. WGAN: 用 Wasserstein 距离改善几何	2
4. GAN-QP 的出发点	2
5. 为什么这是一种“重新设计 dual”的方法	2
6. Turing-test GAN: 改变判别器输入	3
7. Pairwise 思维为什么后来反复出现	3
8. VAE: 另一条概率建模路线	3
9. Flow: 从不可逆生成到可逆变换	3
10. 生成模型研究留下的数学工具	4
11. Gotchas	4
11.1 “有一个 divergence”不等于“好训练”	4
11.2 critic 变强不一定帮助 generator	4
11.3 生成质量指标容易错位	4
12. Know-how	4
13. Know-why	4
复习清单	4
参考资料 (精选)	4

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分: (1) 苏剑林本人署名论文/项目; (2) 其在“科学空间”中长期公开推导与分析的研究性文章; (3) 其参与的团队论文 (例如 Kimi 系列)。对于团队工作, 不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开, 并单独列出 gotchas、know-how 与 know-why。

摘要

在 Transformer 之前, 苏剑林已经持续研究生成模型的数学结构。GAN-QP 试图绕开 WGAN 中 Lipschitz 约束的困难; “Training GANs via Turing Test”则把判别对象从单样本真假改成样本对比较。与科学空间中大量 VAE、GAN、Flow 推导一起看, 这一阶段最重要的不是某个模型后来是否成为主流, 而是形成了一套“从概率距离、对偶与几何解释训练目标”的方法。

1. 生成建模的基本目标

设真实数据分布为 $p_{data}(x)$ ，生成模型诱导分布为 $p_g(x)$ 。训练需要某种方式使

$$p_g \approx p_{data}.$$

不同模型的差别，很多时候来自“如何定义并估计两个分布的差异”。

2. GAN: 通过判别器定义差异

原始 GAN 使用判别器 $D(x)$ 区分真实与生成样本：

$$\min_D \max_D \mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_z \log(1 - D(G(z))).$$

理想判别器与 Jensen-Shannon divergence 有关系，但在两个分布支撑集几乎不重叠时，梯度可能变差。

3. WGAN: 用 Wasserstein 距离改善几何

WGAN 使用 Kantorovich-Rubinstein dual:

$$W(p, q) = \sup_{\|f\|_L \leq 1} \mathbb{E}_p[f(x)] - \mathbb{E}_q[f(x)].$$

关键是 f 必须 1-Lipschitz，于是产生 weight clipping、gradient penalty 等实现问题。

这带出一个自然研究问题：是否能设计一个新的 **critic objective**，让它不依赖显式 **Lipschitz** 约束，却仍然给 **generator** 合理梯度？

4. GAN-QP 的出发点

GAN-QP (Quadratic Potential) 不再完全沿用 WGAN 的距离定义，而构造带样本对距离归一的二次势能目标。直觉上，critic 对真实/生成样本的分数差不能无限增大，因为二次项会惩罚过大的差异；这样可以在目标内部限制 critic，而不是额外施加全局 Lipschitz constraint。

其思想可以抽象成

$$\Delta D = D(x_r) - D(x_f),$$

并在目标中加入与 $\Delta D^2/d(x_r, x_f)$ 类似的约束项，使最优分数差与样本距离相关。

5. 为什么这是一种“重新设计 dual”的方法

经典路线通常是：

先定义 divergence/distance $\rightarrow$ 求可训练的 dual.

GAN-QP 更接近反过来：直接设计一个具有良好训练性质的对抗目标，再研究其对应的分布性质。这种思路后来在很多深度学习研究中都很常见：先从优化几何出发，而不强求目标必须是某个著名统计距离。

6. Turing-test GAN: 改变判别器输入

“Training GANs via Turing Test” 的核心变化是让判别器比较样本对，而不是单独回答“这个样本是真的吗”。

概念上构造：

$$D(x_1, x_2)$$

去判断 pair 中哪个更像真实样本。这种相对比较可以减少判别器依赖某些绝对 shortcut，并把 GAN 解释成“相对逼真度”的图灵测试。

7. Pairwise 思维为什么后来反复出现

从 GAN pairwise critic 到 ZLPR 的正负标签排序，再到 preference optimization，深度学习中相对比较比绝对打分更稳：

is A better than B?

往往比

what is the absolute quality score of A?

更容易定义。

8. VAE: 另一条概率建模路线

VAE 通过 latent variable z 建模：

$$p(x) = \int p(x | z)p(z)dz.$$

使用变分分布 $q(z | x)$ 得到 ELBO：

$$\log p(x) \geq \mathbb{E}_{q(z|x)}[\log p(x | z)] - D_{KL}(q(z | x) \| p(z)).$$

科学空间对 VAE 的大量推导关注 KL、后验、重参数技巧及其几何解释，这些数学工具后来继续用于表示学习和生成模型分析。

9. Flow: 从不可逆生成到可逆变换

Normalizing Flow 构造可逆映射

$$x = f(z),$$

通过变量替换公式精确计算密度：

$$\log p_X(x) = \log p_Z(z) - \log \left| \det \frac{\partial f}{\partial z} \right|.$$

它的核心矛盾是表达能力与 Jacobian determinant 可计算性之间的权衡。后续 autoregressive flow、TARFLOW 等工作继续沿着“可逆/可计算密度/高效生成”展开。

10. 生成模型研究留下的数学工具

- KL / JS / Wasserstein 等分布差异;
- 对偶问题;
- Lipschitz 与梯度范数;
- 变量替换与 Jacobian;
- 变分下界;
- pairwise ranking;
- 支撑集与高维几何。

这些工具在 LLM 时代仍然出现于 RL、reward modeling、normalization、optimizer 与 diffusion/flow matching。

11. Gotchas

11.1 “有一个 divergence” 不等于 “好训练”

统计距离的理论性质和 SGD 下的梯度质量是两件事。GAN 历史反复说明，优化路径可以比极限目标更重要。

11.2 critic 变强不一定帮助 generator

如果判别器过快把真假完全分开，generator 得到的局部梯度可能反而差。

11.3 生成质量指标容易错位

Inception Score/FID 等只反映特定 feature space 的统计，不是完整视觉/语义质量。研究目标应与最终用途对应。

12. Know-how

阅读 GAN/VAE/Flow 论文时，建议固定写三件事：

1. 模型在优化哪个概率量/代理目标;
2. 这个量如何估计，是否有 bias/variance;
3. 训练时真正传给参数的梯度来自哪一项。

很多“新 loss”看起来不同，但第三步可能非常相似。

13. Know-why

这一阶段最值得得到 LLM 的经验是：不要只问最终 **objective** 在理论上等价于什么，还要问它在有限模型、有限 **batch**、有限精度下产生什么优化几何。这正是后来研究训练稳定性和 Muon 等优化器时同样重要的视角。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. 定义题：核心对象、公式和变量分别是什么？
2. 推导题：为什么这种结构能够解决原问题？关键等式如何得到？
3. 工程题：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. 迁移题：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- GAN-QP —<https://arxiv.org/abs/1811.07296>
- Training GANs via Turing Test —<https://arxiv.org/abs/1810.10948>
- 科学空间：生成模型、VAE、Flow 相关文章—<https://spaces.ac.cn/>

- 科学空间 TARFLOW 讨论—<https://spaces.ac.cn/archives/10667>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。