

苏剑林研究专题 08: Transformer 初始化、归一化与深度稳定性

从方差传播、残差尺度到 Attention logit 与 loss spike

2026-08-14

Contents

摘要	2
1. 残差网络的基本递推	2
2. Post-LN vs Pre-LN	2
2.1 Post-LN	2
2.2 Pre-LN	2
3. LayerNorm 与 RMSNorm	2
4. 初始化到底在控制什么	3
5. Residual scaling	3
6. Attention logit 的尺度	3
7. Loss spike 为什么很难只靠 gradient clipping 解释	3
8. “1000 层 Transformer” 问题	4
9. Parameterization 与 width scaling	4
10. 低精度训练的额外约束	4
11. Gotchas	4
11.1 只记录 loss, 不记录内部尺度	4
11.2 全局 gradient norm 掩盖局部异常	4
11.3 Pre-LN “稳定” 不等于无限深	4
12. Know-how: 建议监控的训练 telemetry	5
13. Know-why	5
复习清单	5
参考资料 (精选)	5

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

Transformer 训练稳定性是苏剑林长期研究的另一条主线。初始化、Pre-LN/Post-LN、RMSNorm、残差尺度、深度增长、Attention logit、低精度数值问题看似分散，实际都可以归约到：信号和梯度经过很多层后，均值、方差、谱和范数如何变化。本专题建立一个统一的尺度分析框架，并解释为什么“能训练 12 层”的 recipe 到 1000 层或超大模型上可能完全失效。

1. 残差网络的基本递推

Transformer block 可以抽象为

$$x_{l+1} = x_l + F_l(x_l).$$

如果各层残差分支方差近似独立且不做尺度控制，则

$$\text{Var}(x_L) \approx \text{Var}(x_0) + \sum_{l=0}^{L-1} \text{Var}(F_l).$$

深度增加时 hidden norm 可能持续增长。真实网络并不独立，但这个近似足以说明为什么 residual scaling 与 normalization 很关键。

2. Post-LN vs Pre-LN

2.1 Post-LN

经典结构近似：

$$x_{l+1} = \text{LN}(x_l + F_l(x_l)).$$

每层输出都被规范化，但梯度需要穿过 LayerNorm 和残差组合，在深网络中训练初期更敏感。

2.2 Pre-LN

现代 LLM 常用：

$$x_{l+1} = x_l + F_l(\text{LN}(x_l)).$$

残差主干提供接近 identity 的梯度路径，因此更容易优化很深的网络。但 hidden state 的 residual stream norm 可以随深度积累。

3. LayerNorm 与 RMSNorm

LayerNorm：

$$\text{LN}(x) = \gamma \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta.$$

RMSNorm 去掉均值中心化：

$$\text{RMSNorm}(x) = \gamma \frac{x}{\sqrt{\frac{1}{d} \sum_i x_i^2 + \epsilon}}.$$

RMSNorm 计算更简单，在 decoder-only LLM 中非常常见。它控制均方尺度，但不保证各维均值为零。

4. 初始化到底在控制什么

线性层

$$y = Wx$$

若 W_{ij} 独立、方差为 σ_W^2 ，则在简单假设下

$$\text{Var}(y_i) \approx d\sigma_W^2 \text{Var}(x_j).$$

Xavier/He 初始化本质是在选择 σ_W ，使前向和反向方差不要随层数指数爆炸/消失。

Transformer 还多了 residual branch，因此仅保证单层 variance-preserving 不够；需要考虑 L 层累积。

5. Residual scaling

常见做法是让某些输出投影按深度缩小，例如初始化尺度含

$$\frac{1}{\sqrt{2L}}$$

或等价的残差系数。目标是让

$$\sum_{l=1}^L \text{Var}(F_l)$$

保持 $O(1)$ ，而不是 $O(L)$ 。

不同模型使用不同参数化，关键不是背某个常数，而是检查它是否同时控制 forward activation、backward gradient 和 optimizer update。

6. Attention logit 的尺度

Attention score 是

$$a_{ij} = \frac{q_i^\top k_j}{\sqrt{d_h}}.$$

除以 $\sqrt{d_h}$ 是为了让随机 Q/K 内积的方差不随 head dimension 线性增长。但训练后 Q/K norm 可能继续变大，于是 logit 绝对值仍会升高。

当 logit 很大时 softmax 接近 one-hot:

$$\text{softmax}(a)_j \approx 1$$

对最大项，而其他位置梯度非常小，并可能在低精度下触发数值问题。

7. Loss spike 为什么很难只靠 gradient clipping 解释

一次 loss spike 可能来自:

- 某层 activation/outlier 突然增大;
- QK logit 爆炸;
- optimizer update RMS 异常;
- 某个 batch 数据极端;

- FP8/BF16 overflow/underflow;
- MoE routing imbalance;
- checkpoint/restart 状态不一致。

Gradient clipping 只限制全局梯度 norm，并不能保证每个矩阵更新、每个 Attention head、每个参数组都处于合理尺度。

8. “1000 层 Transformer” 问题

深度极端增加后，需要同时考虑：

signal propagation, gradient path, residual accumulation, optimizer noise.

如果每层只是轻微偏离 identity，1000 次复合也可能产生很大变化。超深网络不是简单把 100 层 recipe 的 num_layers 改成 1000。

9. Parameterization 与 width scaling

模型变宽时，如果学习率和初始化不随 width 调整，单步 function change 可能改变。μP 等理论试图让不同宽度的模型具有可迁移的超参数尺度。

苏剑林关于参数化/初始化的分析值得结合这种观点阅读：真正要保持的是函数与更新的尺度规律，而不是某个参数张量的数值范围看起来相似。

10. 低精度训练的额外约束

BF16/FP16/FP8 的动态范围和 mantissa 精度不同。训练稳定性不仅取决于数学公式，还取决于：

- accumulation dtype;
- norm/softmax 是否升精度;
- loss scaling;
- optimizer states dtype;
- all-reduce 精度;
- quantization granularity.

一个在 FP32 稳定的公式，不能自动推导出 FP8 稳定。

11. Gotchas

11.1 只记录 loss，不记录内部尺度

loss spike 前往往已有 Q norm、K norm、max logit、update RMS 等指标漂移。只看最终 loss 会错过预警信号。

11.2 全局 gradient norm 掩盖局部异常

某个小矩阵可能 update 特别大，但在数十亿参数的 global norm 中几乎看不见。应按 layer/parameter type 记录 RMS。

11.3 Pre-LN “稳定” 不等于无限深

它改善梯度路径，却可能带来 representation collapse、深层贡献变小等其他问题；深度仍需 residual scaling 与参数化设计。

12. Know-how: 建议监控的训练 telemetry

每 N step 记录:

- loss / grad norm;
- activation RMS per block;
- residual stream RMS;
- Q/K/V RMS;
- max / p99 Attention logit;
- softmax entropy;
- parameter RMS 与 update RMS;
- optimizer second moment;
- MoE expert load (如适用)。

最好能在 spike 前后保留小窗口 trace, 而不是只保留 TensorBoard 平均值。

13. Know-why

稳定训练不是“避免 NaN”这么低层的问题。一个模型即使从不 NaN, 也可能因为尺度逐渐失衡而进入低效优化区域。真正的目标是让**信号、梯度和更新**在整个训练周期内保持可控且可预测的尺度。

复习清单

建议在完成本专题后, 能够回答下面四类问题:

1. **定义题**: 核心对象、公式和变量分别是什么?
2. **推导题**: 为什么这种结构能够解决原问题? 关键等式如何得到?
3. **工程题**: 实现时真正容易出错的地方是什么? 哪些超参数决定行为?
4. **迁移题**: 如果数据规模、上下文长度、模型宽度或训练预算变化, 原结论还成立吗?

参考资料 (精选)

- 科学空间: Transformer 初始化、参数化与标准化—<https://spaces.ac.cn/archives/8620>
- 科学空间: 超深 Transformer / 1000 层相关分析—<https://spaces.ac.cn/archives/8978>
- 科学空间: Attention/低精度/loss spike 相关研究—<https://spaces.ac.cn/archives/11371>
- RoFormer —<https://arxiv.org/abs/2104.09864>

版本说明: 2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础, 重点用于技术学习与研究复盘, 而非作者个人传记。