

苏剑林研究专题 09: Adam -> Lion -> Muon -> Moonlight -> MuonClip

从逐元素自适应到矩阵几何与大模型稳定性

2026-08-14

Contents

摘要	2
1. SGD 与 Momentum: 最基本的方向累积	2
2. Adam: 逐元素自适应缩放	2
3. AdamW: 为什么 weight decay 要解耦	2
4. Lion: 只保留方向符号的极简思路	3
5. Muon: 把权重矩阵当矩阵	3
6. Newton-Schulz: 为什么不用每步真的 SVD	3
7. Muon scale-up 的第一个问题: update magnitude	3
8. 第二个问题: Weight Decay	3
9. Moonlight: Muon 的大模型验证	3
10. MuonClip / QK-Clip: 从优化器扩展到稳定性控制	4
11. 哪些参数适合 Muon	4
12. Gotchas	4
12.1 只比较相同步数	4
12.2 把 Newton-Schulz iteration 越多越好	4
12.3 不按 shape 记录 update RMS	4
12.4 把所有参数都换成 Muon	4
13. Know-how: 做优化器消融的最小协议	4
14. Know-why	5
复习清单	5
参考资料 (精选)	5

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分: (1) 苏剑林本人署名论文/项目; (2) 其在“科学空间”中长期公开推导与分析的研究性文章; (3) 其参与的团队论文 (例如 Kimi 系列)。对于团队工作, 不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开, 并单独列出 gotchas、know-how 与 know-why。

摘要

从 Adam/AdamW 到 Muon、Moonlight、MuonClip 的演化，核心问题逐渐从“如何为每个参数自适应学习率”变成“一个二维权重矩阵的更新是否应该利用矩阵几何”。苏剑林长期分析 Adam、weight decay、矩阵范数与更新尺度，并参与 Moonlight 与 Kimi K2/MuonClip 团队工作。本专题重点不是把优化器当公式列表，而是比较它们对梯度方向、尺度、矩阵奇异值与训练稳定性分别做了什么。

1. SGD 与 Momentum：最基本的方向累积

SGD:

$$\theta_{t+1} = \theta_t - \eta g_t.$$

Momentum:

$$m_t = \beta m_{t-1} + (1 - \beta) g_t,$$

$$\theta_{t+1} = \theta_t - \eta m_t.$$

Momentum 的本质是时间维低通滤波：持续一致的梯度被增强，快速改变方向的噪声被平滑。

2. Adam：逐元素自适应缩放

Adam 同时维护一阶和二阶矩：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t,$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2,$$

更新近似

$$\Delta \theta_t = -\eta \frac{m_t}{\sqrt{v_t} + \epsilon}.$$

它把每个 scalar 参数当成独立坐标进行归一化。这在通用深度学习里极其成功，但也留下一个问题：Transformer 大部分参数天然组成矩阵，逐元素处理是否浪费了结构？

3. AdamW：为什么 weight decay 要解耦

在 SGD 中，L2 regularization 与 weight decay 常常等价；在 Adam 这种自适应预条件器中，两者不再等价。

L2 把 $\lambda \theta$ 加进梯度，再被 $1/\sqrt{v}$ 缩放；AdamW 则直接做

$$\theta \leftarrow (1 - \eta \lambda) \theta$$

与梯度预条件解耦。

这一点是理解后续 Muon weight decay 设计的基础：正则/衰减应该作用于参数，还是作用于经过某种几何变换的 update？

4. Lion：只保留方向符号的极简思路

Lion 等优化器说明，自适应优化不一定需要 Adam 那样完整的 second moment。它主要使用 momentum 的符号作为更新方向，减少 optimizer state 和运算。

这里的价值是提供对照：优化器设计空间不仅有“更精确估计二阶矩”，还可以选择完全不同的归纳偏置。

5. Muon：把权重矩阵当矩阵

对于二维权重 $W \in \mathbb{R}^{m \times n}$ ，Muon 先对 momentum gradient G 做矩阵正交化/极分解近似：

$$G = U\Sigma V^\top \rightarrow \text{orth}(G) = UV^\top.$$

这相当于去掉奇异值尺度，只保留矩阵变化的主要方向结构。

直觉上，Adam 对每个元素分别 normalize；Muon 对整个矩阵的奇异方向整体 normalize。

6. Newton-Schulz：为什么不用每步真的 SVD

完整 SVD 成本高。Muon 常用 Newton-Schulz 迭代近似矩阵极分解/正交化。概念上通过若干矩阵乘法迭代，使

$$X_k^\top X_k \rightarrow I$$

从而得到接近正交的 update。

这使算法更适合 GPU，因为 GEMM 是高度优化的核心算子。

7. Muon scale-up 的第一个问题：update magnitude

正交化后的 $UV^\top$ 具有固定的奇异值结构，但不同矩阵 shape 下其元素 RMS、谱范数与 Frobenius norm 的关系不同。如果直接用同一学习率，宽矩阵、方矩阵、窄矩阵的实际 function update 可能不在同一尺度。

Moonlight 的一个重要方向就是为不同 shape 设计更合理的 update scaling，使 Muon 在 LLM 规模上可预测。

8. 第二个问题：Weight Decay

当 optimizer update 的几何已经发生变化，简单沿用 AdamW 的超参数不一定合适。需要重新考虑参数 norm 的平衡：

$$\frac{\|\Delta W\|}{\|W\|}$$

在训练中是否随层、shape 和时间稳定。

Moonlight 的 scale-up 经验说明，优化器不能只比较“公式方向”，还必须比较实际 **update-to-weight ratio**。

9. Moonlight：Muon 的大模型验证

“Muon is Scalable for LLM Training” 系统研究了 Muon 在大模型训练中的 scaling，并以 Moonlight 模型实验展示计算效率优势。关键不是“Muon 在一个小 benchmark 上更高分”，而是检查 compute-optimal setting 下，用同等训练算力达到目标 loss/性能需要多少资源。

这类结论比固定 step 数比较更接近基础模型训练的实际价值。

10. MuonClip / QK-Clip: 从优化器扩展到稳定性控制

Kimi K2 团队工作引入 MuonClip, 并重点控制 Attention Q/K 相关不稳定。一个核心现象是 QK logit 可能在大规模训练中增长, 造成 softmax 过尖甚至 loss spike。

QK-Clip 类机制根据 Q/K 或 Attention logit 的尺度触发约束, 使异常 head 不继续无限放大。

这说明 optimizer scale-up 与 architecture stability 不能分开: 即使全局 update 正常, 某个敏感子结构仍可能积累异常。

11. 哪些参数适合 Muon

Muon 主要针对二维矩阵参数, 例如 Transformer linear weights. bias、norm scale、embedding 等一维或特殊结构参数通常仍用 AdamW/其他 optimizer。

因此真实训练常是 hybrid optimizer:

matrix weights $\rightarrow$ Muon,

others $\rightarrow$ AdamW.

这会引入多个学习率、weight decay 和 scheduler 的协调问题。

12. Gotchas

12.1 只比较相同步数

如果一个优化器单步成本更高/更低, 公平比较应看 wall-clock、FLOPs 或总训练成本, 而不只是 steps。

12.2 把 Newton-Schulz iteration 越多越好

更多迭代让正交化更精确, 但增加 GEMM 成本。优化器目标不是求一个高精度数学分解, 而是提高训练效率。

12.3 不按 shape 记录 update RMS

不同权重矩阵 shape 差异巨大。只看全局 grad norm 很容易掩盖某一类矩阵的异常更新。

12.4 把所有参数都换成 Muon

Embedding、norm、router 等参数具有不同几何, 盲目统一会伤害训练。

13. Know-how: 做优化器消融的最小协议

固定: 数据顺序、初始化、batch、scheduler、token budget。记录:

- train/val loss vs tokens;
- loss vs FLOPs/wall-clock;
- per-layer weight RMS;
- update RMS;
- update/weight ratio;
- QK max logit;
- optimizer state memory;
- kernel utilization。

只有这样才能区分“更好的 optimization geometry”和“仅仅学习率调得更合适”。

14. Know-why

Muon 系列真正挑战了一个长期默认假设：**神经网络参数虽然以矩阵存储，但优化时是否应该仍被视为彼此独立的标量？**当模型以矩阵乘法作为主要计算结构时，利用矩阵的谱与正交几何可能带来更合适的归一化。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. **定义题**：核心对象、公式和变量分别是什么？
2. **推导题**：为什么这种结构能够解决原问题？关键等式如何得到？
3. **工程题**：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. **迁移题**：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- 科学空间：Adam、weight decay、优化器综述—<https://spaces.ac.cn/archives/7094>
- Muon is Scalable for LLM Training —<https://arxiv.org/abs/2502.16982>
- Kimi K2 (MuonClip) —<https://arxiv.org/abs/2507.20534>
- 科学空间：QK-Clip / Muon scale-up —<https://spaces.ac.cn/archives/11126>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。