

苏剑林研究专题 12: MoE / Kimi K2 / 大规模预训练稳定性

条件计算、MuonClip、路由与万亿参数系统

2026-08-14

Contents

摘要	2
1. Dense scaling 的计算矛盾	2
2. MoE FFN 的基本结构	2
3. 容量增加从哪里来	2
4. Router collapse 与 load balancing	2
5. Capacity factor 与 token dropping	3
6. Expert Parallelism	3
7. Kimi K2 的意义	3
8. MuonClip 在 MoE 大模型中的角色	3
9. 为什么“零 loss spike”值得研究	3
10. 大规模训练的观测面	3
11. MoE 与知识专门化：不要过度解释	4
12. Post-training 与 Agentic 能力	4
13. Gotchas	4
13.1 总参数量比较很容易误导	4
13.2 Expert 数越多不一定越好	4
13.3 辅助负载损失可能改变模型目标	4
14. Know-how: MoE 实验应如何做	4
15. Know-why	4
复习清单	4
参考资料（精选）	5

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

Kimi K2 把多条前期研究线带到了万亿参数级系统：MoE 提供参数规模与计算规模解耦，MuonClip 处理优化与稳定性，长周期预训练要求数据、路由、低精度和并行系统同时可靠。本专题重点解释 MoE 的数学/系统核心、为什么“1T 参数”不等于每 token 计算 1T 参数，以及大规模训练稳定性为什么必须从单一 loss 监控升级为全栈 telemetry。

1. Dense scaling 的计算矛盾

Dense Transformer 每个 token 基本激活所有 FFN 参数。模型宽度/层数扩大时，参数量和 FLOPs 几乎一起增长。

MoE 的目标是让总参数 P_{total} 很大，但每个 token 只激活其中一小部分 P_{active} ：

$$P_{active} \ll P_{total}.$$

于是可以扩大模型容量，而不按同样比例增加单 token 计算。

2. MoE FFN 的基本结构

设有 E 个 expert，每个 expert 是 FFN $f_e(x)$ 。Router 输出 logits：

$$r = W_r x.$$

选 top- k expert：

$$\mathcal{E}(x) = \text{TopK}(r, k).$$

输出为

$$y = \sum_{e \in \mathcal{E}(x)} p_e(x) f_e(x).$$

其中 p_e 是路由权重。

3. 容量增加从哪里来

不同 token 可以激活不同 expert，因此总模型可以存储更多特征/知识子空间。若 E 增大而 k 固定，单 token FFN FLOPs 近似不变，但总参数线性增加。

这就是 sparse scaling 的核心。

4. Router collapse 与 load balancing

如果所有 token 都选择少数 expert，其余 expert 几乎不训练。需要负载均衡机制，让 expert 使用率不要过度失衡。

传统做法添加 auxiliary loss，例如鼓励 token fraction 与 routing probability 接近均匀。现代方法也会研究 aux-loss-free balancing，以减少负载目标干扰主语言建模目标。

5. Capacity factor 与 token dropping

分布式 MoE 中每个 expert 每个 batch 能处理的 token 数有限。若 router 把过多 token 发到某 expert, 可能:

- 丢弃 token;
- overflow 到备用 expert;
- 增加动态 buffer 和通信。

因此路由质量不仅是模型问题, 也是网络通信/显存规划问题。

6. Expert Parallelism

不同 expert 可以放在不同 GPU。token hidden state 必须通过 all-to-all 发送到目标 expert, 再收回输出。于是 MoE 的瓶颈常从 GEMM 变成:

all-to-all bandwidth + latency.

理论上 active FLOPs 很低, 如果网络拓扑差, 实际速度仍可能输给 dense。

7. Kimi K2 的意义

Kimi K2 公开工作展示了总参数约万亿规模、每 token 激活远小于总参数的 MoE, 并报告长达 15T+ token 的预训练稳定性。对研究而言, 更重要的是它把 optimizer、routing、并行、数据与 post-training 放在同一个大规模系统中验证。

8. MuonClip 在 MoE 大模型中的角色

当主矩阵参数使用 Muon 类优化器后, 训练动态与 AdamW 不完全相同; 同时 MoE、Attention Q/K、router 都可能产生局部异常。MuonClip/QK-Clip 反映出 scale-up 的一个经验:

优化器必须与对模型最敏感的结构联动监控, 而不是假设一个全局 learning rate 可以统一约束所有模块。

9. 为什么“零 loss spike”值得研究

在数万/数十万 GPU 小时训练中, 一次严重 spike 可能造成:

- 数百/数千 GPU 小时浪费;
- checkpoint rollback;
- optimizer state 破坏;
- data order 改变, 复现困难。

所以稳定性本身就是训练效率指标, 不只是图表美观。

10. 大规模训练的观测面

至少需要监控:

- router entropy / expert load;
- expert token count;
- all-to-all latency;
- Q/K norm 与 max logits;
- per-layer update RMS;
- gradient norm;
- data source mix;
- token throughput;
- checkpoint health;

- NaN/Inf count;
- low-precision scale。

11. MoE 与知识专门化：不要过度解释

常见可视化会发现某些 expert 对代码、数学或语言有偏好，但不能简单说“Expert 7 就是数学专家”。Router specialization 往往是统计倾向，且不同层、不同训练阶段会变化。

12. Post-training 与 Agentic 能力

Kimi K2 等现代模型强调 agent/tool-use 能力，但这类能力不只来自 pretraining MoE 架构，还依赖 SFT、RL、tool trajectories 与数据设计。不能把下游 agent benchmark 的收益单独归因于 MoE 或 MuonClip。

13. Gotchas

13.1 总参数量比较很容易误导

比较 MoE 与 dense 时应同时报告 active parameters、FLOPs/token、memory、throughput、训练 token。

13.2 Expert 数越多不一定越好

更多 expert 会增加路由、通信和参数内存，并可能降低每个 expert 的 token 覆盖。

13.3 辅助负载损失可能改变模型目标

balance loss 太强会强迫 token 走不合适的 expert；太弱则出现热点。应把 routing metrics 当一等训练信号。

14. Know-how: MoE 实验应如何做

固定 active compute，改变 expert 数与 top-k；同时报告：

quality vs active FLOPs,

quality vs wall-clock,

quality vs total parameters.

三种曲线回答的是不同问题，不能互相替代。

15. Know-why

MoE 的本质是条件计算（**conditional computation**）。它不是免费增加智能，而是用路由把有限计算预算分配给不同参数子空间。真正困难的是让“选择谁来算”本身既可学习、又稳定、又适合分布式硬件。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. 定义题：核心对象、公式和变量分别是什么？
2. 推导题：为什么这种结构能够解决原问题？关键等式如何得到？
3. 工程题：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. 迁移题：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- Kimi K2 —<https://arxiv.org/abs/2507.20534>
- Muon is Scalable for LLM Training —<https://arxiv.org/abs/2502.16982>
- 科学空间：MoE、MuonClip、训练稳定性相关文章—<https://spaces.ac.cn/>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。