

苏剑林研究专题 13: RL Scaling / Kimi k1.5

从长 CoT、可验证奖励到 long2short

2026-08-14

Contents

摘要	1
1. 从 pretraining scaling 到 RL scaling	2
2. 推理轨迹是策略，而不仅是标签	2
3. 可验证奖励为什么重要	2
4. Long-context RL	2
5. Policy Optimization 的基本结构	2
6. 为什么不一定需要 MCTS	2
7. Long2Short: 把长推理能力压回短回答	3
8. Multimodal reasoning	3
9. RL 与 SFT 的数据分布差异	3
10. Scaling RL compute 的三个维度	3
11. Gotchas	3
11.1 把 reasoning token 数当能力	3
11.2 verifier leakage	3
11.3 只报最高 pass@k	3
11.4 RL instability	3
12. Know-how: 评估 reasoning scaling	4
13. Know-why	4
复习清单	4
参考资料 (精选)	4

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

Kimi k1.5 代表另一条 scaling 轴：不只扩 pretraining compute，而是扩展 reinforcement learning / inference-time reasoning。苏剑林是该团队论文作者之一。本专题不把工作简化成“更长 CoT”，而是分析

RL 环境、奖励、long-context rollout、policy optimization、long2short 以及为什么 reasoning scaling 的瓶颈与普通 SFT 不同。

1. 从 pretraining scaling 到 RL scaling

预训练主要优化 next-token likelihood:

$$L_{LM} = - \sum_t \log p_{\theta}(x_t | x_{<t}).$$

它学习数据分布中的通用能力，但不保证模型会主动搜索更长的推理路径。

RL 阶段则根据最终任务奖励 R 更新策略，使模型偏向更可能得到正确结果的 trajectory。

2. 推理轨迹是策略，而不仅是标签

一条 reasoning response 可以写成动作序列

$$a_{1:T} \sim \pi_{\theta}(\cdot | q).$$

最终答案正确与否只在轨迹末端可观察，但前面 token 决定了搜索路径。RL 的难点是 credit assignment: 哪些中间决策真正导致成功?

3. 可验证奖励为什么重要

数学、代码等任务可以用答案匹配、执行器、测试用例提供较可靠奖励。相比纯 LLM judge, 这种 verifier 减少 reward model 本身的偏好噪声。

但“最终答案正确”仍不保证中间 reasoning 每步都正确; 模型可能通过错误过程偶然得到正确结果。因此 process-level analysis 仍有价值。

4. Long-context RL

当 rollout 可以非常长时:

- 每个样本 token 成本显著增加;
- batch 中长度差异导致 GPU 利用率下降;
- advantage/return 的方差增大;
- context window、KV-cache 与采样吞吐成为核心瓶颈。

因此 long CoT RL 不只是算法问题，也是 inference system 问题。

5. Policy Optimization 的基本结构

许多现代 LLM RL 方法可以抽象为: 从旧策略采样轨迹，计算 reward/advantage，再最大化

$$\mathbb{E}[A_t \log \pi_{\theta}(a_t | s_t)]$$

并加入 KL/clip 等约束，防止一次更新离旧策略太远。

Kimi k1.5 强调较直接的 policy optimization 路线，而不是依赖复杂 MCTS/value function/PRM 堆栈。

6. 为什么不一定需要 MCTS

MCTS 适合有明确状态转移与可重复评估的环境，但 LLM token tree 极其宽，rollout 昂贵。若基础策略已经较强，直接通过大规模采样 + verifier + policy update 可能更简单、更可扩展。

这不是说 MCTS 无效，而是工程最优点取决于单次 rollout 成本、verifier 质量和训练集规模。

7. Long2Short: 把长推理能力压回短回答

一个很重要的问题是：训练时长 CoT 提升搜索能力，但部署时每题输出几千 token 成本很高。Long2Short 类策略希望利用长推理模型产生的能力/数据，训练模型在更短轨迹中保留结论或高质量 reasoning。

可以把它看成：

search-time compute $\rightarrow$ distilled policy.

8. Multimodal reasoning

Kimi k1.5 还涉及 multimodal reasoning。对 RL 来说，图像输入增加了状态空间与 verifier 难度；如果答案可验证，仍可以使用 outcome reward，但视觉感知错误与推理错误会混在一起。

因此要区分：

- perception bottleneck;
- reasoning bottleneck;
- reward bottleneck.

9. RL 与 SFT 的数据分布差异

SFT 只学习 teacher 给出的 trajectory；RL 可以从当前策略自身的失败/成功边界继续采样，因此理论上能发现训练数据中没有显式示范的新策略。

但 RL 也可能 reward hacking：找到 verifier 漏洞，而不是学到我们想要的推理。

10. Scaling RL compute 的三个维度

1. 每个问题采样更多 trajectories；
2. 每条 trajectory 允许更长 reasoning；
3. 增加 RL 训练迭代/问题规模。

这三者不等价。更多样本提高搜索覆盖；更长轨迹提高单次思考深度；更多迭代改变策略本身。

11. Gotchas

11.1 把 reasoning token 数当能力

更长输出可能只是啰嗦、循环或重复验证。应该看正确率随 token budget 的收益曲线。

11.2 verifier leakage

若训练任务与 benchmark verifier/答案模式高度重叠，模型可能学到 shortcut。

11.3 只报最高 pass@k

pass@k 大量采样可以掩盖单次策略质量。部署更关心 pass@1、平均输出长度与总推理成本。

11.4 RL instability

reward normalization、KL、采样温度、batch composition 都会改变梯度分布。不能把“同一 base model + 同一数据”视为足够可复现。

12. Know-how: 评估 reasoning scaling

同时画三条曲线：

accuracy vs reasoning tokens,

accuracy vs sampled FLOPs,

accuracy vs wall-clock latency.

并分开测 deterministic tasks 与开放式 judge tasks，避免评价噪声混在一起。

13. Know-why

Reasoning RL 的核心不是让模型“写更多思考文字”，而是把额外推理计算变成策略搜索，并用可靠反馈把成功搜索结果固化到参数中。这是一种不同于预训练数据扩张的 scaling 机制。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. **定义题**：核心对象、公式和变量分别是什么？
2. **推导题**：为什么这种结构能够解决原问题？关键等式如何得到？
3. **工程题**：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. **迁移题**：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- Kimi k1.5: Scaling Reinforcement Learning with LLMs —<https://arxiv.org/abs/2501.12599>
- Kimi K2 —<https://arxiv.org/abs/2507.20534>
- 科学空间：LLM/RL/推理相关分析—<https://spaces.ac.cn/>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。