

苏剑林研究专题 14：常用数学工具箱

LogSumExp、SVD、矩阵范数、贝叶斯、信息论与尺度分析

2026-08-14

Contents

摘要	2
1. LogSumExp：平滑最大值与 partition function	2
2. 复数与旋转群：RoPE 的语言	2
3. SVD：理解矩阵而不是元素	2
4. Polar Decomposition 与正交化	3
5. 范数与尺度	3
6. 协方差、特征值与 Whitening	3
7. 贝叶斯公式与条件独立	3
8. 信息论：Entropy / KL / Cross Entropy	3
9. Softmax 与指数族	4
10. Kernel Trick 与 Linear Attention	4
11. 低秩近似	4
12. 尺度分析与无量纲思维	4
13. 微分与 Jacobian：不要只会 autograd	4
14. Gotchas	4
14.1 公式等价不等于数值等价	4
14.2 只看期望不看方差	5
14.3 把矩阵问题逐元素理解	5
15. Know-how：如何建立个人数学笔记	5
16. Know-why	5
复习清单	5
参考资料（精选）	5

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

苏剑林研究文章的一个突出特征, 是反复把“新深度学习问题”还原为经典数学对象。要真正读懂 RoPE、ZLPR、Muon、Whitening、Linear Attention, 就需要一套稳定的数学工具箱。本专题选择最常出现、迁移价值最高的 10 类工具: LogSumExp、矩阵分解、范数与谱、复数旋转、概率/贝叶斯、信息论、指数族与 softmax、核技巧、低秩结构、连续/离散尺度分析。

1. LogSumExp: 平滑最大值与 partition function

定义

$$\text{LSE}(x) = \log \sum_i e^{x_i}.$$

如果 $m = \max_i x_i$, 则数值稳定形式为

$$\text{LSE}(x) = m + \log \sum_i e^{x_i - m}.$$

用途:

- softmax normalization;
- cross entropy;
- CRF partition function;
- ZLPR / 多标签 loss;
- smooth max / hardest-example aggregation.

核心直觉: 大项主导, 但不是 hard max, 因此仍保留其他项梯度。

2. 复数与旋转群: RoPE 的语言

Euler 公式:

$$e^{i\theta} = \cos \theta + i \sin \theta.$$

位置 m 对应相位 $m\theta$, 相对位置来自

$$e^{-im\theta} e^{in\theta} = e^{i(n-m)\theta}.$$

掌握复数形式后, RoPE 许多 trig 展开会变成一行。

3. SVD: 理解矩阵而不是元素

任意矩阵

$$W = U\Sigma V^\top.$$

U, V 描述输入/输出的正交方向, Σ 是每个方向的增益。Muon 把 gradient 的奇异值尺度去掉, 只保留 $UV^\top$ 的方向结构; 低秩 Attention 则关心只保留最大的若干奇异方向。

4. Polar Decomposition 与正交化

矩阵可写成

$$W = QH,$$

其中 Q 是正交/半正交部分, H 是半正定部分。Muon 的 orthogonalized update 可从这个角度理解。Newton-Schulz 则提供不显式 SVD 的迭代近似。

5. 范数与尺度

常见范数:

$$\|W\|_F = \sqrt{\sum_{ij} W_{ij}^2},$$

$$\|W\|_2 = \sigma_{\max}(W).$$

RMS 近似为 Frobenius norm 除以元素数平方根。训练稳定性里必须区分: global grad norm、parameter RMS、update RMS、spectral norm 它们控制的是不同现象。

6. 协方差、特征值与 Whitening

$$\Sigma = \mathbb{E}[(x - \mu)(x - \mu)^\top].$$

特征值描述不同方向的方差。Whitening 用 $\Sigma^{-1/2}$ 把协方差变成单位阵。理解 embedding anisotropy、effective rank、PCA 都依赖这套工具。

7. 贝叶斯公式与条件独立

$$p(y | x) = \frac{p(x | y)p(y)}{p(x)}.$$

Naive Bayes 假设多个证据在给定 y 时条件独立, 于是 log probability 可以相加。NBCE 利用的就是类似“多个 context window 的证据组合”思想。

8. 信息论: Entropy / KL / Cross Entropy

Entropy:

$$H(p) = - \sum_x p(x) \log p(x).$$

KL:

$$D_{KL}(p \| q) = \sum_x p(x) \log \frac{p(x)}{q(x)}.$$

Cross entropy:

$$H(p, q) = H(p) + D_{KL}(p \| q).$$

语言模型 NLL、VAE ELBO、RL KL penalty 都反复使用这些对象。

9. Softmax 与指数族

$$p_i = \frac{e^{z_i}}{\sum_j e^{z_j}}.$$

logits 只在相对差异上有意义，因为加常数不改变 softmax：

$$\text{softmax}(z + c) = \text{softmax}(z).$$

Attention logit 过大时 entropy 降低，softmax 变尖；这连接到 QK stability 与 temperature scaling。

10. Kernel Trick 与 Linear Attention

若

$$k(q, k) = \phi(q)^\top \phi(k),$$

则原本 pairwise 计算可以通过结合律重排。这是 linear attention 的基本代数入口。

Kernel trick 的一般启发是：如果 interaction 可以写成 feature inner product，就可能提前聚合一侧的统计量。

11. 低秩近似

若矩阵奇异值快速衰减，可以近似

$$W \approx U_k \Sigma_k V_k^\top, \quad k \ll d.$$

MLA、LoRA、矩阵压缩、某些 optimizer 都依赖“有效维度远低于表面维度”的经验。

12. 尺度分析与无量纲思维

当模型宽度 d 、深度 L 、序列长度 T 变化时，先问某个量如何随规模增长：

$$O(1), O(\sqrt{d}), O(d), O(L), O(T^2)?$$

例如 Attention 要除 $\sqrt{d_h}$ ；残差分支可能按 $1/\sqrt{L}$ 缩放；KV-cache 按 $O(T)$ 增长。很多稳定性问题本质上是“某个量的 scaling law 没被抵消”。

13. 微分与 Jacobian：不要只会 autograd

对于复合函数

$$y = f(g(x)),$$

Jacobian 链式法则决定梯度传播。VAE reparameterization、Flow log-determinant、LayerNorm/Softmax 的稳定性都需要知道局部 Jacobian 的结构。

在深网络中，多个 Jacobian 相乘的谱决定梯度消失/爆炸。

14. Gotchas

14.1 公式等价不等于数值等价

例如 $\log(\sum(\exp(x)))$ 与稳定 LSE 数学等价，但浮点结果可能一个溢出一个稳定。

14.2 只看期望不看方差

很多训练算法的平均梯度正确，但方差太大仍不可用。RL、sampling、Monte Carlo 尤其如此。

14.3 把矩阵问题逐元素理解

SVD/谱范数/正交化捕捉跨元素耦合，不能用“每个元素都差不多”替代。

15. Know-how：如何建立个人数学笔记

每遇到一个新算法，建立四行：

1. 变量的 shape；
2. 目标函数；
3. 最关键恒等式/不等式；
4. 规模变化时各项的量级。

如果 shape 和量级都写清楚，大量深度学习论文的复杂 notation 会迅速变简单。

16. Know-why

数学工具箱的价值不是为了把论文写得更“理论”，而是为了把多个看似无关的方法映射到同一个结构上。当 RoPE= 旋转群、Muon= 矩阵极分解、Whitening= 协方差归一、Linear Attention= 核分解时，新方法会变成旧数学对象的新组合。

复习清单

建议在完成本专题后，能够回答下面四类问题：

1. 定义题：核心对象、公式和变量分别是什么？
2. 推导题：为什么这种结构能够解决原问题？关键等式如何得到？
3. 工程题：实现时真正容易出错的地方是什么？哪些超参数决定行为？
4. 迁移题：如果数据规模、上下文长度、模型宽度或训练预算变化，原结论还成立吗？

参考资料（精选）

- 科学空间数学分类—<https://kexue.fm/category/Mathematics>
- RoFormer —<https://arxiv.org/abs/2104.09864>
- ZLPR —<https://arxiv.org/abs/2208.02955>
- BERT-whitening —<https://arxiv.org/abs/2103.15316>
- Muon is Scalable for LLM Training —<https://arxiv.org/abs/2502.16982>

版本说明：2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础，重点用于技术学习与研究复盘，而非作者个人传记。