

苏剑林研究专题 15：研究方法论

如何从工程问题产生新算法：换 formulation、写约束、看尺度、做证伪

2026-08-14

Contents

摘要	2
1. 第一步：把现象写成可测量对象	2
2. 第二步：区分能力不足与 formulation 不自然	2
3. 第三步：写下理想约束	2
4. 第四步：寻找最小结构	2
5. 第五步：做最小可证伪实验	3
6. 第六步：控制变量	3
7. 第七步：从“同一步数”升级到“同一资源”	3
8. 第八步：规模分析	3
9. 第九步：建立理论-实现双重等价性	4
10. 第十步：专门寻找 gotchas	4
11. 从博客推导升级为论文证据链	4
12. 如何阅读“科学空间”式长推导	4
层 A：只看问题和最终结论	4
层 B：复现关键推导	4
层 C：实现最小代码	4
13. 如何生成自己的研究问题	4
模板 1：旧方法有一个不自然的约束	5
模板 2：某个量随规模异常增长	5
模板 3：训练与推理的对象不一致	5
模板 4：现有算法忽略数据结构	5
模板 5：两个领域其实有同一个递推	5
14. 研究失败时如何定位	5
15. 15 个专题之间的统一图	5
16. Know-how ：一个可直接使用的研究记录模板	6
17. Know-why	6
复习清单	6
参考资料（精选）	6

系列定位。本报告属于“苏剑林研究专题”系列。报告将三类内容明确区分：(1) 苏剑林本人署名论文/项目；(2) 其在“科学空间”中长期公开推导与分析的研究性文章；(3) 其参与的团队论文（例如 Kimi 系列）。对于团队工作，不把公开论文无法确认的模块主导权归因给某一位作者。

阅读方法。不建议只记结论。每一节都尽量按“问题 -> 数学约束 -> 结构 -> 工程实现 -> 边界条件”展开，并单独列出 gotchas、know-how 与 know-why。

摘要

本专题不再讲某个具体算法，而把前 14 个专题压缩成一套可执行的研究方法：如何从工程异常产生研究问题，如何判断应该“调参”还是“换 formulation”，如何从约束反推结构，如何设计最小可证伪实验，如何通过规模分析避免小模型结论误导大模型，以及如何把博客式推导升级成论文级证据链。

1. 第一步：把现象写成可测量对象

错误问题：

为什么我的 Transformer 很不稳定？

更好的问题：

在 loss spike 前 200 step，哪个层的 Q/K RMS、max attention logit、update/weight ratio 首先偏离正常分布？

研究从“感觉”进入变量之后，才有可能建立因果假设。

2. 第二步：区分能力不足与 formulation 不自然

当模型表现差时，至少有两类原因：

1. 表达能力/数据/训练不足；
2. 任务表示方式本身增加了不必要困难。

GlobalPointer 的价值就是识别第二类：最终评价的是 entity span，却把训练问题写成 token BIO chain；换成 span scoring 后很多边界条件自然消失。

3. 第三步：写下理想约束

RoPE 的研究范式是典型：先要求

$$\langle f(q, m), f(k, n) \rangle$$

中的位置因素只依赖 $m - n$ ，然后寻找满足群性质的变换。

在自己的研究中，也可以先写：

- 应保持什么不变量？
- 哪些对称性应该成立？
- 哪个尺度变化后结果应保持 $O(1)$ ？
- 哪些边界情况必须退化成已知算法？

这些约束经常比网络结构名字更重要。

4. 第四步：寻找最小结构

一个好的第一版算法应尽量少引入自由度。原因是：

- 更容易解释；
- 更容易做消融；
- 更容易证伪；
- 更容易发现真正起作用的部分。

BERT-whitening 是极端例子：先用一个线性统计变换测试“问题是否主要来自 embedding covariance”，而不是直接训练一个复杂 projector。

5. 第五步：做最小可证伪实验

假设：长度外推失败主要因为高频相位 OOD。

好的实验不是直接训练一个 70B 模型，而是：

1. 小模型固定 checkpoint;
2. 只改频率缩放;
3. 画不同频段与长度的 retrieval 曲线;
4. 同时测 short-context regression;
5. 分析 attention logits。

如果最小实验已经否定假设，就没必要继续扩资源。

6. 第六步：控制变量

深度学习实验最容易犯的错误是一次改变：

- optimizer;
- learning rate;
- batch;
- data order;
- warmup;
- model size。

然后把收益全部归因于一个名字。

研究级比较必须记录 config hash、随机种子、数据版本，并尽量只改变单个因素。

7. 第七步：从“同一步数”升级到“同一资源”

大模型研究最终优化的是资源效率。比较 optimizer 或 Attention 时至少有四种预算：

- same tokens;
- same steps;
- same FLOPs;
- same wall-clock。

结论可能不同。Muon 单步做额外矩阵乘，但可能减少达到目标 loss 所需 compute；MLA 增加投影却节省 memory bandwidth。资源坐标必须与真实目标一致。

8. 第八步：规模分析

任何方法都问：当

$$L \rightarrow 10L, \quad d \rightarrow 4d, \quad T \rightarrow 32T$$

时，核心量怎么变？

- KV cache 是 $O(T)$;
- full attention prefill 是 $O(T^2)$;
- residual accumulation 可能随 L 增长;
- optimizer state 随参数量增长。

很多“在小模型更好”的方法，scale 后系统瓶颈完全不同。

9. 第九步：建立理论-实现双重等价性

论文公式正确，但实现可能由于：

- tensor layout;
- dtype;
- padding mask;
- fused kernel;
- cache offset;
- distributed all-reduce

而与理论不一致。

RoPE 最好的测试是内积等式；linear attention 最好的测试是 recurrent 与 parallel 版本逐 token 对齐；optimizer 最好的测试是手算一个小矩阵 update。

10. 第十步：专门寻找 gotchas

真正有价值的工程知识常在“什么时候会失败”。建议每个研究项目强制写一页：

- 哪些输入分布会破坏假设？
- 哪个超参数最敏感？
- 哪种 dtype/shape 例外？
- 哪个 benchmark 可能误导？
- 哪种替代解释同样能解释结果？

这比只写“优势”更接近研究。

11. 从博客推导升级为论文证据链

一个完整研究结果需要：

motivation → formalization → method → ablation → scaling → failure cases.

如果只有漂亮推导，没有充分实验，属于强假设；如果只有 benchmark 提升，没有机制解释，属于经验结果。两者结合才形成更稳固的知识。

12. 如何阅读“科学空间”式长推导

建议分三层：

层 A：只看问题和最终结论

先建立地图，不陷入公式。

层 B：复现关键推导

只手推 3-5 个最关键等式，确认每个假设。

层 C：实现最小代码

用随机 tensor 验证等价式、尺度和边界情况。

真正掌握通常发生在 C 层，而不是收藏文章。

13. 如何生成自己的研究问题

可以从以下模板开始：

模板 1：旧方法有一个不自然的约束

例如 BIO 不能自然嵌套 -> 直接 span scoring。

模板 2：某个量随规模异常增长

例如 QK logit、KV cache、residual norm -> 找到需要归一/压缩的对象。

模板 3：训练与推理的对象不一致

例如训练短 RoPE、推理长位置 -> length extrapolation。

模板 4：现有算法忽略数据结构

例如 Adam 把矩阵元素独立处理 -> matrix-aware optimizer。

模板 5：两个领域其实有同一个递推

例如 Attention 与 RNN -> fixed-state linear attention。


14. 研究失败时如何定位

按照下面顺序排查：

1. 实现是否等价？小 tensor 单测。
2. 训练是否公平？学习率/预算/数据是否匹配。
3. 指标是否对齐？benchmark 是否测目标能力。
4. 假设是否成立？中间变量是否按预期变化。
5. 是否只在某规模成立？做 width/depth/context sweep。
6. 替代解释是什么？是否可能只是参数量或正则变化。

15. 15 个专题之间的统一图

任务表示



表面上研究对象从 NER 到万亿参数模型变化很大，底层方法却高度一致：换对象、写约束、看尺度、做最小验证。

16. Know-how: 一个可直接使用的研究记录模板

每个 idea 建议维护:

Problem:

Existing formulation:

Observed failure:

Hypothesis:

Desired invariant/constraint:

Minimal method:

Minimal falsification experiment:

Metrics:

Scale sweep:

Ablations:

Failure cases:

Implementation tests:

Cost model:

Next hypothesis:

这样能防止研究过程退化成“不断加模块直到分数上涨”。

17. Know-why

研究方法论的最终目标不是追求每个问题都能推导出漂亮 closed form, 而是形成一种可压缩复杂性的习惯: 当系统越来越大时, 先找到少数决定行为的变量、约束和尺度, 再决定是否需要更复杂的方法。

复习清单

建议在完成本专题后, 能够回答下面四类问题:

1. **定义题**: 核心对象、公式和变量分别是什么?
2. **推导题**: 为什么这种结构能够解决原问题? 关键等式如何得到?
3. **工程题**: 实现时真正容易出错的地方是什么? 哪些超参数决定行为?
4. **迁移题**: 如果数据规模、上下文长度、模型宽度或训练预算变化, 原结论还成立吗?

参考资料 (精选)

- 科学空间—<https://spaces.ac.cn/>
- RoFormer —<https://arxiv.org/abs/2104.09864>
- GlobalPointer —<https://arxiv.org/abs/2208.03054>
- BERT-whitening —<https://arxiv.org/abs/2103.15316>
- Muon is Scalable for LLM Training —<https://arxiv.org/abs/2502.16982>
- Kimi Linear —<https://arxiv.org/abs/2510.26692>

版本说明: 2026-08-14。本文以公开论文、公开项目与“科学空间”公开文章所形成的研究脉络为基础, 重点用于技术学习与研究复盘, 而非作者个人传记。